2026 年 MathorCup 数学应用挑战赛——大数据竞赛

赛道 A：啤酒酿造化合物分析与啤酒风味预测

队伍编号	MCB26XXXXX（提交前替换为报名号）
赛道	A

基于数据核验、共变网络与约束生成的啤酒感官评分与风味指纹研究

摘　要

啤酒风味由数百种化合物共同决定，其化学组成与感官感知之间存在高度非线性、多尺度的耦合关系。本文以 250 款比利时商品啤酒的 231 项化学测量、50 个感官维度与 22 个风格标签为对象，按“先把数据认清、再谈模型”的顺序完成三个问题。数据核验确认：样品须按 beer 序号而非 beer_id 对齐；1.csv 仅有 73 个缺失格（0.13%），但删行会损失 25.2% 样本；借助 8.xlsx 可判定 37 个参数列为 log10 记录值，并还原“非正原生值取最小正值一半再取对数”的下限规则；重算证明 2.csv 实为 Spearman 矩阵（偏差 1.6×10^{-16}，Pearson 假设下为 0.087）；还复原出 5 个派生量的精确关系——热量换算与四类“浓度/阈值”式气味活度加和，残差约 10^{-10}。

问题 1 用“训练折内中位数填补—1%/99% 缩尾—标准化—多输出回归”的嵌套交叉验证框架，在 Ridge 与 PLS 共 9 个候选中选出 PLS（10 主成分）：随机 5 折 50 维平均 MAE=0.354（均值基线 0.417）、平均 R^2=0.217，整风格留组 R^2=0.157；90% 共形区间边际覆盖 90.1%，50 维联合覆盖仅 84%。按公开单调的协议 A 给出 250×50 的 0–6 工作等级并填制 3.xlsx，以协议 B 做敏感性对照（逐格一致率仅 23.4%），明确等级不可唯一还原的边界。问题 2 构建 $|\rho|\geq0.6$ 的共变网络（266 条边、19 个非单点模块、模块度 0.745），用 Spearman、岭回归（λ=100）与 5 箱 η^2 的 Borda 平均名次给出 Top-3；200 次 bootstrap 入选频率中位数仅 0.41、方法间平均 Jaccard 仅 0.27，因此名单必须与稳定性一起交付。

问题 3 先建类别条件高斯 copula 基线，再以“生成 226 个基础量→按公式重算 5 个派生量”保证结构自洽，并用类条件收缩经验分布修复零/负值原子，留出能量距离由 29.65 降到 22.47。Tripel、Kriek、Lambic 各生成 100 条化合物谱与 50 维感官画像，画像与真实风格均值相关 0.88/0.96/0.97。跨风格迁移把 11 款 Pils/Lager 迁移为 Tripel：四项缺陷与陈酒花味 Y38 全部逐对象不升高，监督分类器判为 Tripel 的平均概率由 2.4% 升至 39.1%；一维 Wasserstein 下界（DMS 1.78、双乙酰 1.47、4-VG 0.024、反-2-壬烯醛 1.17）说明“逐对象不恶化”与“完整匹配目标分布”不可兼得。

关键词：啤酒风味；感官评分；嵌套交叉验证；共变网络；稳定性选择；高斯 copula；跨风格迁移；可识别性

目　　录

一、问题重述与分析.....1
1.1 问题背景.....1
1.2 数据说明.....1
1.3 三个任务的建模思路.....2
二、数据核验与预处理.....2
2.1 样品对齐、缺失与异常.....2
2.2 化学量的标度核验.....3
2.3 相关矩阵类型与文件结构核验.....4
2.4 感官标签的性质.....5
2.5 派生量的复原.....5
2.6 建模空间与预处理.....6
三、问题 1：数据缺失条件下的感官评分.....7
3.1 问题分析与技术路线.....7
3.2 连续评分预测模型.....7
3.3 交叉验证结果.....9
3.4 预测不确定性的量化.....10
3.5 额外缺失下的稳健性.....11
3.6 由连续预测到 0–6 分级评分.....12
3.7 关于“原始 0–6 等级能否还原”的讨论.....14
3.8 结果分析与讨论.....14
四、问题 2：化合物－风味关联分析.....15
4.1 共表达网络的构建.....15
4.2 模块的化学解释.....16
4.3 三种关联视角与 Top-3 关键化合物.....17
4.4 稳定性分析.....18
4.5 化学合理性与阈值证据.....19
4.6 小结.....20
五、问题 3：风味与“风味指纹”生成.....20
5.1 问题分析.....20
5.2 类别条件高斯 copula 基线.....21
5.3 结构一致的生成：226 个基础量 + 5 个派生量.....22
5.4 生成样本的感官画像.....24
5.5 跨风格迁移：Pils/Lager → Tripel.....25
5.6 “缺陷不恶化”到底能保证什么.....27
5.7 小结.....28
六、模型评价与推广.....28
6.1 模型优点.....28
6.2 局限性与改进方向.....28
6.3 应用推广.....29
七、结论与建议.....29
参考文献.....30
AI 工具使用声明.....32
附录 A 核心代码（节选）.....32
附录 B 50 个感官维度的 Top-3 关键化合物（完整表）.....34
附录 C 支撑材料清单.....36

一、问题重述与分析

1.1 问题背景

啤酒是以麦芽、水为主要原料，添加啤酒花并经酵母发酵酿制而成的低酒精度发酵酒。它的风味不是由某一种“神奇化合物”决定的，而是由几百种化合物按浓度、阈值和相互作用的“合奏”决定：酒花带来萜类化合物，贡献草本与柑橘香；酵母在发酵中产生酯类和高级醇，贡献果香、花香与酒精感；麦芽在焙烤与糖化过程中生成呋喃、吡嗪和醛类，贡献面包、焦糖与烟熏香[1,2,3,4]；酒花萜类中的香叶醇与里哪醇还通过协同作用贡献柑橘香[5]。与此同时，二甲基硫（DMS）、双乙酰、4-乙烯基愈创木酚（4-VG）、反-2-壬烯醛等化合物在超过各自阈值后会变成“缺陷”，分别对应煮玉米味、黄油味、丁香/药味和纸板味[2,6,7]。

如果能够由化学组成定量预测感官风味，并进一步按风格“设计”化合物谱，就能把酿酒师凭经验反复试错的过程，变成可计算、可复核的优化问题。这正是本题的数据背景：原始研究[1]对 250 款比利时商品啤酒做了系统化学分析与 16 人训练品评小组的感官评价，覆盖 22 个风格、226 项化学性质（加 5 个派生量共 231 列）与 50 个感官属性。本题要求在这套数据上完成三件事：缺失条件下的感官评分、化合物—风味的关联解释、以及风格条件生成与跨风格迁移。

1.2 数据说明

附件共 8 个文件。题面文字与附件实际内容存在若干不一致（这是本题的一部分，不是“隐藏彩蛋”）：赛题称“226 种不同啤酒”，附件实际是 250 个样品（参考原文为 250 个样品、226 项化学参数，因此 226 更可能指化学参数数量）；正文称 2.csv 为 Pearson 相关，数据说明称 Spearman；正文称 3.xlsx 有 10 个工作表，实际是 12 张单样品评分卡加 1 张 summary；6.csv 实际 44 行而非 46 行；7.csv 实际 186 个描述符而非 187 个。本文一律以附件实际数据为准，并在第二章逐项核验。

表 1 附件数据构成与本文核验结论

文件	实际规模	内容与核验结论
1.csv	250×234	250 个样品×231 项化学特征；37 列为 log10 记录值，33 列为原值/响应值；缺失 73 格
2.csv	231×231	231 个化合物间相关矩阵；重算证明为 Spearman（1.6×10^{-16}），而非题面所写 Pearson
3.xlsx	12 张卡片+summary	空白评分卡模板，Aroma/Flavour 两套共 52 个项目（50 个有目标列）；0–6 分
4.csv	250×53	50 个感官维度的连续值，为逐品评员 z 化后的均值，不是原始 0–6 分
5.csv	50×50	50 个感官维度间的相关矩阵（Spearman）
6.csv	44×51	44 项化学指标×50 个感官属性的交叉相关矩阵（题面称 46 行）

文件	实际规模	内容与核验结论
7.csv	250×189	250 个样品×186 个评论描述符（题面称 187 个），含 750 个缺失
8.xlsx	7 张工作表	感官阈值、校准化学数据、GBM 重要性/SHAP、啤酒价格等参考数据

1.3 三个任务的建模思路

问题 1 是一个“高维小样本、多输出、含缺失且标签被预处理过”的回归问题。我们把任务拆成两段：第一段用化学特征预测 4.csv 的连续感官值，这一段的精度可以用折外误差客观评价；第二段把连续值映射为 0–6 等级，这一段必须承认“原始整数标签没有被附件给出”，因此用公开、单调、可复核的分级协议完成，并把协议变化带来的影响量化出来。

问题 2 是一个“关联结构 + 排序 + 稳定性”的问题。先用 2.csv 画出化合物之间的共变网络，寻找化学上“抱团”的模块；再用三种互补的关联视角给每个感官维度排序，聚合出 Top-3；最后用 bootstrap 重采样回答一个容易被忽略的问题：如果换一袋 250 个样品，这个名单会换掉几个人？

问题 3 是一个“条件生成 + 约束迁移”的问题。先学习“给定风格，生成符合该风格的化合物谱”的模型，再训练好的评分器把化合物谱映射成感官画像；跨风格迁移时，把目标风格的类中心作为“方向”，用约束优化保证 4 个缺陷化合物和 1 个缺陷感官维度逐对象不恶化。全程区分三件事：分布像不像、代数关系对不对、缺陷指标是否安全。

二、数据核验与预处理

本章的结论全部来自实际计算，而不是读表猜测。数据核验决定了后面所有模型能不能建立在一个正确的“刻度”上，因此我们把它放在建模之前单独成章。

2.1 样品对齐、缺失与异常

第一个容易踩的坑是“用哪一列连接不同文件”。1.csv、4.csv、7.csv 都有 beer 列与 beer_id 列：beer 是 1–250 的序号，三个文件的 beer 完全同序、对应的 tasting_category_fine 也完全一致；而 beer_id 在 1.csv 与 4.csv 中逐个不同，4.csv 的 beer_id 还只有 96 个不同取值（原始表取整所致）。如果按 beer_id 连接，几乎每一行都会错位。因此全文一律按 beer 序号对齐。

第二个坑是缺失。231 个化学特征共 250×231=57 750 个单元格，其中只有 73 个缺失（0.13%），分布在 9 个特征、63 个样品上；缺失最多的是乙酸戊酯（27 格）、酒花香气总和（13 格）、甲基吡嗪（12 格）、双乙酰（9 格）与 3-甲基丁醛（7 格）。缺失比例虽低，但直接删掉含缺失的 63 行会损失 25.2% 的样本，在只有 250 个样品的任务里

代价太大。本文的处理是：保留全部样品，在每一折训练数据内部用该折的列中位数填补，验证/测试样本只使用训练折参数；同时对极端值做 1%/99% 分位缩尾（只限制影响力，不删除原始数据）[8]。

第三个坑是“模板里的 0 不是评分者的 0”。3.xlsx 的 12 张评分卡中，624 个分数格全部是公式，缓存值均为 0；按公式逐项识别，每张卡有 220 个真实勾选格，共 2 640 个，非空勾选为 0。这些 0 是“未勾选时公式返回 0”，不是人工给出的 0 分。因此后续绝不能拿模板缓存值当训练标签。

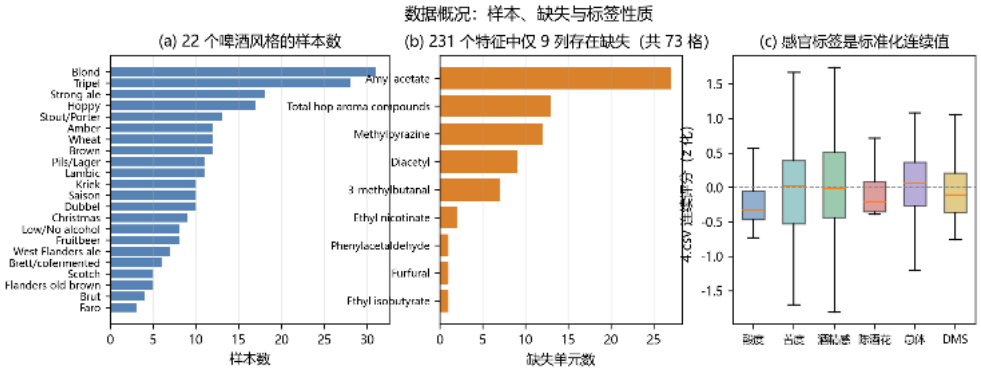


图 1 数据概况。(a) 22 个风格的样本数；(b) 231 个特征中仅 9 列存在缺失（共 73 格）；(c) 4.csv 的感官目标是标准化后的连续值（含负值），并非原始 0–6 分。

2.2 化学量的标度核验

1.csv 里有些数字是“原值”，有些是“对数”。这像调音台上的音量旋钮：读数每加 1，实际音量可能乘 10（log10），也可能乘 e（ln）。如果分不清，后面所有“超过阈值”的判断都会错。好在 8.xlsx 的 Calibrated chemical dataset 提供了 70 列的原生校准值，与 1.csv 按 beer 对齐后可以做“成对核验”。结果显示：37 列满足“记录值 = log10(原生值)”，正值的平均对数误差约 3×10^{-10}；若按 ln 解释，平均误差会达到 0.8–1.8，明显被数据否定。pH、乙醇、色度、苦度、CO_2、DMS、4-VG 等列全部落在前一情形，这与题面“少量理化参数保留原始量纲”的说法不符，必须按 log10 理解。Box 与 Cox 的原始文章也提醒：变换的选择要服务于解释目的，而不能盲从形式计算[9]。

表 2 化学特征标度核验示例（记录值 = log10 原生值）

变量（化学含义）	单位	log10 平均绝对偏差	ln 平均绝对偏差	非正原生值个数
pH（pH）	pH	1.7×10^{-10}	0.80	0
Ethanol（乙醇）	% v/v	2.6×10^{-10}	1.12	1
Color（色度）	EBC	2.9×10^{-10}	1.64	0
Iso-alpha acids（异 α-酸）	IBU	2.3×10^{-10}	1.64	2
DMS（二甲基硫）	μg/L	3.0×10^{-10}	1.81	1
4-VG（4-乙烯基愈创木酚）	mg/L	3.0×10^{-10}	1.19	168

对数还有一个“不可逆”的细节：原生浓度为 0 的样品不能取 log。数据里实际采用的规则是“把非正原生值替换成该列最小正原生值的一半再取对数”，即对某列最小正原生值 m，

$$h(q) = q \ (q > 0); \quad h(q) = m/2 \ (q \le 0); \quad z = \log_{10} h(q) \qquad (2\text{-}1)$$

因此 10^z 恢复出来的是“替换后的正数”，不是原始 0。最典型的是 4-VG：168 个原生 0 全部被压到同一个有限值 $\log_{10}(0.0194031667/2) = -2.013157381$。如果直接把该值取 10 的幂，会得到 0.0097 mg/L 而不是 0，这在问题 3 的缺陷判定中会直接改变结论。本文对已有样品用 8.xlsx 的原生参照恢复真实 0；对生成的新样品则明确声明“只能给出与观测下限相容的候选值”，不冒充唯一还原。

另外，8.xlsx 与 1.csv 的“原生参照”并非逐格完全一致：在按原值保留的 33 列中，有 86 个单元格的绝对差超过 10^{-7}（例如 object 64 的芳樟醇记录为 0.371，参考表为 33.57）。没有来源说明时无法判断谁是纠错真值，本文以题面指定的 1.csv 为计算基准，只在缺失处用参考值补充，并把全部冲突逐格保存备查。

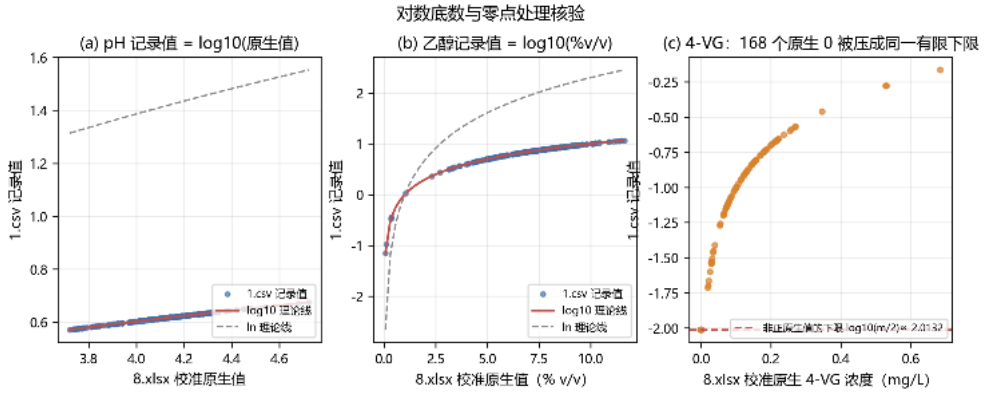


图 2 标度核验。(a)(b) 记录值与 8.xlsx 原生校准值满足 10^记录值=原生值，ln 假设明显偏离；(c) 原生浓度为 0 的 4-VG 被替换为“最小正值的一半”后取对数，因此 10^记录值≠0。

2.3 相关矩阵类型与文件结构核验

题面正文说 2.csv 是 Pearson 相关，数据说明却说是 Spearman。两者不是一回事：Pearson 看“数值是否一起线性涨落”，Spearman 只看“名次是否一起涨落”，后者对“很久才爆发一次、一爆发就很大”的痕量化合物更稳健[10]。我们用 1.csv 的原始观测逐对重算两种矩阵，再与 2.csv 比较：与 Spearman 的平均绝对偏差只有 1.6×10^{-16}（浮点误差量级），与 Pearson 的偏差是 0.087。因此 2.csv 确为 Spearman 矩阵；5.csv、6.csv 也做同样核验，结论一致。这是后面网络分析必须用“秩相关”而不是“线性相关”的直接依据。

表 3 相关矩阵类型核验（由原始数据重算后与附件矩阵比较）

矩阵	比较单元格数	Spearman 平均绝对偏差	Pearson 平均绝对偏差	结论
2.csv（化合物×化合物）	26 565	1.61×10^{-16}	0.0877	Spearman
5.csv（感官×感官）	1 225	1.60×10^{-16}	0.0513	Spearman
6.csv（化合物×感官）	2 200	1.51×10^{-16}	0.0579	Spearman

文件结构方面，6.csv 实际是 44 行×50 列（题面写 46 行），7.csv 实际 186 个描述符（题面写 187 个）。这两处不一致不影响建模，但提醒我们：程序要按文件实际尺寸读，不能把题面的数字硬塞进数组。3.xlsx 实际有 12 张单样品卡与 1 张 summary，卡片上共 52 个项目；其中 Aroma 块的 A-16 与 Flavour 块的 F-16 都是“乙醛”（Acetaldehyde），在 4.csv 中没有对应目标列，因此最终需要交付的是 50 个维度而不是 52 个；填卡时这两项标为 N/A 并写明原因。

2.4 感官标签的性质

4.csv 的 50 列感官值有负值、各列尺度也不一，显然不是原始 0–6 整数分。参考原始研究[1]的方法可知：每名品评员的打分先被“按个人标准差缩放、按个人均值中心化”，再对同一款酒的品评员取平均。因此观测到的连续值 z 与真实共识分 g 近似满足一个线性潜变量关系

$$z=\frac{g-\mu}{s} \implies z'=\frac{(a+bg)-(a+b\mu)}{bs}=z \tag{2-2}$$

这说明：只凭 4.csv，无法唯一反推原始 0–6 等级——两套不同的原始分数只要相差一个正仿射变换，观测到的 z 就一模一样。更直接的证据是：4.csv 的每一行在 50 个目标上都有 50 个不同取值，因此它不可能只是“同一行的 7 个整数等级做了一次无噪仿射变换”（那样每行最多 7 种取值）。本文因此把“连续预测”和“0–6 分级”分开处理：连续预测用折外指标评价；0–6 等级用公开声明的协议生成，并用两种协议对比其敏感性。

2.5 派生量的复原

1.csv 中有 5 列（kcalperc、esters_sum、aroma_hops_sum、acids_sum、sulfur_sum）是由其他化合物“算出来”的派生量，但附件没有给公式。我们没有停在“未知”上：把 8.xlsx 的原生参照、稀疏线性组合搜索和阈值表放在一起核验，发现这 5 列都能写成少数几个基础变量的简单线性组合，且系数与 8.xlsx 的感官阈值高度接近。记 u_j 为第 j 个变量的原生值（不用 10^记录值，避免对数地板误差），d_j 为派生列记录值，则

$$10^{d_{37}}=0.0003\,u_{27}+0.4\,u_{31}+0.4\,u_{33}+5.523 \tag{2-3}$$

$$10^{d_{228}} = u_6/23 + u_7/1.035 + u_8/0.225 + u_9/0.1 + u_{10}/0.75 + u_{11}/10 + \quad (2\text{-}4)$$

$$10^{d_{229}} = u_{164}/0.625 + u_{118}/1.5 + u_{155}/0.23 + u_{121}/0.0245 + u_{128}/0 \quad (2\text{-}5)$$

$$10^{d_{230}} = u_{23}/0.145 + u \quad (2\text{-}6)$$

$$10^{d_{231}} = u_2/50 + u_3/1.2 + u_4/19 + u_{12}/3 \quad (2\text{-}7)$$

这些分母（1.035、0.225、0.1、0.75、10、0.625、1.5、0.23、0.0245、0.023、0.0045……）与 8.xlsx 的阈值表几乎一一对应，说明派生量的本质是“浓度除以阈值再求和”的气味活度（OAV）式加和：总酯、酒花香气、总酸、硫化合物各自把一组化合物的“气味单位”加起来；kcalperc 则是热量换算。这给问题 3 一个非常重要的结构性约束：生成新配方时，不能让 231 个坐标各自独立采样，而应先生成基础量，再按上式重算派生量。

表 4 5 个派生量的复原关系与核验误差（记录尺度）

派生列	化学含义	核验对象数	平均绝对误差	最大绝对误差
kcalperc（V037）	热量	250	2.6×10^{-10}	5.0×10^{-10}
esters_sum（V228）	总酯（OAV 式）	250	2.5×10^{-10}	4.9×10^{-10}
aroma_hops_sum（V229）	酒花香气（OAV 式）	237	2.6×10^{-10}	5.0×10^{-10}
acids_sum（V230）	总酸（OAV 式）	250	2.7×10^{-10}	5.0×10^{-10}
sulfur_sum（V231）	硫化合物总和	250	2.4×10^{-10}	5.0×10^{-10}

注：V229 有 13 个样品缺失；若直接用 1.csv 的 10^记录值替代原生值，最大误差会因十进制定点误差放大到 3.4×10^{-8}，改用 8.xlsx 原生参照后降到 5.0×10^{-10}，与其余四列一致。

2.6 建模空间与预处理

三个问题使用的“空间”不同，必须在文中说清：问题 1 在 1.csv 的混合记录刻度上建模；问题 2 在网络与排序中使用秩（名次）空间；问题 3 既需要把化合物谱从记录刻度还原到原生刻度，又需要把感官画像放回 D04 连续刻度。所有标准化、缩尾、填补的参数都只在训练数据内部估计，验证数据只“套用”参数，不参与估计。问题 1 的预处理写成公式是

$$\tilde{x}_j = \frac{\mathrm{clip}(\mathrm{fill}(x_j, m_j),\ a_j,\ b_j) - \mu_j}{s_j} \quad (2\text{-}8)$$

其中 m_j 是训练折第 j 列的中位数，a_j、b_j 是训练折填补后该列的 1% 与 99% 分位点，μ_j、s_j 是缩尾后训练列的均值与标准差；缺失位置填 m_j，其余位置保留原值再缩尾。对应代码只有“填中位数、做缩尾、减均值除标准差”三步，但每一步的参数都来自当前训练折，避免信息泄漏。问题 2 把每列先转成平均名次、再标准化（秩空间），

问题 3 则用经验分布函数把每列映射到标准正态（秩-高斯变换），从而让不同量纲的化合物可以放在同一个协方差结构里。

三、问题 1：数据缺失条件下的感官评分

3.1 问题分析与技术路线

问题 1 的输入是 231 维化学特征，输出是 50 个感官维度。它有三个现实困难：第一，样本只有 250 个，特征却有 231 个，而且特征之间高度共线（酯类之间、酒花萜烯之间往往“同涨同落”），直接给每个特征一个自由系数会非常不稳；第二，数据有缺失与极端值；第三，4.csv 给出的不是原始 0–6 分，而是标准化后的连续值，我们没有真实的整数等级可以拿来做“准确率”。因此本文把任务拆成两段：先用回归模型预测连续感官值，这一段可以用折外（out-of-fold）误差客观评价；再用公开的分级协议把连续值变成 0–6 等级，这一段只做“可复核的相对分级”，不冒充原始标签。

技术路线可以概括成一条链：读取 1.csv 与 4.csv 并按 beer 对齐 → 在每一折训练数据内完成中位数填补、1%/99% 缩尾与标准化 → 用嵌套交叉验证在 Ridge 与 PLS 的 9 个候选中选模 → 得到每个样品的折外连续预测 → 用共形预测给出不确定性区间 → 按协议 A 生成 0–6 工作等级并填制 3.xlsx → 用协议 B 与斜率扰动做敏感性分析。

3.2 连续评分预测模型

（1）岭回归。把训练输入记为矩阵 X（n×231），50 个目标记为矩阵 Y（n×50），我们要求一个系数矩阵 B（231×50），使预测 XB 接近 Y。普通最小二乘只最小化平方误差，当 X 的列高度相关时，B 会变得很大且随样本微小变化而剧烈摆动；岭回归在平方误差上加一个“系数别太大”的惩罚：

$$L(B) = \|Y - XB\|_F^2 + \lambda \|B\|_F^2 \qquad (3\text{-}1)$$

对 B 求导令其为 0，得到 $(X^TX + \lambda I)B = X^TY$。$\lambda>0$ 时，即使 X 有完全重复的方向，这个方程也有唯一解；λ 越大，系数被压得越狠。直观地说，当两个变量提供相同信息时，平方惩罚会让它们“平摊”权重，而不是一个取很大的正数、另一个取很大的负数互相抵消[11]。

（2）偏最小二乘（PLS）。PLS 不直接解上面的方程，而是先找少数几个“旋钮”：每个旋钮是 231 个特征的一个加权组合，要求这个组合与目标矩阵的协方差尽量大，然后把已经解释掉的部分从数据中减掉，再找下一个旋钮。它与主成分分析的区别是：主成分只看输入自身波动最大的方向，而 PLS 会“看着目标”挑方向，因此可能保留输入里

波动不大、但对感官有用的方向[12]。本文使用能同时处理 50 个输出的 PLS2，旋钮数在 {2, 5, 10, 20} 中选。

（3）候选与选模。候选共 9 个：5 个岭回归（$\lambda \in \{0.1, 1, 10, 100, 1000\}$）与 4 个 PLS（主成分数 $\in \{2, 5, 10, 20\}$）。每个候选都封装成“预处理 + 回归 + 目标标准化”的流水线：50 个目标的量纲不同，训练时先把每个目标减去训练均值、除以训练标准差，预测后再变回 D04 刻度，避免波动大的目标独占 PLS 的方向。

选模必须回答两个问题：选哪个模型、以及“选模型这个过程”本身遇到新样品时表现如何。本文使用两圈交叉验证：外层把 250 个样品分成 5 折，每次藏起 1 折（50 个）作为“新样品”；在剩下的 4 折里再做 3 折内层交叉验证，只根据内层结果选模型与参数。内层的选择指标是“按每个目标训练标准差归一化后的均方误差”的平均：

$$\mathrm{NMSE} = \frac{1}{50}\sum_{j=1}^{50} \mathrm{mean}_i \left[\frac{(Y_{ij} - \hat{Y}_{ij})^2}{(s_j^{\mathrm{train}})^2} \right] \qquad (3\text{-}2)$$

这样大波动的目标不会因为数值大就主导选择。外层只评估“选完模型后的预测”，不参与选模，从而避免“看完外层成绩再挑赢家”的选择偏差[13]。为了检查结论是否只在随机划分下成立，我们还做了两种留组验证：整风格留组（把同一风格的全部样品一起藏起来，模拟“遇到没见过的风格”）与按 4.csv 重复编号留组（重复编号的语义未知，仅作敏感性分析）。

（4）不确定性。点预测之外，本文用分离式共形预测给出区间[14,15]。把 200 个样品分成 150 个训练、50 个校准、50 个测试；在训练集上选模并拟合后，对每个目标计算 50 个校准绝对残差，取第

$$\mathrm{rank} = \lceil (n_{\mathrm{cal}} + 1) \times 0.9 \rceil = \lceil 51 \times 0.9 \rceil = 46 \qquad (3\text{-}3)$$

小的残差 q_j 作为半宽，则新样品的 90% 边际区间是 $[\hat{y}_j - q_j, \hat{y}_j + q_j]$。这个构造只要求“校准样品与未来样品可交换”，不要求模型一定正确，因此比“假设残差服从正态分布”更稳妥。对 50 维同时覆盖，则先算每个校准样品“最差维度的标准化残差”，再取第 46 小值作为联合盒子的半宽：

$$r_i^{\max} = \max_j \frac{|z_{ij} - \hat{y}_j(x_i)|}{s_j^{\mathrm{train}}} \qquad (3\text{-}4)$$

如果某样品的最大标准化残差被覆盖，它的 50 个维度就同时被覆盖；这避免了“50 个 90% 区间不等于 95%/90% 联合区间”的常见误读。

3.3 交叉验证结果

表 5 给出三种验证协议下 4 个模型族的 50 维平均结果。最终内层选择规则在全部 250 个样品上选出 PLS（10 个主成分）。随机 5 折下，选定的 PLS 平均 MAE 为 0.354，均值基线为 0.417（逐维度改善比例平均 13.2%）；平均 R^2 为 0.217，50 个维度全部为正。整风格留组时平均 R^2 降到 0.157，说明“遇到没见过的风格”确实更难，但模型仍明显好于均值基线。

表 5 三种验证协议下的 50 维平均结果（MAE 越小越好，R^2 越大越好）

模型	随机 5 折 MAE	随机 5 折 R^2	整风格留组 MAE	整风格留组 R^2	重复编号留组 R^2
均值基线	0.4169	−0.0069	0.4216	−0.0290	−0.0136
岭回归	0.3541	0.2085	0.3667	0.1619	0.2045
PLS	0.3532	0.2238	0.3662	0.1749	0.2104
内层选定流程	0.3544	0.2172	0.3688	0.1573	0.2104

值得注意的是，PLS 与岭回归的差距很小（平均 R^2 相差约 0.015），而内层选定的流程反而略低于“只用 PLS”。这不是异常，而是选择偏差的代价：内层要同时选算法族与参数，会偶尔选到岭回归（整风格留组协议下 5 折中有 2 折改选岭回归），这种波动本身就应该被报告，而不是只挑一个最好看的数字。它也提示：在这套数据上，线性多输出模型已经能拿到大部分可解释的信号，更复杂的模型未必更好——这与原始研究[1]在树模型上得到的量级（训练品评组 R^2 约 0.22）是一致的。

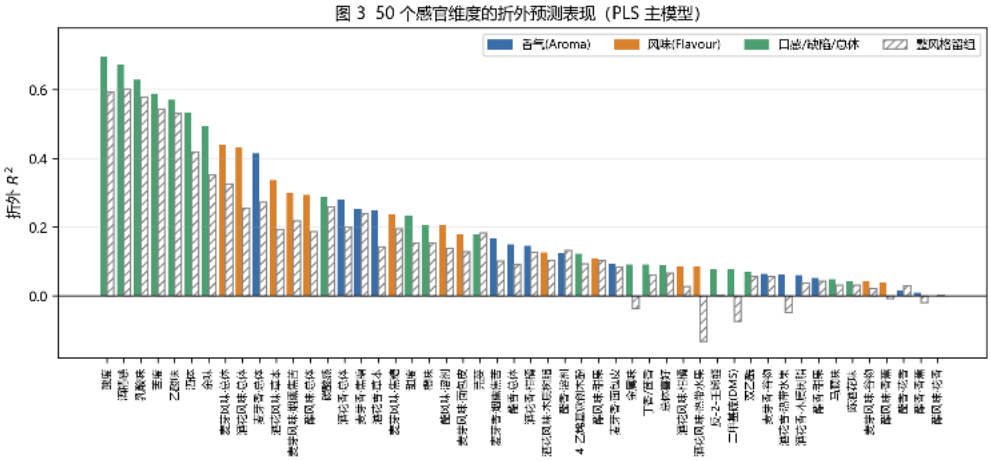


图 3 50 个感官维度的折外 R^2（随机 5 折为主结果，整风格留组为泛化压力测试）。酸度、酒精感、乳酸、苦度、酒体等“化学上有一对一对应物”的维度表现最好；酯香花香、陈酒花味等依赖微量阈值效应的维度最差。

图 3 把 50 个维度逐个展开。表现最好的是酸度（R^2=0.695）、酒精感（0.675）、乳酸味（0.630）、苦度（0.587）、乙酸味（0.571）与酒体（0.533）；最差的是酯香花香（0.002）、酯香香蕉（0.009）、酯香花香（风味，0.016）、酯风味香蕉（0.039）、麦芽

风味谷物（0.043）、陈酒花味（0.044）。这组结果非常符合化学直觉：酸度直接对应 pH 与乳酸/乙酸，苦度直接对应异 α-酸，酒精感直接对应乙醇，酒体与乙醇、蛋白质、甘油相关；而“酯香花香/香蕉”这类描述依赖极低浓度下的阈值与挥发释放，单一化合物浓度并不能决定感知；“陈酒花味”是陈化过程的综合结果，既与反-2-壬烯醛等醛类有关，也受酒花品种、储存条件影响，在 50 个化学测量里没有足够直接的代理变量。

表 6 折外表现最好与最差的感官维度（随机 5 折，选定流程）

最好 6 个维度	R^2	最差 6 个维度	R^2
酸度	0.695	酯香·花香	0.002
酒精感	0.675	酯香·香蕉	0.009
乳酸味	0.630	酯味·花香	0.016
苦度	0.587	酯味·香蕉	0.039
乙酸味	0.571	麦芽风味·谷物	0.043
酒体	0.533	陈酒花味	0.044

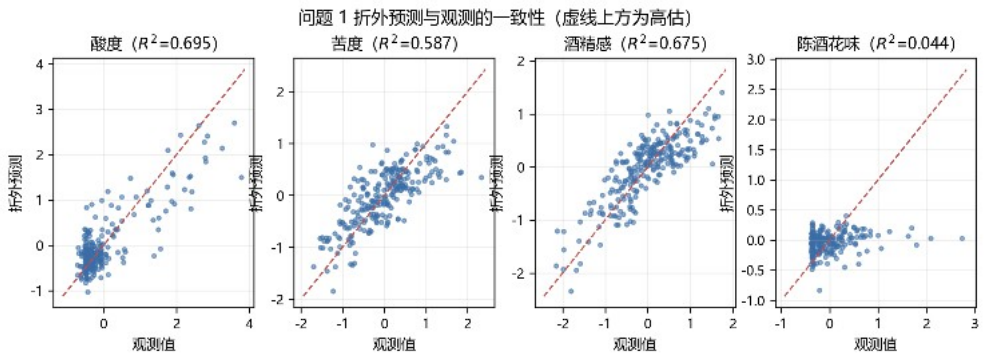


图 4 四个代表性感官维度的折外预测散点。酸度与酒精感接近对角线；陈酒花味的预测值域被明显压缩，说明该缺陷维度难以由现有化学测量稳定预测。

3.4 预测不确定性的量化

50 个测试样品上的实测结果：逐维度 90% 边际区间的平均覆盖率为 90.12%（50 个目标中 2253/2500 个格子被覆盖），各维度覆盖率在 64%–98% 之间，平均区间宽度 1.54 个 D04 单位。覆盖最低的是酒精感（64%），最高的是乳酸味与乙酸味（98%）；区间最宽的是乙酸味（2.20），最窄的是酒精感（1.08）。这说明模型对“酸、苦、酒精”这些强信号维度的预测更稳定，对弱信号维度的不确定性更大——这正是应该告诉使用者的信息，而不是只报一个平均 R^2。

联合覆盖要低得多：50 个测试样品中只有 42 个（84%）的 50 个维度同时落入联合盒子，二项 95% 区间为 [70.9%, 92.8%]；而“50 个边际区间同时覆盖”的经验比例只有 10%。这不是程序错误，而是概率论的基本事实：边际 90% 不等于联合 90%。如果一位酿酒师要同时看 50 个指标，他得到的“全部指标都可信”的概率远低于 90%。

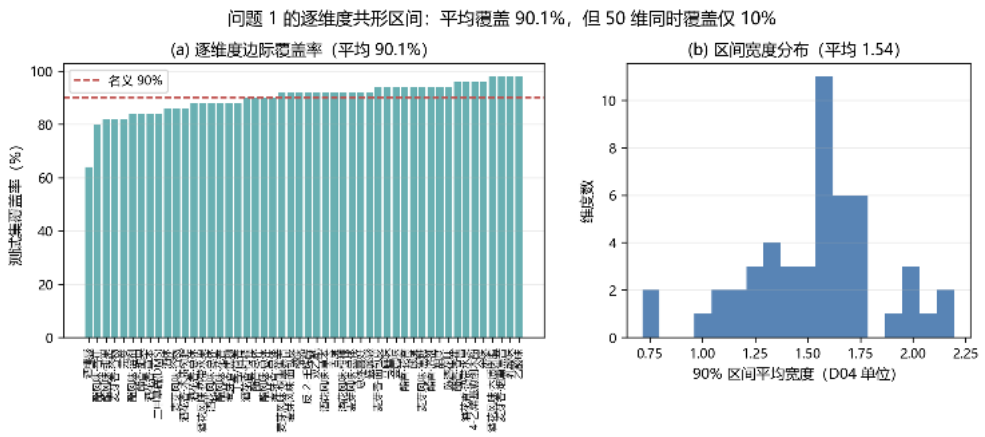


图 5 问题 1 的共形预测区间。(a) 逐维度边际覆盖率平均 90.1%（各维度 64%–98%）；(b) 区间宽度分布。联合盒子在 50 个测试样品上的覆盖为 84%（42/50）。

3.5 额外缺失下的稳健性

题目强调“数据缺失条件”。原始数据只有 73 个缺失格，为了检验模型在更严重缺失下的行为，我们做了一个额外的压力实验：在每一折训练集与测试集的原始非缺失格上再随机挖空 10%/30%/50%，仍用训练折中位数填补、其余流程不变，重复 5 折。结果见表 7 与图 6：平均 MAE 从 0.353 升到 0.356/0.364/0.377，平均 R^2 从 0.180 降到 0.165/0.135/0.077。退化是渐进的，没有出现“缺失一多就崩溃”的情况；在 30% 额外缺失时把中位数填补换成 KNN 填补（k=5）只带来很小改善（MAE 0.3627、R^2 0.139），说明在当前缺失率下填补方法不是瓶颈。

表 7 额外随机缺失下的折外表现（PLS 主模型，同一 5 折划分）

额外缺失比例	平均 MAE（中位数填补）	平均 R^2（中位数填补）	平均 MAE（KNN 填补）	平均 R^2（KNN 填补）
0%	0.3532	0.1795	0.3532	0.1793
10%	0.3564	0.1651	—	—
30%	0.3641	0.1347	0.3627	0.1394
50%	0.3771	0.0765	—	—

注：本表是补充压力实验，用同一 5 折但只训练 PLS(10)，不做内层选模，因此 0% 时的数值（0.3532/0.1795）与表 5 的“选定流程”（0.3544/0.2172）略有差异，两者不能混用。

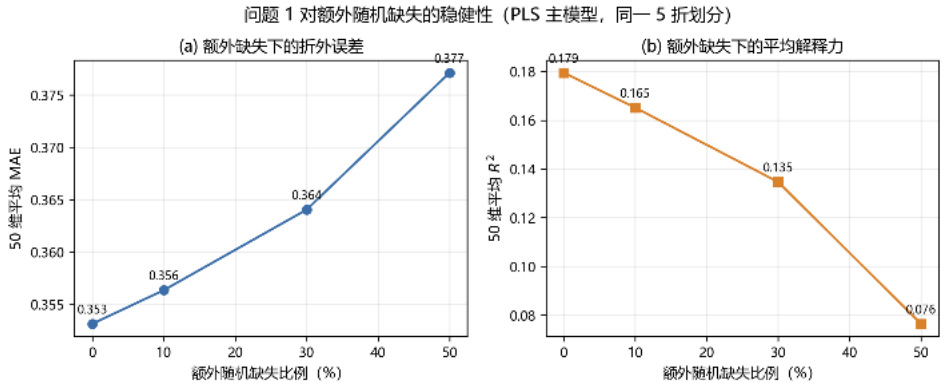


图 6 额外随机缺失稳健性。在原始 73 个缺失格之外再挖空 10%/30%/50%，平均 MAE 由 0.353 升至 0.356/0.364/0.377，平均 R^2 由 0.180 降至 0.165/0.135/0.077，退化是渐进的。

3.6 由连续预测到 0–6 分级评分

题目要求给出 0–6 的分级评分。由于原始整数等级不可识别，本文采用一个公开、单调、容易复核的“尺子”（协议 A）：把训练目标的均值位置规定为 3 分，每偏离一个训练标准差加 1 分，再四舍五入并截断到 0–6：

$$G_j(z) = \mathrm{clip}\left(\left\lfloor 3 + \frac{z-\mu_j}{s_j} + 0.5 \right\rfloor,\ 0,\ 6\right) \tag{3-5}$$

其中 μ_j、s_j 是训练目标 j 的均值与总体标准差，⌊·⌋ 是向下取整，+0.5 表示“半级向上”，避免不同软件默认舍入方式造成的歧义。这个协议保证 z 越大等级不会越小，因此后续“迁移后不恶化”的比较可以在同一把尺子下进行。为了检验分级口径的影响，另设一个含义不同的协议 B：把训练目标从小到大排列，取 1/7、2/7、…、6/7 六个分位点作切点，数一个预测值越过了几个切点（分位点定义与边界处理按 NumPy 官方文档实现）[16]：

$$G_j^{B}(z) = \sum_{r=1}^{6} \mathbf{1}\{z \ge q_{jr}\}, \qquad q_{jr} = \mathrm{quantile}_{r/7}(Y_j) \tag{3-6}$$

协议 A 用“标准差”做单位，保留连续尺度的距离；协议 B 用“相对分布位置”做单位，接近等频分箱。两者都是合法但不同的尺子。同一批连续预测在两种协议下的结果差别很大：全拟合时逐格一致率只有 23.4%，平均绝对等级差 1.04 级，B 比 A 平均高 0.42 级；折外预测下一致率为 25.9%，平均绝对差 0.99 级。

表 8 协议 A 与协议 B 的一致性，以及陈酒花味（Y38）的等级分布

比较项	全拟合预测	折外预测
两协议逐格一致率	23.4%	25.9%
平均绝对等级差	1.04 级	0.99 级
B − A 平均差	+0.42 级	+0.48 级
Y38 达到等级 ≥2 的比例（协议 A）	99.6%	99.6%

比较项	全拟合预测	折外预测
Y38 达到等级 ≥2 的比例（协议 B）	92.4%	95.2%

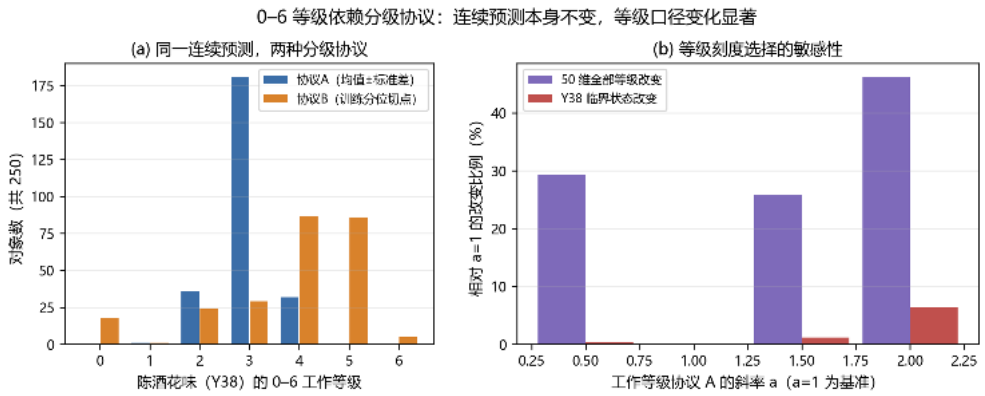


图 7 评分协议的敏感性。(a) 同一批连续预测在协议 A 与协议 B 下得到不同的陈酒花味等级分布；(b) 协议 A 的斜率从 1 变为 0.5/1.5/2 时，全部等级改变 29.3%–46.3%，但“是否达到等级 2”的判定改变较小（0.4%–6.4%）。

进一步把协议 A 的斜率从 1 改成 0.5、1.5、2：相对斜率 1，12 500 个等级中分别有 29.3%、25.8%、46.3% 发生改变；但只看陈酒花味“是否达到等级 2”，改变比例分别只有 0.4%、1.2%、6.4%。这给出一个很有用的结论：绝对等级对尺子很敏感，但“是否越过某条临界线”这种二值判断要稳健得多。后面的跨风格迁移正是利用这一点：我们不承诺绝对等级，只在同一把固定尺子下承诺“等级不升高”。

按协议 A，我们把 250 个样品的 50 维工作等级写入官方 3.xlsx 的 12 张评分卡与 summary（600 个卡片分数格、564 个 summary 格，逐格回读一致），并在卡片的 B104 单元格与 summary 第 15 行写明评分口径。A-16/F-16 两项乙醛没有对应目标列，标为 N/A 并注明原因。表 9 给出前 12 款啤酒的部分维度作为示例；完整的 250×50 等级矩阵在支撑材料中。

表 9 前 6 张评分卡的感官维度示例（协议 A，全拟合模型）

Beer	风格	酸度	苦度	酒精感	二甲基硫	陈酒花味	总体喜好
1	Brut	3	3	4	3	3	4
2	Low/No alcohol	2	2	0	2	2	2
3	Blond	3	3	3	3	2	3
4	Strong ale	3	3	4	3	2	4
5	Blond	3	4	3	4	2	3
6	Amber	2	3	4	3	3	3

注：示例仅用于展示填表格式；12 张卡的完整等级见支撑材料的 250×50 矩阵与 3.xlsx。

3.7 关于“原始 0–6 等级能否还原”的讨论

这一节要回答一个容易被论文回避的问题：既然给出了 0–6 等级，它到底有多“真”？答案是：在没有真实锚点的前提下，绝对等级不可识别；我们能做的是把“不可识别”的边界写清楚。理由在 2.4 节已经给出：$z=(g-\mu)/s$ 对 g 的正仿射变换不变。进一步，若假设同一目标在所有样品上共用一套未知的六个单调切点，则在不加任何真实锚点时，每个观测值 z 的可能等级集合仍是 $\{0,1,2,\ldots,6\}$：对任意 k，把前 k 个切点放在 z 左边、其余放在 z 右边，就构造出一套让 z 恰好得 k 分的合法切点。也就是说，“一个数到底该是几分”在没有锚点时不只是一个统计估计问题，而是信息不足。

如果再增加一个假设“本批 50 个目标中每个目标的 7 个等级都出现过”，可能的集合会收紧一些，但依然很宽：12 500 个格子中只有 945 格（7.6%）的可行集合变小，162 格（1.3%）收缩为单点，平均集合大小仍有 6.73/7；对陈酒花味“是否达到等级 2”，250 行中只有 17 行可以被判定，其余 233 行仍横跨临界线。这说明：任何声称“准确恢复了原始 0–6 分”的做法都不可验证。如果未来能拿到真实整数标签，则可以用有序 probit/logit 之类的潜变量模型来做校准[17]；从统计上看，这又是典型的“部分识别”问题[18]：数据只能约束一个可能集合，不能唯一确定参数。本文因此只把整数表当作“工作等级”，把连续预测当作主结果，并在问题 3 的安全比较中使用“同一固定协议下的相对不升高”，而不是“真实等级不升高”。

3.8 结果分析与讨论

问题 1 得到的核心结论有三条。第一，化学组成确实携带可观的感官信息：50 个维度全部取得正 R^2，最强的酸度、酒精感、苦度、酒体都能达到 0.5 以上，这为后续“用化学谱设计风味”提供了基础。第二，不同维度的可预测性差异极大：凡是化学测量与感知之间存在“一对一”对应物的维度（pH—酸度、异 α-酸—苦度、乙醇—酒精感、CO_2—碳酸感）都容易预测；凡是依赖阈值、挥发、相互作用或陈化过程的维度（酯香、花香、陈酒花味）都很难，因为这些感知不是由某一个浓度单独决定的。第三，预测的不确定性必须逐维度报告：平均 90% 覆盖不等于 50 维联合 90% 覆盖，联合覆盖只有 84%，这对下游使用（例如同时看 50 个指标做决策）是非常重要的提醒。

从建模角度看，线性多输出模型（PLS/岭回归）在这套 250×231 的数据上已经接近“可解释信号”的上限，且训练与调参成本低；更复杂的模型需要更多样本才能体现优势。本文保留 PLS 作为主模型，不是因为它“最先进”，而是因为它在嵌套验证下表现稳定、系数可解释、并且能为问题 3 提供分段线性的评分器。

四、问题 2：化合物–风味关联分析

4.1 共表达网络的构建

问题 2 要求用 2.csv 构建化合物共表达图。第一步不是画图，而是确认“相关”的定义。2.3 节已经用原始数据证明 2.csv 是 Spearman 矩阵，因此网络中的“相关”应理解为“名次一起涨落”。我们保留相关系数的正负号（正=同向，负=反向），但连边强弱用绝对值：

$$A_{jk} = |\rho_{jk}| \cdot \mathbf{1}\{|\rho_{jk}| \geq 0.6\}, \qquad A_{jj} = 0 \tag{4-1}$$

阈值 0.6 是预先声明的展示阈值，不是从图上“调”出来的自然常数。网络用 Louvain 算法做社区发现[19]：它从每个点各自成团开始，反复尝试把点移到邻居团里，使模块度增加，最后把每个团缩成一个新点继续，直到不再提升。模块度衡量的是

$$Q = \frac{1}{2m}\sum_{j,k}\left[A_{jk} - \frac{k_j k_k}{2m}\right]\mathbf{1}\{c_j = c_k\} \tag{4-2}$$

即“圈内实际连线强度”减去“按节点总连接强度随机搭线时预期的圈内强度”，再对所有圈求和。Q 越高说明圈内连接比随机情况越密集。需要强调：Louvain 是启发式优化，高 Q 不代表找到了“唯一真实的分类”，模块度还有分辨率限制[20]。

在阈值 0.6 下，231 个化合物形成 266 条边、120 个社区（其中 101 个是孤立点，只有 19 个社区含 2 个以上变量），模块度 Q=0.7446；最大连通分量包含 99 个化合物、242 条边。表 10 给出阈值与随机种子的敏感性：把阈值从 0.4 调到 0.8，边数从 1660 降到 39、非单点社区从 21 增到 208，与 0.6 划分的 ARI 最低只有 0.098；而固定阈值 0.6、只换 Louvain 随机种子，ARI 最低仍有 0.955。结论是：网络结构对“连边阈值”敏感，对“算法种子”不敏感。因此我们在正文中把 0.6 当作展示尺度，并用 0.4–0.8 的完整表说明结构的不确定性。

表 10 连边阈值对网络结构的影响（Louvain 种子固定）

绝对相关阈值	边数	社区数（含孤点）	孤立点数	模块度 Q	与 0.6 划分的 ARI
0.4	1 660	21	14	0.5021	0.214
0.5	645	58	48	0.6552	0.383
0.6	266	120	101	0.7446	1.000
0.7	109	171	150	0.7442	0.384
0.8	39	208	194	0.6853	0.098

为了检验“边本身”是否稳定，我们对 250 个样品做 40 次有放回重采样，每次重新计算 Spearman 矩阵、重建网络、重跑 Louvain，再与全样本网络比较：社区划分的 ARI 中位数为 0.749，边集合的 Jaccard 中位数为 0.718。也就是说，即使数据只有轻微重采

样，约 28% 的边会换掉、约 25% 的社区归属会改变。这个数字提醒我们：网络适合当“解释替代变量”的结构材料，不能当作“真实机制”的证据。

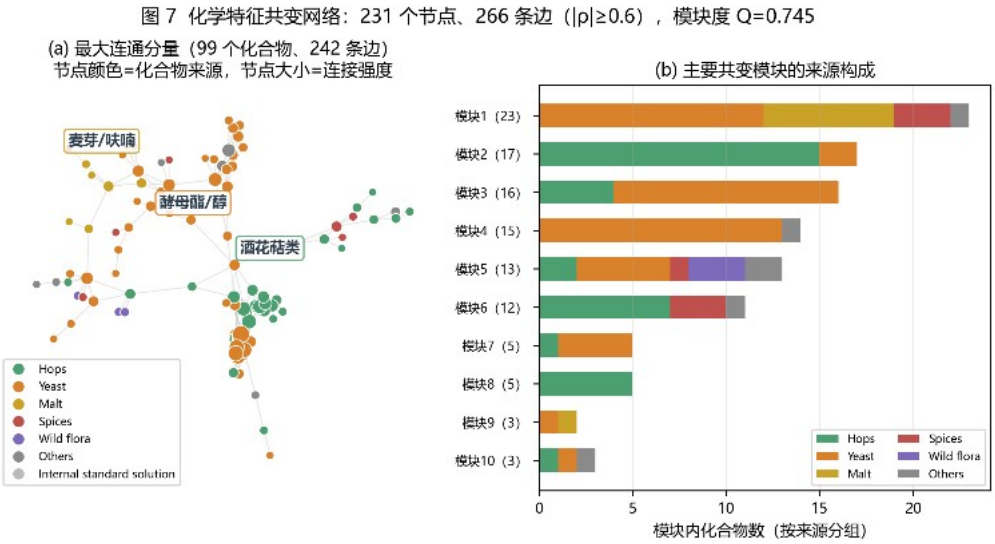


图 8 共变网络与模块。(a) 最大连通分量按来源着色：酒花萜类、酵母酯/醇、麦芽来源化合物各自聚成模块；(b) 主要模块的来源构成，大型模块以酒花萜类和酵母代谢物为主。

4.2 模块的化学解释

把每个模块内的化合物与 8.xlsx 的“来源”字段对照，可以读出相当清晰的化学结构。表 11 列出最大的 6 个非单点模块：模块 1（23 个变量）以酵母来源的醇类与麦芽来源的呋喃类为主，包括 3-甲基-2-己醇、邻甲酚、2-乙酰呋喃、4-甲基-1-戊醇等；模块 2（17 个变量）几乎全是酒花来源的倍半萜醇与环氧化物，如石竹烯醇、葎草烯环氧化物、α-桉叶醇；模块 3（16 个）是酵母酯类与酒花萜类的混合，包括辛酸异戊酯、2-丁基辛酸酯、Z-β-金合欢烯等；模块 4（15 个）是乙醇、总酯、己酸乙酯、热量值、甘油、异戊醇、乙酸异戊酯等“主发酵产物”；模块 5（13 个）混合了酵母与野生菌来源的挥发性酚（4-乙基愈创木酚、4-乙基苯酚）与香料来源物质；模块 6（12 个）是酒花香气核心——里哪醇、α-松油醇、香叶醇、β-水芹烯、α-松油醇等。

这些模块与酿酒化学的常识一致：酒花萜烯共同来自酒花添加，酵母酯/醇共同来自发酵，麦芽呋喃/吡嗪来自焙烤，野生菌来源的酚类共同来自 Brettanomyces 等微生物[6]。更重要的是，当我们换用 0.4 或 0.5 的阈值时，这些“来源纯度”高的模块仍然存在，只是被拆得更碎——这支持“模块结构有化学基础”的解读。同时必须诚实指出：绝对相关网络会把正相关与负相关混在一起，101 个孤立点也不等于“没有关联”，只是没有超过 0.6 的连边；模块划分本身随阈值变化，不能当成唯一真相。

表 11 最大的 6 个共变模块及其化学构成

模块（变量数）	主要来源构成	代表化合物	化学解读
模块 1（23）	酵母 12、麦芽 7、香料 3	3-甲基-2-己醇、邻甲酚、2-乙酰呋喃	发酵醇 + 焙烤呋喃
模块 2（17）	酒花 15、酵母 2	石竹烯醇、葎草烯环氧化物、α-桉叶醇	酒花倍半萜
模块 3（16）	酵母 12、酒花 4	辛酸异戊酯、2-丁基辛酸酯、Z-β-金合欢烯	酵母酯 + 酒花萜
模块 4（15）	酵母 13	乙醇、总酯、己酸乙酯、甘油	主发酵产物
模块 5（13）	酵母 5、野生菌 3、酒花 2	4-乙基愈创木酚、4-乙基苯酚、苯乙酸乙酯	挥发性酚/香料
模块 6（12）	酒花 7、香料 3	里哪醇、α-松油醇、香叶醇、β-水芹烯	酒花香气核心

4.3 三种关联视角与 Top-3 关键化合物

“哪个化合物对一个感官维度最重要”不是一道有唯一答案的题。一个化合物可能自己与目标相关，也可能通过与其他化合物的共变“代表”了同一组信号；目标还可能是非线性的（例如超过阈值后才产生影响）。本文用三种互补视角，各自给出 231 个变量的名次，再用平均名次（Borda 法）聚合。

视角一：秩相关。把每一列换成平均名次、标准化后，计算化合物 j 与目标 k 的 Spearman 相关，取绝对值作为分数：

$$S_{jk} = \left|\mathrm{corr}\left(\mathrm{rank}(X_j),\ \mathrm{rank}(Y_k)\right)\right| \qquad (4\text{-}3)$$

视角二：岭回归系数。把 231 个变量同时放入一个多输出岭回归（λ=100），取第 j 个变量对第 k 个目标的系数绝对值作为分数。它与单变量相关的区别是：它试图控制其余 230 个变量，因此更接近“偏关联”，但也更容易受共线性影响。

$$B = (Z_X^{\top} Z_X + 100\, I)^{-1} Z_X^{\top} Z_Y, \qquad \mathrm{score}_{jk} = |B_{jk}| \qquad (4\text{-}4)$$

视角三：分位箱 η^2。把每个化合物按名次分成 5 个等频箱，看不同箱里的目标平均名次是否不同；用 η^2 衡量“组间差异占总差异的比例”，并扣除分箱本身占用的自由度：

$$\eta^2_{\mathrm{adj}} = \max\left\{0,\ 1 - (1-\eta^2)\frac{n-1}{n-G}\right\}, \qquad \eta^2 = \frac{\sum_g n_g(\bar{z}_g - \bar{z})^2}{\sum_i (z_i - \bar{z})^2} \qquad (4\text{-}5)$$

这个视角能发现 U 形/阈值型关系（两端高、中间低），而相关系数只能发现单调关系。三种分数的量纲不同，不能直接相加，所以每个方法内部先排名（1=最强），再取平均名次：

$$R_{jk} = \frac{1}{3}\left[\mathrm{rank}_S(j,k) + \mathrm{rank}_B(j,k) + \mathrm{rank}_\eta(j,k)\right. \qquad (4\text{-}6)$$

每个目标取 R_jk 最小的 3 个变量作为 Top-3。表 12 给出部分代表性维度的结果；完整 50×3 表在附录 B。

表 12 部分代表性感官维度的 Top-3 关键化合物（括号内为 200 次 bootstrap 入选频率）

感官维度	第 1 名	第 2 名	第 3 名
酸度	pH（0.92）	Prenyl isobutyrate（0.38）	Perillyl acetate（0.33）
苦度	Iso-alpha acids（0.99）	Ethyl octanoate（0.83）	Ethyl decanoate（0.44）
酒精感	Ethanol（1.00）	Caloric value（0.99）	Acetaldehyde（0.28）
酒体	Ethanol（0.99）	Caloric value（0.99）	Ethyl hexanoate（0.25）
碳酸感	Carbon dioxide（1.00）	Ethyl octanoate（0.88）	3-methyl-2-hexanol（0.21）
4-乙烯基愈创木酚	4-VG（0.97）	Terpinyl acetate（0.66）	Prenyl isobutyrate（0.32）
酯风味·溶剂	Ethyl acetate（0.93）	Glycerol（0.44）	Methanethiol（0.38）
酒花香·草本	Ethyl decanoate（0.73）	Ethyl octanoate（0.75）	Iron（0.30）
陈酒花味	2-undecanol（0.53）	E-ortho-methoxy cinnamaldehyde（0.39）	Neryl propanoate（0.15）
双乙酰	Eugenol（0.87）	Ethyl decanoate（0.27）	Ethyl octanoate（0.24）
反-2-壬烯醛	β-phellandrene（0.18）	Terpinen-4-ol（0.24）	Iso-alpha acids（0.19）

4.4 稳定性分析

Top-3 名单的最大风险不是“排错一名”，而是“换一袋数据就换人”。我们对 250 个样品做 200 次有放回重采样，每次完整重算三种视角、Borda 排名与 Top-3，统计每个变量的入选频率。结果相当清醒：150 个名额的入选频率中位数只有 0.4125，最低 0.07，只有 20 个名额的频率不低于 0.8。也就是说，大约一半的“第三名”在重采样下会被别人替换。方法之间的分歧也很大：三对方法（秩相关—岭回归、秩相关—η^2、岭回归—η^2）的 Top-3 Jaccard 平均只有 0.266；把岭回归的 λ 从 100 改成 10 或 1000，Top-3 平均 Jaccard 分别为 0.488 与 0.608。这里需要强调：bootstrap 只能暴露不稳定性，并不能给出误发现率保证[21]。

为了区分“真的不稳定”和“只是第三名在抖”，我们还做了三件事。第一，统计“模块级”的入选频率：只要 Top-3 中有一个变量来自某模块就算命中，例如陈酒花味的 Top-3 落在 17 变量的酒花萜类模块里，该模块至少一名代表入选的频率为 0.745——这说明“这个方向有信号”，但“具体是哪三个名字”并不稳定。第二，检查类内相关：把每个变量在每个风格内去均值后再算相关，150 个名额中只有 1 个出现“整体相关与类内相关符号相反”，说明大部分关联不是单纯由风格均值差异造成的。第三，给出蒙特卡洛标准误：200 次 bootstrap 下频率的标准误最大约 0.035，因此 0.51 与 0.53 这样的差别不应被当成真实优劣。

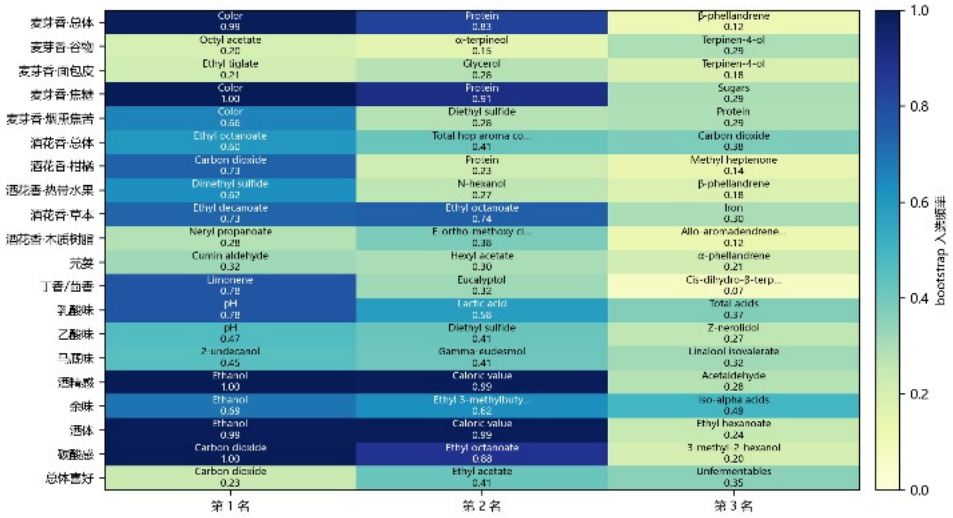


图 9 每个感官维度的 Top-3 关键化合物与稳定性。颜色/数字为 200 次 bootstrap 的入选频率：苦度—异 α-酸、酒精感—乙醇、碳酸感—CO_2、4-VG—4-乙烯基愈创木酚等深色席位非常稳定；浅色席位说明名单容易换人。

4.5 化学合理性与阈值证据

把 Top-3 与酿酒化学对照，可以看到不少“教科书式”的对应：酸度—pH、苦度—异 α-酸[22]、酒精感—乙醇、酒体—乙醇/热量、碳酸感—CO_2、4-VG—4-乙烯基愈创木酚、酯风味溶剂—乙酸乙酯，这些第一名几乎都是化学上的一对一对应物，与原始研究[1]用梯度提升模型得到的“酸度与酒精最容易预测”的结论一致。酒花萜类（里哪醇、香叶醇、β-水芹烯、石竹烯）出现在酒花香/草本/丁香等维度附近，也有充分的化学依据[3,5]。

但也要解释“为什么有些第一名看起来不化学”。例如麦芽香的前两名是色度与蛋白质，而不是麦芽风味化合物。原因是色度、蛋白质与麦芽风格高度共变：深色麦芽既带来颜色也带来焦糖/焙烤香，蛋白质影响酒体与泡沫；在只有 250 个样品、231 个高度相关变量的条件下，一个“代理变量”完全可能比真正的风味化合物排得更前。再如双乙酰的第一名是丁香酚（Eugenol），而双乙酰本身的测量列（2,3-丁二酮）没有进入前三：这是因为市售比利时啤酒大多在阈值以下，感官双乙酰与化学双乙酰的关系被阈值、检测限与风格差异掩盖，而丁香酚恰好与某些酵母/香料风格共变。这正是“关联不等于因果”的具体表现，也是我们在 4.4 节坚持报告稳定性的原因。

为了给“阈值型非线性”提供数据证据，我们做了一个探索性检验：对 8.xlsx 中给出阈值、且原生观测在阈值两侧各至少 10 个的 21 个化合物，对每个感官目标拟合“折线回归”——阈值左边一个斜率、阈值右边另一个斜率：

$$y = a + b\,(x/t) + c\max(x/t - 1,\ 0) + \varepsilon \qquad (4\text{-}7)$$

其中 t 是原生阈值，c 是阈值两侧的斜率变化。21 个变量×50 个目标共 1 050 个检验；用普通同方差 F 检验做 BH 校正后有 174 个显著，用异方差稳健的 HC3 检验后有 166 个显著[23,24]。例如 DMS 在 17.25 μg/L 阈值附近与苦度、酒精感、酒花香的关系出现显著折点，乙酸乙酯在 24 mg/L 附近与苦度/酒花香出现折点，己酸乙酯在 0.23 mg/L 附近与酒精感出现折点。这些结果只作为“结构证据”，不是因果证明：阈值本身来自参考表而非估计，1050 个检验也存在多重比较问题，且目标之间相关会削弱 BH 的独立性假设。

表 13 阈值折线检验中最显著的 6 组（HC3 稳健 p 值，已做 BH 校正）

化合物（阈值）	感官目标	阈值处斜率变化	HC3 p 值	BH q 值
DMS（17.25 μg/L）	苦度	−1.67	2.1×10^{-16}	2.2×10^{-13}
DMS（17.25 μg/L）	酒精感	−1.78	9.0×10^{-13}	4.7×10^{-10}
Ethyl acetate（24 mg/L）	苦度	−1.47	1.3×10^{-11}	4.5×10^{-9}
Ethyl acetate（24 mg/L）	酒花香·草本	−0.98	1.1×10^{-10}	2.8×10^{-8}
Ethyl hexanoate（0.23 mg/L）	酒精感	−1.40	5.6×10^{-10}	1.2×10^{-7}
Ethyl octanoate（0.70 mg/L）	酒精感	−1.45	2.2×10^{-8}	2.7×10^{-6}

4.6 小结

问题 2 交付的不只是 50 个 Top-3 名单，还包括“这份名单有多可信”的完整证据：网络在阈值下如何变化、模块的化学来源是否一致、bootstrap 下每个名字的入选频率、方法之间与正则化参数之间的 Jaccard、以及阈值型非线性的探索性检验。这些结果对问题 3 的直接作用是：Top-3 与模块帮助我们识别“哪些化合物是同一组信号的代表”，因此在生成与迁移时，不能只盯住单个化合物，而要考虑整组相关变量的联动。

五、问题 3：风味与“风味指纹”生成

5.1 问题分析

问题 3 有两个任务：一是“给定风格，生成像样的化合物谱，并给出感官画像”；二是“把 Pils/Lager 的化合物谱迁移成 Tripel 风格，同时保证缺陷化合物不恶化”。数据里有 22 个风格，但样本很不均衡：Tripel 28 个、Pils/Lager 11 个、Kriek 10 个、Lambic 11 个，最少的 Faro 只有 3 个。231 维特征对每个风格只有几个到二十几个样本，直接训练一个深的生成网络（例如 CVAE）很容易过拟合，而且不可解释。因此本文选择“先把数据结构弄清楚、再逐步加约束”的路线。

这一问需要同时满足三类要求，必须分开检查：（1）分布像不像：生成样本的统计特征应与目标风格的真实样本接近；（2）结构对不对：生成的 231 维必须满足 2.5 节复

原出的 5 条派生关系，不能 231 个坐标各自独立采样；（3）缺陷安不安全：迁移后 4 个缺陷化合物与陈酒花味不能比源样品更差。任何单一指标（哪怕很漂亮）都不能替代另外两类检查。

5.2 类别条件高斯 copula 基线

第一版生成器采用“秩-高斯 + 类别条件高斯 copula”。它的想法很像“先把每个变量换成它在自己这一列里的名次，再把名次映射到标准正态”，于是不同量纲的化合物可以放在同一个相关结构里；然后按风格估计均值与共享协方差，采样后再逆变换回原刻度。具体地：

（1）用经验分位数把每一列 x_j 变成标准正态分数 $z_j = \Phi^{-1}(\hat{F}_j(x_j))$，其中 $\hat{F}_j$ 是训练数据的经验分布函数[25]；（2）对每个风格 c，类均值向全局均值收缩，避免只有 3 个样本的风格“把均值拉飞”：

$$\tilde{\mu}_c = \frac{n_c}{n_c + 5}\mu_c + \frac{5}{n_c + 5}\mu_{\text{globa}} \qquad (5\text{-}1)$$

例如 Kriek 有 10 个样本，权重为 10/15≈0.67；Tripel 有 28 个，权重为 28/33≈0.85。5 是预先给定、容易解释的伪计数，不是从数据里“调”出来的最优值。（3）残差 $r = z - \tilde{\mu}_c$ 的 231×231 协方差用 Ledoit–Wolf 收缩估计[26]：

$$\hat{\Sigma} = (1 - \lambda)S + \lambda \bar{v} I \qquad (5\text{-}2)$$

其中 S 是样本协方差，$\bar{v}$ 是各坐标方差的平均，λ 由训练数据估计（本次收缩系数 0.1438）。231 维、每类只有几个样本时，分别估计每类协方差不可靠，因此各类共享同一个残差协方差，这是“用偏差换方差”的建模选择。（4）采样时先抽标准正态 ε，再计算 $z_{new} = \tilde{\mu}_c + L\varepsilon$（L 是 $\hat{\Sigma}$ 的 Cholesky 因子），最后用逆经验分布变换回原刻度。另外用概率主成分分析（PPCA）做低参数对照[27]：它只保留 5 或 10 个主方向，再给每个方向加噪声。

为客观比较，本文做 5 次按风格分层的 70%/30% 划分（175 训练/75 留出），每次重新拟合生成器，再用三种分布距离比较生成样本与留出样本：能量距离、高斯核 MMD^2、秩空间高斯负对数似然[28,29]。表 14 的结果说明“没有单一赢家”：按能量距离，条件模型（27.77）优于全局模型（29.89）与两个 PPCA（29.21/28.87）；但按秩空间 NLL，全局模型（397.02）反而优于条件模型（417.06）。原因是 NLL 奖励“把方差估小”，而条件均值本身有估计误差，小样本下条件模型的方差估计偏紧。我们把这种“指标之间打架”如实报告，而不是只挑一个指标宣布胜利；本文也没有实际训练更深的 CVAE[30,31]：每个风格只有 3–28 个样本，网络参数远多于样本量，容易过拟合且不可解释。

表 14 231 维基线生成模型的留出比较（5 次划分、22 类等权平均）

方法	能量距离（越低越好）	MMD²（越低越好）	秩空间 NLL（越低越好）
条件高斯 copula（类均值收缩）	27.770	0.3127	417.06
全局高斯 copula	29.893	0.3460	397.02
条件 PPCA（5 维）	29.212	0.3348	437.88
条件 PPCA（10 维）	28.871	0.3296	435.27

5.3 结构一致的生成：226 个基础量 + 5 个派生量

第一版生成器有一个致命问题：它把 231 个坐标一起生成，虽然统计上“像”，但不能保证 5 条派生关系成立。我们检查了第一版生成样本在 5 个派生量上的记录尺度偏差，中位数达到 0.07–0.36，最大达到 2.07——这在化学上是不可接受的，因为派生量本应由基础量唯一决定。于是第二版改为“只生成 226 个基础量，再按 2.5 节的公式重算 5 个派生量”。具体流程是：

- 基础量：226 列 = 231 列去掉 5 个派生列；其中 V001–V036 用 8.xlsx 的原生参照值（保留真实的 0、负值与缺失），其余列保持 1.csv 观测刻度；
- 生成：用类别条件的高斯 copula 生成 226 维基础量；
- 重算：按式 (2-3)–(2-7) 计算 5 个派生量，若任一派生聚合非正或非有限，则拒绝该候选并重采样（绝不取绝对值或截断成小数来“凑”等式）；
- 回写：按已验证的对数规则把 231 列映射回 1.csv 的记录刻度，再送入问题 1 的评分器得到 50 维感官画像。

第二个问题是“零原子”。很多化合物在部分风格里大量为 0（例如 4-VG 在 Tripel 中 23/28 为 0，二硫化碳在 Lambic 中约 82% 为 0）。如果先用总体经验分布、再让类均值去平移，条件分布的零概率会被压得过大：第一版生成中 Tripel 的 4-VG 100/100 全为 0，而真实是 23/28≈0.82；Kriek 的二硫化碳零率 0.92，真实 0.60。原因是“总体逆 CDF 把一大段概率压到同一个零原子”。修正办法是直接规定每个类、每个变量的经验分布，并让它向总体分布收缩：

$$\tilde{F}_{jc}(x) = \frac{n_{jc}}{n_{jc}+5}\hat{F}_{jc}(x) + \frac{5}{n_{jc}+5}\hat{F}_{j0}(x) \qquad (5\text{-}3)$$

其中 n_jc 是第 c 类第 j 列的有效观测数（缺失格不参与计数），F̂_jc 是类内经验分布，F̂_j0 是总体经验分布。这样零原子的概率就是“类内零值权重与总体零值权重按比例混合”，不会再被均值平移随意压成 1。采样时先在标准正态空间估计共享相关矩阵 R，再抽 Z~N(0,R)、U=Φ(Z)，最后用带权阶梯逆 CDF 逐列取训练值——这保证零与负值“不会被插值跨过”。

在这一结构下，300 个候选（Tripel/Kriek/Lambic 各 100）的零率与真实类内零率明显接近：Tripel 的 4-VG 从 1.00 修到 0.87（真实 0.82），Kriek 的二硫化碳从 0.92 修到 0.69（真实 0.60），Lambic 的二硫化碳从 0.98 修到 0.85（真实 0.82）。留出比较也更好：结构一致 + 类条件经验边际的生成器在能量距离上达到 22.47（条件高斯 27.25、全局 29.65），MMD^2 为 0.233（0.308/0.345），是所有方案里最好的。需要说明：由于分布含离散原子，它没有连续高斯似然，NLL 一栏不适用。

表 15 零/负值原子修复前后的类内零率对照（括号内为真实参考值）

风格	修复前的零率（生成）	修复后的零率（生成）	真实类内零率
Tripel：4-VG	1.00	0.87	0.82
Tripel：二硫化碳	0.99	0.92	0.89
Kriek：二硫化碳	0.92	0.69	0.60
Kriek：4-VG	0.99	0.94	1.00
Lambic：二硫化碳	0.98	0.85	0.82
Lambic：4-VG	0.94	0.79	0.91

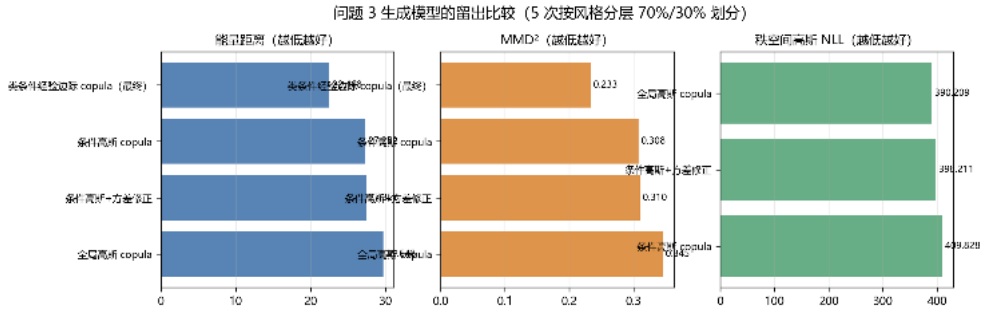


图 10 生成模型留出比较。类条件经验边际 copula 在能量距离与 MMD 上最好；含离散原子的分布无法直接计算连续高斯 NLL，故 NLL 栏留空。

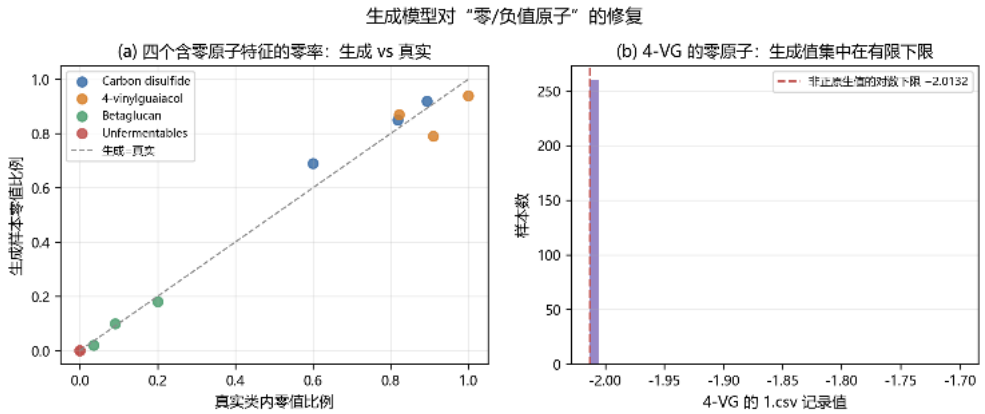


图 11 零原子修复。(a) 四个含零原子特征的零率：生成 vs 真实（对角线表示完全一致）；(b) 4-VG 的生成值集中在记录尺度下限 −2.0132，对应原生“非正值”。

从 300 个候选中，我们还按“5 个派生聚合都落在该类真实观测范围内”筛选了代表性样本：Tripel 100 个中 66 个通过、Kriek 20 个、Lambic 21 个，每类取 3 个共 9 个代

表。代表样本的作用是展示“在该类历史数据范围内”的合理配方，不是声称它们是真实的新啤酒；筛选后的分布已不同于未筛生成器，因此留出指标只对未筛生成器成立。

5.4 生成样本的感官画像

把生成化合物谱送入问题 1 的评分器，就得到 50 维感官画像。表 16 对比三个风格“生成均值”与“真实风格均值”：Tripel 呈现高酒精、高酯香、低酸、低苦的画像；Kriek 与 Lambic 呈现高酸、高乳酸/乙酸、低苦、低酒精的画像。数值上，生成画像与真实风格均值在 50 个维度上的相关系数分别为 Tripel 0.88、Kriek 0.96、Lambic 0.97，平均绝对差分别为 0.06、0.19、0.12 个 D04 单位。生成值整体比真实值“保守”（幅度偏小），这与小样本生成模型向均值收缩的预期一致。

表 16 生成风格均值与真实风格均值的感官画像对比（D04 单位）

样本	酒精感	酒体	总体	酯香	苦度	酸度	乳酸	4-VG	双乙酰	陈酒花
生成 Tripel	0.34	0.15	0.16	0.21	0.15	-0.20	-0.19	0.17	-0.02	-0.10
真实 Tripel	0.41	0.19	0.11	0.11	0.23	-0.34	-0.28	0.24	0.04	-0.05
生成 Kriek	-0.52	-0.27	-0.02	0.37	-0.66	1.36	1.12	-0.43	-0.07	-0.09
真实 Kriek	-0.67	-0.49	-0.18	0.76	-1.03	1.86	1.33	-0.48	-0.23	-0.19
生成 Lambic	-0.36	-0.18	-0.06	-0.01	-0.40	1.17	0.93	-0.23	-0.06	0.09
真实 Lambic	-0.60	-0.23	0.15	-0.11	-0.61	1.79	1.48	-0.42	0.07	0.17

为了进一步检验“生成的谱是否真的像某一风格”，我们额外训练了三个二分类逻辑回归（Tripel vs 其余、Kriek vs 其余、Lambic vs 其余），用 5 折交叉验证评估：AUC 分别为 0.851、0.998、0.981，说明这三个风格在化学上是可以被区分的。把生成样本送入这三个分类器，Tripel/Kriek/Lambic 各自被判为对应风格的平均概率为 0.735/0.726/0.718，而被判为其他风格的概率大多低于 0.10。这个“风格保真度”检验独立于分布距离，从判别角度支持生成样本确实落在目标风格附近。

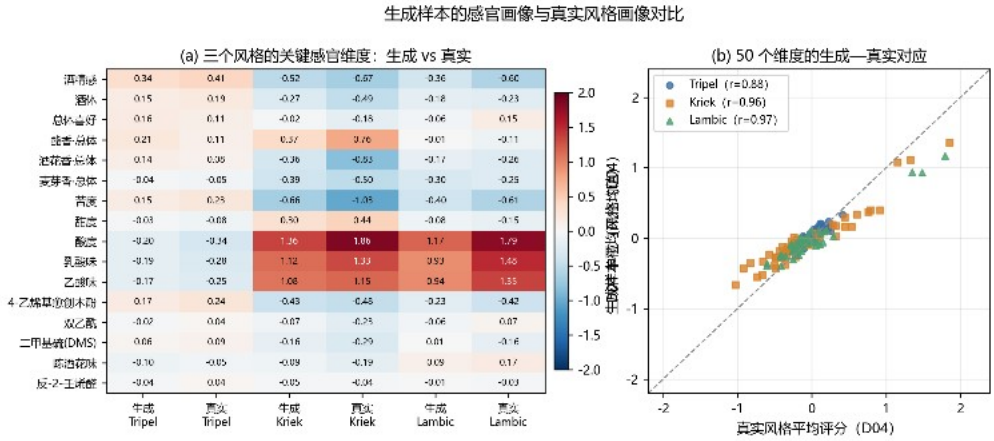


图 12 生成样本的感官画像。(a) 16 个关键维度的风格均值：Tripel 高酒精、高酯香、低酸；Kriek/Lambic 高酸、高乳酸/乙酸、低苦；生成值与真实值同向但幅度更保守。(b) 50 维散点，三个风格的生成—真实相关系数分别为 0.88、0.96、0.97。

5.5 跨风格迁移：Pils/Lager → Tripel

跨风格迁移可以理解为“在保持源样品骨架的前提下，把它朝目标风格的方向推”。第一步给出一个“提议方向”：把 Pils/Lager 的类均值平移到 Tripel 的类均值：

$$x^{\text{prop}} = x^{\text{src}} + (\mu_{\text{Tripel}} - \mu_{\text{Pils/Lager}}) \qquad (5\text{-}4)$$

但直接平移很可能让缺陷化合物升高。于是第二步求一个离提议不远、同时满足约束的点：4 个缺陷化合物的原生值不超过源对象，5 个派生聚合为正，且评分器预测的陈酒花味 Y38 不高于源对象。用加权平方距离衡量“改动大小”：

$$\min_x \frac{1}{2}\sum_j \left[\frac{x_j - x_j^{\text{prop}}}{s_j}\right]^2 \quad \text{s.t.} \quad x_j^C \le x_j^{C,\text{src}}, \quad \hat{y}_{38}(x) \le \hat{y}_{38}(x^{\text{src}}), \quad \text{agg}(x) > 0 \qquad (5\text{-}5)$$

其中 s_j 是该列 90% 分位与 10% 分位之差，用来把不同量纲的坐标放在同一把尺子上。求解用 SLSQP（序列二次规划），并且优化器报告“成功”不算数——必须把保存后的 CSV 重新读入、重新计算 5 个派生量与评分，逐项核对约束。

在核对中我们发现一个很重要的问题：如果把“迁移前”的基线只设成“模型对源样品的预测”，有 5 个对象的迁移后预测虽然低于模型预测，却高于源样品在 4.csv 里的真实观测值（例如 object 124：真实观测 Y38≈−0.355，模型预测 0.025，迁移后 −0.070，看上去降了，其实比真实观测高 0.28）。这说明“自己跟自己比”会掩盖问题。我们把上界加强为三重最小：

$$\text{cap}_i = \min\left\{\hat{y}_{38}(x_i^{\text{orig}}),\ \hat{y}_{38}(x_i^{\text{re}}),\ z_i^{\text{obs}}\right\} \qquad (5\text{-}6)$$

优化时把上界再收紧 10^{-6}（只为吸收 CSV 序列化误差），最终判定用保存后重读的值、且不允许正容差。此外还有两个技术细节：（1）对 226 维中的 44 个“临界坐标 +

派生父变量 + 基础参数”做固定，剩下 182 个自由坐标；在这 182 维上评分器是分段线性的，因此可以解析地写出一个带盒约束的二次规划解：

$$x(m) = \mathrm{clip}(p - m s^2 \circ \beta,\ \mathrm{low},\ \mathrm{high}), \qquad \beta^\top x(m) \le \mathrm{rhs} \tag{5-7}$$

其中 m≥0 是乘子，β 是评分器在该子空间上的斜率；β'x(m) 关于 m 单调不增，因此只需二分一个标量 m 就能找到既满足评分约束、又离提议最近的解。这个子问题有全局最优证明（固定 182 维、线性约束、严格凸目标），但它不等于完整 226 维迁移的全局最优。（2）评分器在缩尾箱外是“平的”，同一个裁剪输入可以对应多个原值；我们在不改变任何 50 维预测的前提下，把箱外坐标拉回箱边，改善与原值的接近程度，并明确标注“等输入修复点不是原 QP 解”。

最终结果（11 个 Pils/Lager 源对象）：44 个缺陷约束全部通过（11 对象×4 化合物），11 个 Y38 连续预测全部下降（最大上升为 0），在协议 A/B 下 11/11 等级不升高；到 Tripel 类中心的距离 11/11 缩短；没有对象退回源点。object 124 的 QP 解乘子 m=15.61，加权目标 2.43，182 个自由坐标中有 27 个贴到边界，实际评分与仿射近似的最大偏差 2.8×10^{-16}。表 17 汇总四项缺陷的“阈值倍数”，表 18 给出每个对象的 Y38 与协议等级变化。

表 17 四项缺陷化合物在迁移前后的阈值倍数（11 个源对象）

缺陷化合物（阈值）	阈值倍数均值	阈值倍数最大值	超阈值对象数	逐对象判定
DMS（17.25 μg/L）	0.914	1.586	3	迁移后≤迁移前
双乙酰（0.29925 mg/L）	0.392	1.751	1	迁移后≤迁移前
4-VG（0.206333 mg/L）	0.072	0.697	0	迁移后=迁移前
反-2-壬烯醛（0.35）	0.011	0.034	0	迁移后≤迁移前

表 18 跨风格迁移的感官安全对照（观测源守卫分支）

源对象	迁移前 Y38 预测	迁移后 Y38 预测	连续变化	协议 A 等级	协议 B 等级
124	0.025	-0.355	-0.380	3→2	4→1
81	0.209	0.119	-0.090	4→3	5→5
218	0.117	0.033	-0.084	3→3	5→4
96	-0.109	-0.146	-0.037	3→3	4→4
230	0.020	-0.103	-0.123	3→3	4→4
185	-0.002	-0.252	-0.250	3→3	4→3
139	0.168	-0.262	-0.431	3→3	5→2
209	-0.101	-0.180	-0.079	3→3	4→3
119	0.062	0.051	-0.011	3→3	5→5
90	0.038	-0.215	-0.253	3→3	5→3
28	0.147	0.042	-0.105	3→3	5→5

从“像不像 Tripel”的角度再看一次：独立分类器给出 11 个源对象被判为 Tripel 的平均概率从 2.4% 升到 39.1%，其中 10 个对象上升；唯一的例外是 object 28

（0.121→0.109），它的源样品本身已经比较接近 Tripel，约束把改动拉回了原地。这与“到 Tripel 类中心距离全部缩短”的结论一致，但两者都不是“真实风格保真度”的证明——迁移后的啤酒没有被真正酿造和品评。

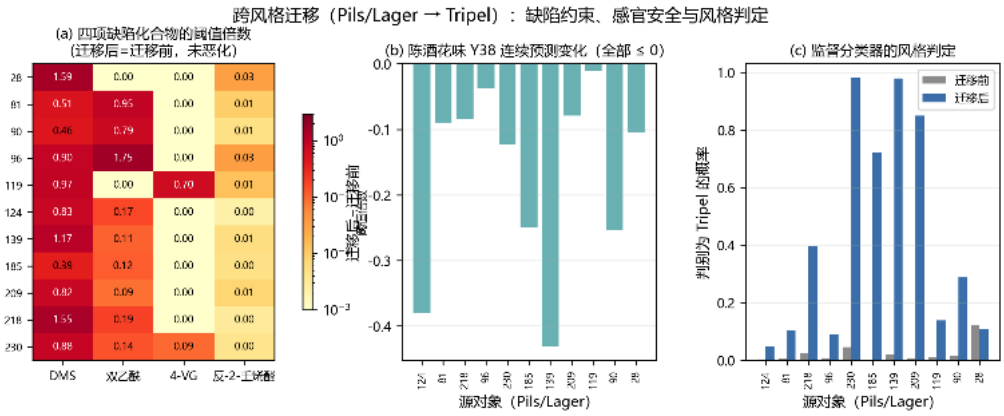


图 13 跨风格迁移。(a) 四项缺陷化合物的原生值相对阈值倍数：迁移后保持源对象的数值（红=超过阈值）；(b) 陈酒花味 Y38 连续预测逐对象下降；(c) 独立监督分类器判为 Tripel 的概率由平均 2.4% 升至 39.1%，10/11 个对象上升。

5.6 “缺陷不恶化”到底能保证什么

上面的结果是“在模型预测这个代理上不恶化”。它离“真实 K 不恶化”还有多远？可以用一个精确的数学结论划出边界。设源样品的某个缺陷量为 S，目标风格的真实分布为 R，迁移后的分布为 Q。要求“每个源对象都不升高”意味着 Q 在随机序意义下不优于 S，即对任意阈值 t，迁移后超过 t 的概率不超过源：

$$F_Q(t) \geq F_S(t) \qquad \text{for all } t \qquad (5\text{-}8)$$

而一维 Wasserstein-1 距离是两个累积分布函数之间的面积：$W_1(Q,R) = \int |F_Q - F_R|\, dt$。由于 $F_Q \geq F_S$，在 $F_S > F_R$ 的地方必然有 $|F_Q - F_R| \geq F_S - F_R$，于是得到一条与生成模型无关的下界[32]：

$$W_1(Q,R) \geq \int [F_S(t) - F_R(t)]_+ \, dt \qquad (5\text{-}9)$$

也就是说，只要源风格与目标风格的尾部比例不同，“逐对象不恶化”就必然与“完整匹配目标分布”冲突，差距由这条面积下界给出。对本题的 4 个缺陷化合物，按原生阈值归一化后的下界分别为：DMS 1.78、双乙酰 1.47、4-VG 0.024、反-2-壬烯醛 1.17；最大正尾差分别为 0.714、0.445、0.088、0.549。这解释了为什么“完美迁移成 Tripel 分布”与“每个源对象缺陷都不升高”不能同时做到——这不是模型不够好，而是两个要求本身在数学上互相排斥。

还有两个必须写清楚的边界。第一，真实 K（陈酒花味的原始 0–6 等级）不可识别：协议 A/B 本身对同一批预测给出不同的 K 分布，迁移后的真实等级更没有被观测。

第二，“均值不升高”不等于“尾部风险不降低”：例如迁移前 K 恒为 1（均值 1、达到 2 的概率 0），迁移后以 0.7 概率为 0、0.3 概率为 3（均值 0.9、达到 2 的概率 0.3），均值下降了，但临界风险反而上升。因此本文只承诺“同一固定协议下连续预测与工作等级不升高”，并把真实 K 的安全标记为“不可识别”，不把它包装成“已验证安全”。

5.7 小结

问题 3 的交付物包括：三个风格各 100 条结构一致的化合物谱、对应 50 维感官画像、9 个范围兼容的代表样本、11 个 Pils/Lager→Tripel 迁移配方及其逐项安全对照、以及一条关于“安全与目标分布不可兼得”的严格下界。方法上最重要的经验是：先修代数结构（5 条派生关系），再修边际分布（零原子），最后才谈距离与约束；顺序反过来，就会像第一版模型那样“看起来很像、内部却不自洽”。

六、模型评价与推广

6.1 模型优点

（1）数据核验扎实、验证方式保守。所有“题面陷阱”（对齐键、对数底数、零点地板、相关类型、文件尺寸、空模板）都逐项核验并用可复核的数字报告；问题 1 使用嵌套交叉验证，把“选模型”放进评估框架，同时报告随机、整风格留组与重复编号留组三种协议，以及共形区间与联合覆盖。

（2）结论强度与证据匹配。对 Top-3 名单，给出 bootstrap 入选频率、方法间 Jaccard、模块级频率与阈值敏感性；对 0–6 等级，明确“不可识别”并用双协议对照；对迁移安全，区分“模型预测不恶化”与“真实 K 不恶化”。

（3）生成模型结构自洽、全流程可复现。先生成 226 个基础量、再按复原公式计算派生量，使 231 维向量内部一致；零/负值原子用类条件收缩经验分布显式建模；随机种子、参数网格、算法细节与结果文件一一对应，论文数字可追溯到具体结果表。

6.2 局限性与改进方向

（1）模型容量。问题 1 的主模型是线性的 PLS/岭回归；在 250 个样本、231 个高度相关特征下这是稳健的选择，但可能漏掉非线性与交互。如果样本量增大，可以尝试带稀疏约束的树模型或多任务网络，并用同样的嵌套验证公平比较。

（2）标签识别性。4.csv 是逐品评员 z 化后的连续值，原始 0–6 等级不可唯一还原。本文用公开协议给出工作等级，但这不能替代真实的评分卡数据。若能在数据收集阶段记录每位品评员的原始整数打分，就能真正校准序数模型，并评估等级准确率[17]。

（3）关联不等于因果。问题 2 的 Top-3 是关联排序，不是化学贡献度；共变网络也不能区分“原因”与“伴随现象”。要论证因果，需要设计加标实验（在真实啤酒中按预测添加化合物再品评），原始研究[1]正是这样验证的。

（4）生成与迁移的样本量。每个风格只有 3–28 个样本，生成模型学到的是“类内分布的一个收缩估计”，不能保证覆盖真实酿造中所有可能的配方；迁移后的“安全”也只在模型预测与固定协议下成立。若能把生成配方真正酿造并做感官评价，才能形成闭环验证。

（5）缺失与异常。虽然额外缺失实验显示模型退化是渐进的，但本文只用中位数/KNN 填补，没有对缺失机制建模，也没有做多重插补的不确定性传播；如果缺失比例显著上升，需要重新评估。

6.3 应用推广

本文的框架可以直接用于啤酒厂的质量控制与风味设计：给定一批原料与发酵条件测得的化学谱，先用问题 1 的模型预测感官画像，再用问题 2 的 Top-3 与模块找到“要动哪一组化合物”，最后用问题 3 的结构一致生成与约束迁移给出候选配方，并检查缺陷指标。同样的“多通道测量 + 人工评分 + 约束生成”框架也可以迁移到其他发酵食品（葡萄酒、清酒、酱油）或一般工业配方问题：核心步骤都是“先核验刻度与缺失 → 再做可解释的关联/预测 → 最后用结构约束与安全边界生成候选”。

七、结论与建议

本文围绕 250 款比利时商品啤酒的 231 项化学测量与 50 个感官维度，完成了数据核验、感官评分、关联解释、条件生成与跨风格迁移五项工作。主要结论如下：

（1）数据核验：1.csv 的 37 个参数列是 log10 记录值，非正原生值被“最小正值一半”替代；2.csv/5.csv/6.csv 均为 Spearman 相关矩阵；231 个特征中只有 73 个缺失，但删行会损失 25.2% 样本；5 个派生量可由基础量精确重建（残差约 10^{-10}），其本质是热量换算与四类气味活度加和。

（2）感官评分：PLS（10 主成分）在嵌套交叉验证下 50 维平均 R^2=0.217、MAE=0.354（均值基线 0.417）；整风格留组时 R^2=0.157；90% 共形区间的边际覆盖率为 90.1%，但 50 维联合覆盖仅 84%。按协议 A 给出 250×50 的 0–6 工作等级并填制 3.xlsx；协议 A/B 的逐格一致率只有 23.4%，说明绝对等级依赖分级口径，原始 0–6 等级不可唯一还原。

（3）关联解释：$|\rho|\geq 0.6$ 的共变网络有 266 条边、19 个非单点模块、模块度 0.745；模块的化学来源与酿酒常识一致（酒花萜类、酵母酯/醇、麦芽呋喃）。Top-3 中酸度

—pH、苦度—异 α-酸、酒精感—乙醇、碳酸感—CO_2、4-VG—4-乙烯基愈创木酚等对应关系化学上成立；但 200 次 bootstrap 下入选频率中位数仅 0.41、方法间平均 Jaccard 仅 0.27，说明“具体名单”高度不稳定，必须与稳定性一起使用。

（4）生成：结构一致（226 基础 + 5 派生）的类条件经验边际 copula 在留出比较中能量距离 22.47、MMD^2 0.233，优于全局模型与高斯条件模型；三个风格各生成 100 条化合物谱与 50 维感官画像，画像与真实风格均值的相关系数为 0.88/0.96/0.97；独立分类器对生成样本的风格判定概率约 0.72–0.74。

（5）迁移：11 个 Pils/Lager→Tripel 迁移样本的四项缺陷与陈酒花味 Y38 全部逐对象不升高，监督分类器判为 Tripel 的平均概率由 2.4% 升至 39.1%；但一维 Wasserstein 下界（DMS 1.78、双乙酰 1.47、4-VG 0.024、反-2-壬烯醛 1.17）说明“逐对象不恶化”与“完整匹配目标分布”不可兼得，真实 K 的绝对等级仍不可识别。

基于以上结论，给出三条建议。第一，数据层面：如果希望得到“真实 0–6 等级”，应在品评环节保留每名品评员的原始整数打分与个人校准记录，而不是只保留 z 化后的均值；对痕量缺陷化合物（DMS、双乙酰、4-VG、反-2-壬烯醛）应报告检测限与缺失机制，因为它们的阈值效应最容易被缺失与对数地板扭曲。

第二，建模层面：在 250 个样品、231 个高度相关特征的规模下，线性多输出模型已经能拿到大部分可解释信号；报告结果时应同时给出折外指标、不确定性区间与不同验证协议下的表现，避免用一个平均 R^2 掩盖 50 个维度之间的巨大差异。

第三，应用层面：生成/迁移模型可以用于“给出候选配方并筛选缺陷风险”，但不能替代真实酿造与品评；在工业落地时，应把本文的“模型内安全约束”与“真实阈值检测”串联起来，形成“生成候选—实验室验证—反馈更新”的闭环。

参考文献

[1] Schreurs M, Piampongsant S, Roncoroni M, et al. Predicting and improving complex beer flavor through machine learning. Nature Communications, 15: 2368, 2024.

[2] Meilgaard M C. Flavor chemistry of beer. Part II: Flavor and threshold of 239 aroma volatiles. Master Brewers Association of the Americas Technical Quarterly, 12(3): 107–117, 1975.

[3] Verstrepen K J, Van Laere S D M, Vanderhaegen B M P, et al. Flavor-active esters: adding fruitiness to beer. Journal of Bioscience and Bioengineering, 96(2): 110–118, 2003.

[4] Dzialo M C, Park R, Steensels J, et al. Physiology, ecology and industrial applications of aroma formation in yeast. FEMS Microbiology Reviews, 41(Supp_1): S95–S128, 2017.

[5] Takoi K, Itoga Y, Koie K, et al. The contribution of geraniol metabolism to the citrus flavour of beer: synergy of geraniol and β-citronellol under coexistence with excess linalool. Journal of the Institute of Brewing, 116(3): 251–260, 2010.

[6] Bossaert S, Crauwels S, De Rouck G, et al. The power of sour — a review: old traditions, new opportunities. BrewingScience, 72: 78–88, 2019.

[7] Lusk L T, Kay S B, Porubcan A, et al. Key olfactory cues for beer oxidation. Journal of the American Society of Brewing Chemists, 70(4): 257–261, 2012.

[8] Rubin D B. Inference and missing data. Biometrika, 63(3): 581–592, 1976.

[9] Box G E P, Cox D R. An analysis of transformations. Journal of the Royal Statistical Society: Series B, 26(2): 211–252, 1964.

[10] Spearman C. The proof and measurement of association between two things. American Journal of Psychology, 15(1): 72–101, 1904.

[11] Hoerl A E, Kennard R W. Ridge regression: biased estimation for nonorthogonal problems. Technometrics, 12(1): 55–67, 1970.

[12] Wold S, Martens H, Wold H. The multivariate calibration problem in chemistry solved by the PLS method. In: Matrix Pencils, Lecture Notes in Mathematics 973. Berlin: Springer, 286–293, 1983.

[13] Cawley G C, Talbot N L C. On over-fitting in model selection and subsequent selection bias in performance evaluation. Journal of Machine Learning Research, 11: 2079–2107, 2010.

[14] Lei J, G'Sell M, Rinaldo A, et al. Distribution-free predictive inference for regression. Journal of the American Statistical Association, 113(523): 1094–1111, 2018.

[15] Angelopoulos A N, Bates S. Conformal prediction: a gentle introduction. Foundations and Trends in Machine Learning, 16(4): 494–591, 2023.

[16] NumPy Developers. numpy.quantile and numpy.searchsorted documentation. https://numpy.org/doc/stable/reference/generated/numpy.quantile.html, 访问时间 2026-10-26.

[17] Rennie J D M, Srebro N. Loss functions for preference levels: regression with discrete ordered labels. In: Proceedings of the IJCAI Multidisciplinary Workshop on Advances in Preference Handling, 180–186, 2005.

[18] Manski C F. Partial Identification of Probability Distributions. New York: Springer, 2003.

[19] Blondel V D, Guillaume J-L, Lambiotte R, et al. Fast unfolding of communities in large networks. Journal of Statistical Mechanics: Theory and Experiment, 2008(10): P10008, 2008.

[20] Fortunato S, Barthélemy M. Resolution limit in community detection. Proceedings of the National Academy of Sciences, 104(1): 36–41, 2007.

[21] Meinshausen N, Bühlmann P. Stability selection. Journal of the Royal Statistical Society: Series B, 72(4): 417–473, 2010.

[22] Oladokun O, Tarrega A, Mendez-Sevillano S, et al. The impact of hop bitter acid and polyphenol profiles on the perceived bitterness of beer. Food Chemistry, 205: 212–220, 2016.

[23] Benjamini Y, Hochberg Y. Controlling the false discovery rate: a practical and powerful approach to multiple testing. Journal of the Royal Statistical Society: Series B, 57(1): 289–300, 1995.

[24] MacKinnon J G. Thirty years of heteroskedasticity-robust inference. In: Recent Advances and Future Directions in Causality, Prediction, and Specification Analysis. New York: Springer, 437–461, 2012.

[25] Liu H, Lafferty J, Wasserman L. The nonparanormal: semiparametric estimation of high dimensional undirected graphs. Journal of Machine Learning Research, 10: 2295–2328, 2009.

[26] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices. Journal of Multivariate Analysis, 88(2): 365–411, 2004.

[27] Tipping M E, Bishop C M. Probabilistic principal component analysis. Journal of the Royal Statistical Society: Series B, 61(3): 611–622, 1999.

[28] Székely G J, Rizzo M L. Energy statistics: a class of statistics based on distances. Journal of Statistical Planning and Inference, 143(8): 1249–1272, 2013.

[29] Gretton A, Borgwardt K M, Rasch M J, et al. A kernel two-sample test. Journal of Machine Learning Research, 13: 723–773, 2012.

[30] Kingma D P, Welling M. Auto-encoding variational Bayes. In: International Conference on Learning Representations (ICLR), 2014.

[31] Sohn K, Lee H, Yan X. Learning structured output representation using deep conditional generative models. In: Advances in Neural Information Processing Systems 28, 3483–3491, 2015.

[32] Vallender S S. Calculation of the Wasserstein distance between probability distributions on the line. Theory of Probability and Its Applications, 18(4): 784–786, 1974.

[33] DeepSeek. DeepSeek-V3.2, 深度求索（DeepSeek）, 使用日期 2026-10-26.

AI 工具使用声明

本参赛队在竞赛过程中使用了 DeepSeek（DeepSeek-V3.2，深度求索）[33] 作为辅助工具，使用日期为 2026-10-26。具体使用情况如下：

（1）部分论文段落的文字组织与润色：在参赛队给出建模思路、结果数值与结论要点后，DeepSeek 协助把其中一部分段落整理为更通顺的书面表达；文中所有数值、公式与结论均由参赛队从实际计算结果中核对与修改后确定。

（2）代码调试与文档整理：辅助检查绘图脚本与论文排版脚本的语法问题，协助整理支撑材料的文件说明与目录结构。

核心的建模思路、算法设计、参数选择、数据处理、结果分析与结论由参赛队独立完成。参赛队对所有 AI 工具参与生成的内容逐项核验与修改，并对其正确性负责。更详细的使用目的、交互记录、采纳内容与人工修改情况，见支撑材料中的《AI 工具使用详情说明.pdf》。

附录 A 核心代码（节选）

完整的可复现代码见支撑材料 code/ 目录（本论文所有数字均由这些脚本生成）。以下仅摘录关键步骤的 Python 实现，便于读者核对算理。

A.1 训练折内的预处理（中位数填补 → 1%/99% 缩尾 → 标准化）

```
class RobustPreprocessor(BaseEstimator, TransformerMixin):
    def fit(self, X, y=None):
        X = np.asarray(X, dtype=float)
        self.median_ = np.nan_to_num(np.nanmedian(X, axis=0), nan=0.0)
        filled = np.where(np.isnan(X), self.median_, X)
        self.low_, self.high_ = np.quantile(filled, [0.01, 0.99], axis=0)
        clipped = np.clip(filled, self.low_, self.high_)
        self.mean_ = clipped.mean(axis=0)
        self.scale_ = clipped.std(axis=0, ddof=0)
```

```
        self.scale_[self.scale_ <= 1e-12] = 1.0
        return self
    def transform(self, X):
        X = np.asarray(X, dtype=float)
        filled = np.where(np.isnan(X), self.median_, X)
        clipped = np.clip(filled, self.low_, self.high_)
        return (clipped - self.mean_) / self.scale_
```

A.2 两层交叉验证选模（外层 5 折、内层 3 折）

```
CANDIDATES = ([("ridge", a) for a in (0.1, 1, 10, 100, 1000)] +
              [("pls", k) for k in (2, 5, 10, 20)])


def make_model(family, param):
    reg = Ridge(alpha=param) if family == "ridge" else PLSRegression(n_components=int(param))
    return TransformedTargetRegressor(
        regressor=Pipeline([("prep", RobustPreprocessor()), ("reg", reg)]),
        transformer=StandardScaler())


def inner_select(X_tr, Y_tr, seed):
    best = None
    kf = KFold(3, shuffle=True, random_state=seed)
    for family, param in CANDIDATES:
        errs = []
        for tr, va in kf.split(X_tr):
            m = make_model(family, param).fit(X_tr[tr], Y_tr[tr])
            pred = m.predict(X_tr[va])
            sd = Y_tr[tr].std(axis=0, ddof=0) + 1e-12
            errs.append(np.mean(((Y_tr[va] - pred) / sd) ** 2))
        score = np.mean(errs)
        if best is None or score < best[0]:
            best = (score, family, param)
    return best[1], best[2]
```

A.3 0–6 工作等级：协议 A 与协议 B

```
def protocol_A(scores, mu, sd, slope=1.0):
    raw = 3.0 + slope * (scores - mu) / sd
    return np.clip(np.floor(raw + 0.5), 0, 6).astype(int)


def protocol_B(scores, Y_train):
    cuts = np.quantile(Y_train, np.arange(1, 7) / 7, axis=0, method="linear")
    return np.column_stack([
        np.searchsorted(cuts[:, j], scores[:, j], side="right")
        for j in range(scores.shape[1])])
```

A.4 共表达网络、模块度与 Borda 聚合

```
rho = pd.read_csv("2.csv", index_col=0).values          # 已核验为 Spearman
A = np.where(np.abs(rho) >= 0.6, np.abs(rho), 0.0)
np.fill_diagonal(A, 0.0)
G = nx.from_numpy_array(A)
comms = nx.community.louvain_communities(G, weight="weight", seed=20261026)
Q = nx.community.modularity(G, comms, weight="weight")


def borda_top3(scores_by_method, n_features=231):
    ranks = [rankdata(-s, axis=0, method="average") for s in scores_by_method]
    mean_rank = np.mean(ranks, axis=0)                # 231 x 50
    order = np.argsort(mean_rank, axis=0, kind="stable")
    return order[:3, :].T                             # 每个目标 3 个变量
```

A.5 结构一致的类条件生成（226 基础量 ＋5 派生量）

```
# 1) 生成 226 个基础量（类条件收缩经验边际 + 共享相关矩阵的 copula）
Z = rng.standard_normal((n, 226)) @ factor.T          # factor 来自共享相关阵 R
U = norm.cdf(Z)
X_base = np.column_stack([inverse_weighted_cdf(j, g, U[:, j])
                          for j in range(226)])
# 2) 由基础量按复原公式计算 5 个派生聚合（原生尺度）
agg = candidate_derived_from_native(X_base)
if not np.all(np.isfinite(agg)) or np.any(agg <= 0):
```

```
    continue                                          # 拒绝并重采样，不截断
# 3) 按已核验的对数规则映射回 1.csv 记录刻度，再交给评分器
X_record = native_to_recorded(X_base, agg, floors)
```

A.6 观测源守卫下的受约束迁移（182 维精确二次规划）

```
# 固定 44 个坐标（C 坐标 + 派生父变量 + 基础参数），其余 182 个为自由坐标
def qp_free_coords(p, beta, s, low, high, rhs):
    x = lambda m: np.clip(p - m * s**2 * beta, low, high)
    if beta @ x(0.0) <= rhs:                          # 无需压缩评分
        return x(0.0), 0.0
    right = 1.0
    while beta @ x(right) > rhs and right < 1e60:     # 倍增找括号
        right *= 2.0
    lo, hi = 0.0, right
    for _ in range(75):                               # 二分乘子
        mid = 0.5 * (lo + hi)
        if beta @ x(mid) <= rhs: hi = mid
        else: lo = mid
    return x(hi), hi

# 迁移后必须用保存并重读的 CSV 重新计算 5 个派生量与 50 维评分，
# 判定 after <= cap（cap = min{原值预测, 重表达预测, 观测值}），不允许正容差。
```

附录 B 50 个感官维度的 Top-3 关键化合物（完整表）

括号内为 200 次 bootstrap 下该化合物进入 Top-3 的入选频率。频率低不代表不重要，而是说明“换一袋样品后这个席位容易被替换”。

表 B-1 50 个感官维度的 Top-3 关键化合物

目标	感官维度	第 1 名（频率）	第 2 名（频率）	第 3 名（频率）
Y01	麦芽香·总体	Color（0.99）	Protein（0.83）	β-phellandrene（0.12）
Y02	麦芽香·谷物	Octyl acetate（0.20）	α-terpineol（0.15）	Terpinen-4-ol（0.29）
Y03	麦芽香·面包皮	Ethyl tiglate（0.21）	Glycerol（0.28）	Terpinen-4-ol（0.18）
Y04	麦芽香·焦糖	Color（1.00）	Protein（0.91）	Sugars（0.29）
Y05	麦芽香·烟熏焦苦	Color（0.66）	Diethyl sulfide（0.28）	Protein（0.29）
Y06	酒花香·总体	Ethyl octanoate（0.60）	Total hop aroma compounds（0.41）	Carbon dioxide（0.38）
Y07	酒花香·柑橘	Carbon dioxide（0.73）	Protein（0.23）	Methyl heptenone（0.14）
Y08	酒花香·热带水果	Dimethyl sulfide（0.62）	N-hexanol（0.27）	β-phellandrene（0.18）
Y09	酒花香·草本	Ethyl decanoate（0.73）	Ethyl octanoate（0.74）	Iron（0.30）
Y10	酒花香·木质树脂	Neryl propanoate（0.28）	E-ortho-methoxy cinnamaldehyde（0.38）	Allo-aromadendrene epoxide（0.12）
Y11	酯香·总体	Acetaldehyde（0.74）	N-hexanol（0.62）	Protein（0.55）
Y12	酯香·溶剂	Acetaldehyde（0.46）	1-propanol（0.22）	Ethyl acetate（0.34）
Y13	酯香·香蕉	N-hexanol（0.75）	Tau-cadinol（0.32）	Isoamyl acetate（0.37）
Y14	酯香·花香	β-phellandrene（0.29）	Isobutyl acetate（0.17）	E-dihydro-apofarnesal（0.15）
Y15	酯香·甜果	β-phellandrene（0.48）	Neryl formate（0.37）	Lactic acid（0.20）
Y16	麦芽风味·总体	Acetaldehyde（0.76）	Color（0.78）	pH（0.54）
Y17	麦芽风味·谷物	E-β-ionone（0.35）	Terpinen-4-ol acetate（0.20）	Vanillin（0.13）
Y18	麦芽风味·面包皮	Glycerol（0.61）	Acetaldehyde（0.36）	2-acetylpyrrole（0.28）
Y19	麦芽风味·焦糖	Color（0.97）	Protein（0.60）	Acetaldehyde（0.60）
Y20	麦芽风味·烟熏焦苦	Ethanol（0.42）	Color（0.40）	Iso-alpha acids（0.43）
Y21	酒花风味·总体	Iso-alpha acids（0.85）	Dimethyl sulfide（0.39）	Iron（0.42）
Y22	酒花风味·柑橘	Ethyl furoate（0.24）	Protein（0.32）	Furfural（0.26）

目标	感官维度	第 1 名（频率）	第 2 名（频率）	第 3 名（频率）
Y23	酒花风味·热带水果	Dimethyl sulfide（0.46）	Hexyl acetate（0.58）	Geraniol（0.32）
Y24	酒花风味·草本	Iso-alpha acids（0.71）	Iron（0.75）	Ethyl octanoate（0.47）
Y25	酒花风味·木质树脂	Ethyl tetradecanoate（0.43）	Isobutanol（0.48）	Ethyl hexadecanoate（0.14）
Y26	酯风味·总体	Protein（0.88）	Acetaldehyde（0.67）	Caloric value（0.47）
Y27	酯风味·溶剂	Ethyl acetate（0.93）	Methanethiol（0.38）	Glycerol（0.43）
Y28	酯风味·香蕉	Protein（0.56）	N-hexanol（0.47）	Acetaldehyde（0.27）
Y29	酯风味·花香	β-phellandrene（0.54）	Isopentyl butanoate（0.35）	E-dihydro-apofarnesal（0.18）
Y30	酯风味·甜果	Diethyl sulfide（0.69）	Protein（0.44）	β-phellandrene（0.27）
Y31	酸度	pH（0.92）	Prenyl isobutyrate（0.38）	Perillyl acetate（0.33）
Y32	苦度	Iso-alpha acids（0.99）	Ethyl octanoate（0.83）	Ethyl decanoate（0.44）
Y33	甜度	Ethyl decanoate（0.74）	Sugars（0.74）	Protein（0.60）
Y34	4-乙烯基愈创木酚	4-vinylguaiacol（0.96）	Terpiryl acetate（0.66）	Prenyl isobutyrate（0.32）
Y35	双乙酰	Eugenol（0.87）	Ethyl decanoate（0.27）	Ethyl octanoate（0.23）
Y36	二甲基硫(DMS)	Unfermentables（0.44）	E-nerolidol（0.32）	Protein（0.35）
Y37	金属味	Iron（0.63）	Ethyl 3-methylbutyrate（0.20）	α-calacorene（0.41）
Y38	陈酒花味	2-undecanol（0.53）	E-ortho-methoxy cinnamaldehyde（0.39）	Neryl propanoate（0.14）
Y39	反-2-壬烯醛	β-phellandrene（0.18）	Terpinen-4-ol（0.23）	Iso-alpha acids（0.19）
Y40	橙味	Camphor（0.87）	Ethanol（0.28）	Caloric value（0.20）
Y41	芫荽	Cumin aldehyde（0.32）	Hexyl acetate（0.30）	α-phellandrene（0.21）
Y42	丁香/茴香	Limonene（0.78）	Eucalyptol（0.32）	Cis-dihydro-β-terpineol（0.07）
Y43	乳酸味	pH（0.78）	Lactic acid（0.58）	Total acids（0.37）
Y44	乙酸味	pH（0.47）	Diethyl sulfide（0.41）	Z-nerolidol（0.27）
Y45	马厩味	2-undecanol（0.45）	Gamma-eudesmol（0.41）	Linalool isovalerate（0.32）
Y46	酒精感	Ethanol（1.00）	Caloric value（0.99）	Acetaldehyde（0.28）
Y47	余味	Ethanol（0.69）	Ethyl 3-methylbutyrate（0.62）	Iso-alpha acids（0.49）
Y48	酒体	Ethanol（0.99）	Caloric value（0.99）	Ethyl hexanoate（0.24）
Y49	碳酸感	Carbon dioxide（1.00）	Ethyl octanoate（0.88）	3-methyl-2-hexanol（0.20）
Y50	总体喜好	Carbon dioxide（0.23）	Ethyl acetate（0.41）	Unfermentables（0.35）

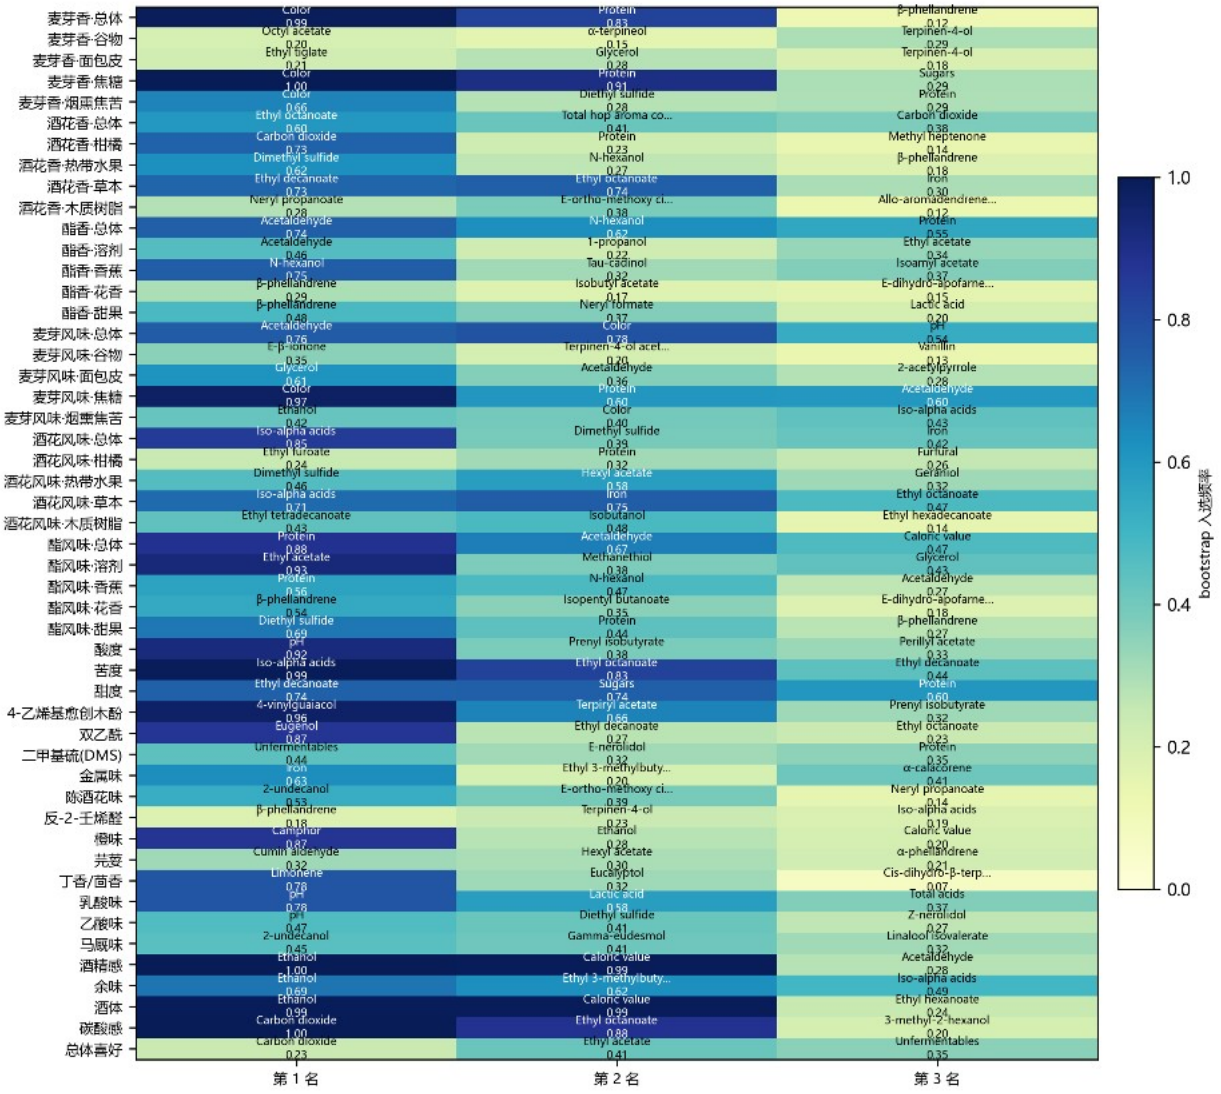


图 B-1 50 个感官维度的 Top-3 关键化合物与 200 次 bootstrap 入选频率（完整版；正文图 9 为代表性维度缩略版）。

附录 C 支撑材料清单

支撑材料目录 A 赛道_复原解答/ 的组织如下：

表 C-1 支撑材料清单

路径	内容
paper/A 赛道论文_啤酒风味复原版.pdf	本论文提交版 PDF
paper/AI 工具使用详情说明.pdf	竞赛规定的 AI 工具使用详情说明
results/Q1_评分表_官方 3xlsx 格式.xlsx	问题 1 最终答案：按官方 3.xlsx 格式填写的 12 张评分卡与 summary
results/Q1_连续评分预测_*.csv	问题 1 的 250×50 连续预测（全拟合与折外）
results/Q1_0-6 分级_协议 A/协议 B_*.csv	问题 1 的 0–6 工作等级矩阵（两种协议、全拟合与折外）
results/Q2_Top3 关键化合物_汇总.csv	问题 2 的 50×3 Top-3 关键化合物及稳定性指标
results/Q2_网络节点与模块.csv、Q2_共变模块构成.csv	共变网络节点、边与模块的化学构成
results/Q3_生成化合物谱_*.csv	Tripel/Kriek/Lambic 各 100 条结构一致的化合物谱
results/Q3_生成感官画像_D04 尺度.csv	300 条生成样本的 50 维感官画像

路径	内容
results/Q3_跨风格迁移_*.csv、Q3_迁移_*.csv	11 个 Pils/Lager→Tripel 迁移配方与缺陷/感官安全对照
code/	复原、补充分析、绘图、评分卡、公式与论文排版脚本
code/full_pipeline_project/	脱敏版完整计算工程（12 个脚本 + 8 个数据文件；运行 run_all.py 复现问题 1–3）
code/_impl_spec.md	完整计算工程的逐脚本实现规格说明（参数、种子、公式、限制）
README.md	结果文件与代码的逐项说明

说明：原始附件 1–8 未做任何修改；所有处理结果、图、表均由 code/ 下脚本重新生成。若需复核，可按 README.md 的顺序运行脚本；随机种子为 20261026，在不同 BLAS/线程配置下末位数字可能有微小差异。