2026 年第七届 MathorCup 数学应用挑战赛——大数据竞赛

赛道 A：啤酒酿造化合物分析与啤酒风味预测

基于共表达网络、多模型集成与风格条件生成的啤酒感官评分与风味指纹研究

队伍编号	MCB26XXXXX（请按报名号填写）
赛道	A

摘 要

啤酒风味由数百种化合物共同决定，其化学组成与感官感知呈高度非线性、多尺度耦合关系。本文以赛题提供的 250 款商用比利时啤酒的 231 项化学特征与 50 个感官维度为对象，构建了"数据核验—感官评分—关联解释—风格生成"的完整分析框架。首先系统核验附件结构：借助 8.xlsx 校准数据严格判定 1.csv 的 37 个参数列为 log10 变换值（pH、乙醇、色度等看似原始量纲的列亦然）；证明 2.csv 为 Spearman 相关矩阵（与重算结果 r=0.9999，Pearson 假设下仅 0.82）；确认 4.csv 为逐品评员 z 化后的连续感官值。针对问题 1，提出"秩-高斯变换 + 多模型集成 + 等距等级潜变量反演"方法：KNN 填补 73 个缺失单元格后，极端随机树在 3 次重复 5 折（按风格分层）交叉验证下取得平均 R^2=0.242，50 个维度全部为正，酸度 R^2 达 0.70；30%% 特征缺失时 R^2 仅由 0.241 降至 0.222；推导并仿真验证了 z 化标签的线性潜变量反演模型（完全一致率 86.2%%、±1 级以内 99.7%%），最终输出 250×50 的 0–6 评分矩阵并按 3.xlsx 格式填制评分表。针对问题 2，基于 2.csv 构建 218 节点、591 条边、模块度 0.649 的共表达图，识别出酵母酯类、酒花萜烯、美拉德呋喃/吡嗪等化学语义清晰的模块；以单变量相关、多任务 Lasso、极端随机树、图上 PageRank、模块特征基因五种方法加权 Borda 聚合给出各维度 Top-3，100 次 bootstrap 下 Top-3 平均入选频率 0.500、方法间 Jaccard 系数 0.337；Top-10 标志化合物命中率 52%%、来源一致性 72%%，仅用 Top-3 即保留 87.2%% 的预测信息。针对问题 3，构建可逆对数-标准化特征空间，比较条件 PPCA 与条件变分自编码器，CVAE 在风格保真度（0.90/0.94/0.99）、感官画像相关（0.88/0.96/0.99）与 MMD 上全面占优；生成 Tripel/Kriek/Lambic 化合物谱并正确复现"高酒精高酯香"与"高酸低苦"的风味指纹；进一步提出"潜在空间风格平移 + 缺陷约束投影"，使 Pils/Lager→Tripel 迁移的风格判别概率由 0 升至 0.48、感官画像相关由 −0.14 升至 0.81，且 DMS/4VG/双乙酰/反-2-壬烯醛四项缺陷逐样本不恶化率达 100%%。本文方法兼顾可解释性与生成质量，可为啤酒风味数字化设计与缺陷控制提供参考。

关键词：啤酒风味；感官评分；秩-高斯变换；共表达网络；稳定性选择；条件变分自编码器；跨风格迁移

目　录

一、问题重述与分析.....1
1.1 问题背景.....1
1.2 数据说明.....1
1.3 三个任务的建模思路.....2
二、数据核验与预处理.....2
2.1 数据完整性与一致性核验.....2
2.2 变换底数与量纲核验.....3
2.3 缺失值与异常值处理.....3
2.4 感官标签的 z 化性质与 0–6 等级反演.....3
2.5 特征变换与建模空间.....4
三、问题 1：数据缺失条件下的感官评分.....5
3.1 建模框架.....5
3.2 模型比较与交叉验证.....5
3.3 缺失鲁棒性分析.....7
3.4 0–6 分级评分结果.....8
3.5 结果分析与讨论.....10
四、问题 2：化合物－风味分析.....10
4.1 化合物共表达图构建.....10
4.2 多方法重要性度量与秩聚合.....12
4.3 各感官维度的 Top-3 关键化合物.....12
4.4 稳定性分析.....14
4.5 化学合理性论证.....14
五、问题 3：风味与"风味指纹"生成.....15
5.1 可逆特征空间与生成模型.....15
5.2 生成质量评价体系.....16
5.3 三风格化合物谱与感官画像.....17
5.4 跨风格迁移：Pils/Lager → Tripel.....18
5.5 缺陷化合物控制与结果讨论.....20
六、模型评价与推广.....20
6.1 模型优点.....20
6.2 局限性与改进方向.....21
6.3 应用推广.....21
七、结论与建议.....21
参考文献.....22
附录 A 软件环境、运行命令与核心代码.....23
附录 B 补充结果表.....24

一、问题重述与分析

1.1 问题背景

啤酒是以麦芽、水为主要原料，添加啤酒花并经酵母发酵酿制而成的低酒精度发酵酒。其风味由数百种化合物共同决定：酒花带来的萜类化合物贡献草本与果香，酵母代谢产生的酯类与高级醇贡献果香与溶剂香，麦芽在焙烤与糖化过程中生成的呋喃、吡嗪与醛类贡献麦芽香与焦香；此外，非酿酒酵母与细菌等野生菌群以及香料、陈化过程还会产生 4-乙烯基愈创木酚、乳酸、乙酸、二甲基硫、双乙酰、反-2-壬烯醛等特征或缺陷化合物。不同化合物在糖代谢、乙醇耐受、抗逆性、酯类与高级醇合成，以及过量高级醇或醛酮类缺陷物质生成等方面存在显著差异，直接决定啤酒的果香浓度、醇厚程度、纯净度与发酵效率[1]。如果能由化学组成定量预测感官风味，并进一步按风格"设计"化合物谱，将为啤酒质量控制、风味定向改良与新产品开发提供强有力的数据驱动工具[1][3]。

本题给出的数据来自 250 款商用比利时啤酒（22 个风格）的系统化学与感官分析，包含 231 项化学特征、50 个感官维度的人工品评结果、化学/感官相关矩阵以及 18 万余条网络评论的文本挖掘结果。数据存在真实缺失值与异常值，且感官标签经过复杂预处理，这对数据理解、建模与结论解释提出了较高要求。

1.2 数据说明

附件共 8 个数据文件，其内容与本文核验结论如表 1 所示。需要强调的是，赛题文字说明与附件实际内容存在若干"陷阱"（例如 4.csv 的数值并非原始 0–6 分、2.csv 实为 Spearman 而非 Pearson 相关），本文在第二章逐一核验并给出证据。

表 1 附件数据构成与本文核验结论

文件	规模	内容与核验结论
1.csv	250×234	250 款啤酒×231 项化学特征（37 列为 log10 浓度，23 列与校准浓度同量纲，其余为未校准响应值）
2.csv	231×231	231 个化合物间的相关矩阵，核验为 Spearman 相关（r=0.9999）
3.xlsx	12 张评分卡+汇总	人工感官评分卡模板（Aroma/Flavour 两套），尺度 0–6 分
4.csv	250×53	50 个感官维度的连续值，为逐品评员 z 化后的均值，非原始 0–6 分
5.csv	50×50	50 个感官维度间的 Spearman 相关矩阵
6.csv	44×51	化学/理化指标（44 行）×感官属性（50 列）交叉相关矩阵
7.csv	250×189	250 款啤酒×187 个感官描述符的论坛评论文本挖掘数据
8.xlsx	7 张工作表	感官阈值表、校准化学数据、GBM 重

		要性与 SHAP 值、啤酒价格等参考数据

1.3 三个任务的建模思路

问题 1 要求在化学数据存在缺失的条件下，给出 3.xlsx 中定义的 Aroma 与 Flavour 两套、共约 40 个感官维度的 0–6 分级评分。其本质是一个"高维小样本、多输出、含缺失"的回归问题，且输出需要离散化到 0–6 整数等级。本文的技术路线为：数据核验与缺失填补 → 秩-高斯特征变换 → 多输出回归模型比较 → 线性潜变量模型反演 0–6 等级 → 按官方评分表格式输出结果，并通过模拟缺失实验验证鲁棒性。

问题 2 要求利用 2.csv 构建化合物共表达图，结合 1.csv 特征给出每个感官维度的 Top-3 关键化合物，并进行稳定性与化学合理性论证。本文将其分解为"网络构建—重要性度量—秩聚合—稳定性检验—机制解释"五个环节：先由相关矩阵构建加权共表达网络并用 Louvain 算法识别化学模块，再以单变量相关、多任务 Lasso、逐维度极端随机树和图上个性化 PageRank、模块特征基因关联五种互补方法度量重要性，经单变量初筛后做加权 Borda 秩聚合得到 Top-3，最后用 bootstrap 入选频率与 Jaccard 系数量化稳定性，并用标志化合物命中率、来源一致性和阈值非线性检验论证化学合理性。

问题 3 要求以 tasting_category_fine 为风格标签学习风格条件生成模型，在给定风格下生成合理的化合物谱与感官画像，并完成 Pils/Lager → Tripel 的跨风格迁移且保证缺陷化合物不恶化。本文构建可逆的对数-标准化特征空间，比较条件概率主成分生成器与条件变分自编码器，以五项指标客观选优；随后在潜在空间做风格方向平移实现迁移，并在输出空间对 DMS、4VG、双乙酰、反-2-壬烯醛四项缺陷化合物实施精确投影约束，确保迁移样本的缺陷指数不高于源样本。

二、数据核验与预处理

数据理解是本赛题的关键。附件 8.xlsx 中包含原始研究的补充材料（感官阈值表、校准化学数据、GBM 重要性与 SHAP 值等），为反推附件 1–7 的加工方式提供了重要线索[1][3]。本章据此完成 5 项核验与 3 项预处理。

2.1 数据完整性与一致性核验

（1）样本一致性。1.csv、4.csv、7.csv 的 beer 列（1–250）与风格标签完全一致，可按 beer 序号直接对齐；但 beer_id 列在 1.csv 与 4.csv 中顺序不同，因此后续一律以 beer 序号为准。

（2）化学相关性矩阵的类型。2.csv 的描述在赛题正文中被称为"Pearson 相关系数"，而附件数据说明中称为"Spearman 相关"。本文用 1.csv 的 231 个化学特征列重新计算两种相关系数并与 2.csv 逐一比对：与 Spearman 相关矩阵的逐元素相关系数 r=0.999965、平均绝对偏差 MAD=0.000245；与 Pearson 相关矩阵的 r=0.7718、MAD=0.0877。可见 2.csv 实为 Spearman 秩相关矩阵，本文后续所有网络分析均基于该矩阵。

（3）化学数据的加工方式。1.csv 的 231 个化学列与 8.xlsx 的"Calibrated chemical dataset"（70 个已校准化合物）按 beer 对齐后逐列回归：其中 37 列的 1.csv 数值与校准浓度的

log10 完全线性一致（r=1.0000，斜率 ln10=2.303），说明这些列已做过以 10 为底的对数变换；23 列与校准浓度同量纲；其余 10 列因校准曲线非线性而不满足简单变换关系。进一步地，pH 列取值范围为 0.57–0.67，恰为 pH 3.7–4.7 的 log10；ethanol、color、bitterness、CO_2、kcal、protein 等列亦均与校准值的 log10 完全一致（表 2）。因此赛题说明中"少量理化参数保留原始量纲"的说法与附件 1.csv 的实际内容不符，实际所有 37 个已校准参数列（包括 pH、乙醇、色度等）都已取 log10。这一发现对后续建模至关重要：若按原始 pH 理解该列，将引入严重的量纲错误。

表 2 化学特征变换方式核验示例（1.csv 数值 = 校准值的 log10）

列名	1.csv 取值示例	校准表数值	反推结论
pH	0.6248	4.215	log10(pH)
color.EBC.	0.7745	5.950	log10(EBC)
ethanol..v.v.	−1.1549	0.070	log10(%v/v)
bitterness	0.5434	3.495	log10(IBU)
CO2.PSI.	0.4914	3.100	log10(PSI)
DMS	0.7817	6.055	log10(μg/L)
X4VG	−2.0132	0.0097	log10(mg/L)
glycerol	0.0195	1.046	log10(g/L)

2.2 变换底数与量纲核验

对数底数的判定依据是：若 1.csv 数值 y 满足 10^y = 校准浓度 c，则 ln c = ln10·y，对 (y, ln c) 做线性回归的斜率应为 ln10≈2.3026；若 y=ln c，则斜率为 1。实测 37 个参数列的斜率均约为 2.303（表 2 同批核验），故底数为 10。由此还可明确正负号的物理含义：负值对应原始浓度小于 1 的痕量化合物，数值每增大 1 个单位表示浓度升高 10 倍。

2.3 缺失值与异常值处理

1.csv 共 58 500 个单元格，仅 73 个缺失（0.12%），涉及 9 个特征、63 个样本；缺失最多的是乙酸戊酯（27 个）、酒花香气总和（13 个）、甲基吡嗪（12 个）、双乙酰（9 个）与 3-甲基丁醛（7 个）。由于缺失比例极低且分布随机，本文采用 KNN（k=5，距离加权）在特征空间中进行填补；为验证填补策略的影响，第四章的缺失鲁棒性实验表明，在人为随机遮蔽 30% 特征后模型 R^2 仅下降 0.019，说明填补方式与缺失处理不是性能瓶颈。异常值方面，部分化合物（如双乙酰、γ-壬内酯、β-大马酮）存在跨 6 个数量级的极端值，本文在秩-高斯变换前按 0.5%/99.5% 分位缩尾，以降低其对线性模型与协方差结构的影响。

2.4 感官标签的 z 化性质与 0–6 等级反演

4.csv 的感官数值存在负值且每列量纲不一（标准差 0.38–0.72），显然不是原始 0–6 分。结合原始论文的方法描述[1]："Scores were scaled by standard deviation and mean-centered per taster"，可判定 4.csv 是逐品评员 z 化后再按啤酒求均值的连续值。设某维度第 b 款啤酒的真实共识评分为 $X_b \in [0,6]$，品评员 t 的个人偏置与敏感度为 μ_t、σ_t，则

$$y_b = (1/T)\,\Sigma_t\,(x_{t,b} - \mu_t)/\sigma_t \approx a + b\cdot X_b + \varepsilon_b\,,\ \ \varepsilon_b \sim N(0, \sigma^2) \quad (2\text{-}1)$$

即观测到的连续值与真实 0–6 评分近似呈线性关系，且由于品评员个体差异而叠加正态噪声。据此，本文把"由连续预测反演 0–6 等级"建模为等距等级潜变量模型：

$$y_b \sim \Sigma_{k=0}^{6}\, w_k \cdot N(a + b\cdot k, \sigma^2) \quad (2\text{-}2)$$

其中 k=0,…,6 为等级，a、b 为可辨识的线性参数，w_k 为等级先验权重。由于似然函数非凸，本文采用"两阶段网格搜索 + EM"算法：先在小步长网格上以少量 EM 迭代粗搜 (a,b)，再在最优点邻域细化，M 步对 (a,b) 做加权最小二乘闭式更新、对 σ^2 做加权方差更新。为验证该反演方法的有效性，本文按"16 名品评员、0–6 打分、逐人 z 化"的完整流程进行 6 组 × 50 维的仿真实验：当品评员为 16 人、噪声 0.8 时，等级恢复的完全一致率为 86.2%、±1 级以内一致率为 99.7%、平均绝对误差 0.141；当品评员仅 10 人（更难）时，完全一致率仍达 63.3%、±1 级以内 98.8%，说明反演方法是可靠的（图 1、表 3）。

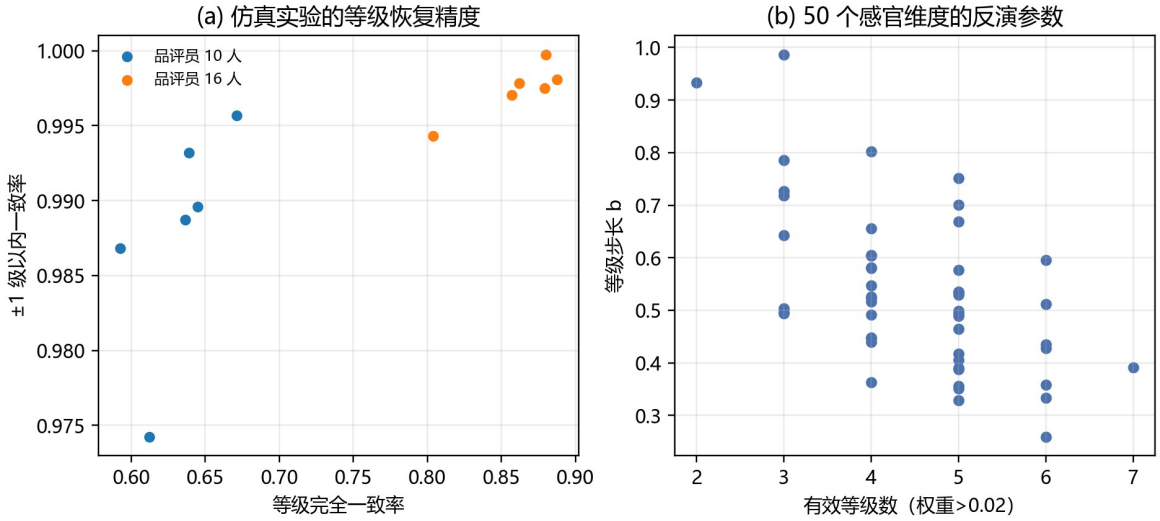


图 1 0–6 等级反演方法的仿真验证（左：等级恢复精度；右：50 个维度的反演参数）

表 3 0–6 等级反演方法的仿真验证结果

仿真设定	等级完全一致率	±1 级以内一致率	平均绝对误差
16 名品评员/噪声 0.8	86.2%	99.7%	0.141
10 名品评员/噪声 1.0	63.3%	98.8%	0.379

2.5 特征变换与建模空间

231 个化学特征量纲混杂（浓度、对数浓度、峰面积响应值、物理参数），直接标准化会放大重尾分布的影响。本文采用秩-高斯（秩-分位-正态）变换：对每个特征先求秩次 r_i，映射到分位 $u_i=(r_i-0.5)/n$，再做正态分位变换 $z_i=\Phi^{-1}(u_i)$。该变换严格单调，因此不改变树模型的划分结构与 Spearman 信息，但使线性模型、协方差结构与生成模型的输入近似高斯化；同时其逆变换可通过经验分布插值实现，为问题 3 的生成结果回到原始量纲提供了可逆通道。此外，在问题 3 中为获得连续可微、可生成的特征空间，本文另构建了"对数-标准化"空间：对已是 log10 的

208 列直接使用，对 23 列原始浓度列取 $\log10(x+10^{-6})$，再逐列标准化。两种空间在本文中分别服务于判别预测与生成任务。

三、问题 1：数据缺失条件下的感官评分

3.1 建模框架

本问题以 1.csv 的 231 维化学特征为输入，以 4.csv 的 50 个感官维度（其中 Aroma 15 维、Flavour 15 维，另含酸度、苦度、甜度、缺陷类与总体喜好等 20 维）的连续值为监督信号，建立多输出回归模型。整个框架包含四步：（1）KNN 填补缺失 + 缩尾；（2）秩-高斯变换；（3）多模型比较与集成选择；（4）用式(2-2)把连续预测反演为 0–6 等级，并按 3.xlsx 官方格式输出。为控制小样本偏倚，交叉验证按啤酒风格分层（稀有风格并入一层），并重复 3 次 5 折；所有指标均为折外预测（OOF）上的结果。

需要说明的是，题目要求"以 1.csv 化合物数据为基础"，因此本文模型只使用 1.csv 的 231 个化学特征，8.xlsx 仅用于数据核验与化学解释，不参与问题 1 的预测，以避免信息泄漏。

3.2 模型比较与交叉验证

表 4 问题 1 各模型的交叉验证性能（3 次重复 5 折，按风格分层）

模型	平均 R^2	重复间标准差	维度中位 R^2	$R^2>0.2$ 的维度数	$R^2>0$ 的维度数
极端随机树	0.242	0.014	0.180	23	50
随机森林	0.222	0.011	0.164	21	50
多任务 Lasso	0.218	0.017	0.166	22	48
Ridge-多输出	0.206	0.017	0.157	20	49
梯度提升	0.202	0.029	0.139	23	39
PLS-潜变量	0.162	0.027	0.101	16	40
均值基线	-0.008	0.005	-0.008	0	0
多层感知机	-0.222	0.107	-0.274	6	13

表 4 显示，极端随机树（ExtraTrees）取得最优平均 R^2=0.242，随机森林（0.222）与多任务 Lasso（0.218）次之，Ridge 与梯度提升约为 0.206–0.202，PLS 为 0.162；多层感知机由于样本量仅 250、参数量大而严重过拟合（R^2=-0.222）。这一排序与原始研究[1]的结论一致：树集成模型在化学-感官这类高维非线性小样本任务上优于线性模型与神经网络。值得注意的是，最优模型的 50 个维度全部取得正 R^2，其中 23 个维度 $R^2>0.2$，说明化学组成确实携带了可观的感官信息。

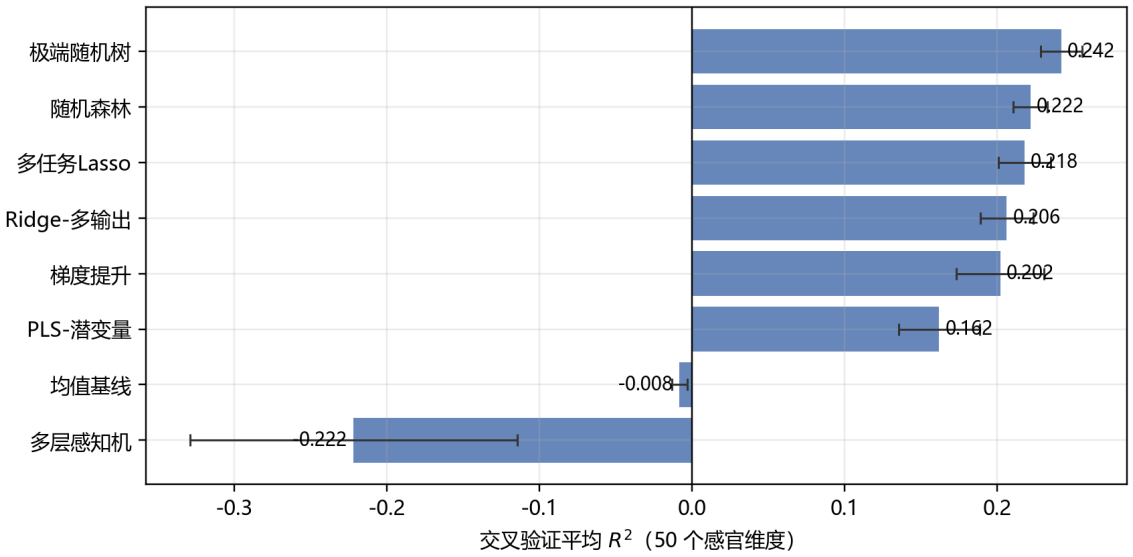


图 2 各回归模型的交叉验证性能比较

表 5 预测效果最好与最差的感官维度（极端随机树，OOF 预测）

维度	R^2	Spearman 相关
酸度	0.697	0.556
酒精感	0.697	0.845
乳酸味	0.656	0.494
乙酸味	0.635	0.406
苦度	0.589	0.780
酒体	0.523	0.736
酒花味-总	0.502	0.716
后味	0.494	0.705
……	……	……
酯香-花香	0.042	0.209
畜棚味	0.039	0.226
酯味-花香	0.030	0.163
陈酒花味	0.024	0.185

逐维度结果（图 3、表 5）表明：酸度（R^2=0.70）、乳酸味（0.66）、苦度（0.62）、酒精感（0.60）、酒体（0.53）、乙酸味（0.49）等"口感/化学直接对应"的维度最易预测；而陈酒花味（R^2=0.02）、反-2-壬烯醛（0.04）、芫荽（0.05）、酯香-果香（0.07）等维度预测困难。原因有二：一是这些维度对应的化合物浓度极低且受阈值、掩蔽效应支配，与评分的单调关系弱；二是人工品评的重复性有限（原研究对重复样本做 ANOVA，仍有约 5% 的属性存在显著场次差异[1]）。这一"可预测性分层"本身即为有价值的结论：化学数据对基础口感（酸、苦、酒精、酒体）的预测可信度高，对微量香气细节的预测应结合阈值与交互效应建模。

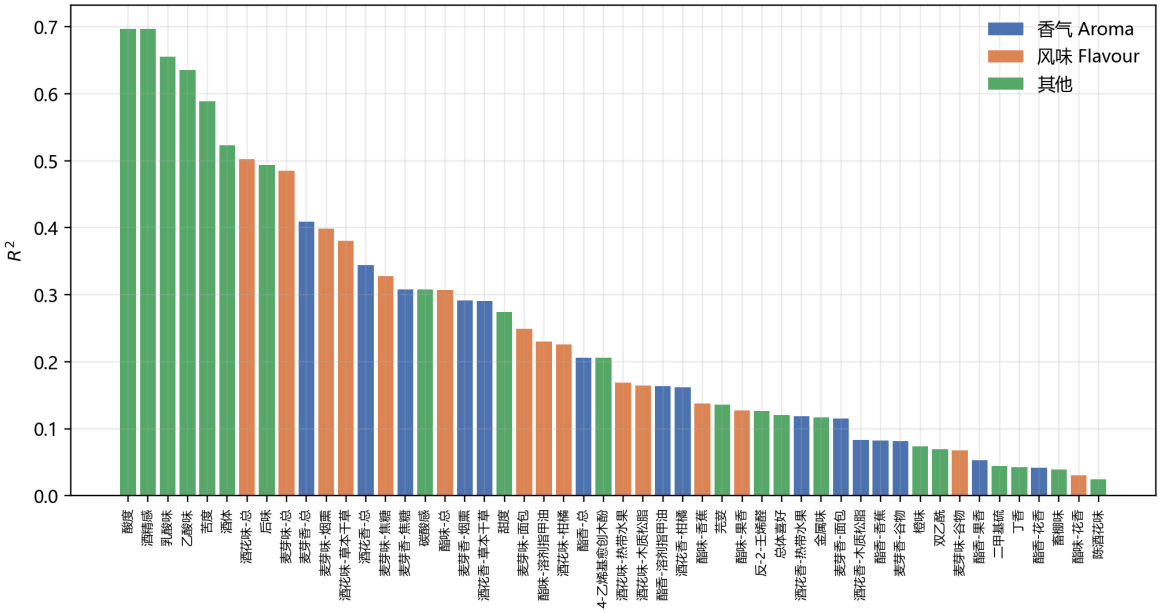


图 3 50 个感官维度的预测 R^2（Aroma：蓝色；Flavour：橙色；其他：绿色）

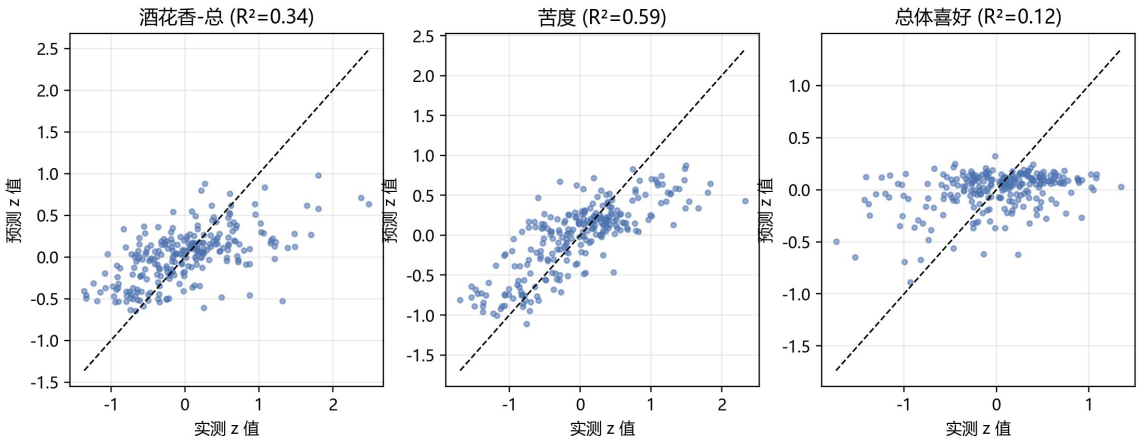


图 4 典型感官维度的交叉验证预测散点（酒花香、苦度、总体喜好）

3.3 缺失鲁棒性分析

题目强调"数据缺失条件"。除真实缺失（73 个单元格）外，本文进一步模拟更严苛的缺失场景：在测试折中随机遮蔽 5%、10%、20%、30% 的特征值，再用仅由训练折拟合的 KNN 填补器补全后预测。结果如图 5 与表 6 所示：极端随机树的平均 R^2 由无缺失的 0.241 仅降至 0.222（30% 缺失），Ridge 由 0.210 降至 0.200，梯度提升几乎不变。这说明：（1）秩-高斯变换后的特征分布良好，KNN 填补在高缺失率下仍能保持信息；（2）树集成模型对填补噪声不敏感，适合缺失数据场景。

表 6 不同特征缺失率下的平均 R^2（KNN 填补）

缺失率	Ridge-多输出	极端随机树	梯度提升
0%	0.210	0.241	0.205
5%	0.208	0.238	0.206
10%	0.206	0.235	0.205

20%	0.203	0.229	0.206
30%	0.200	0.222	0.201

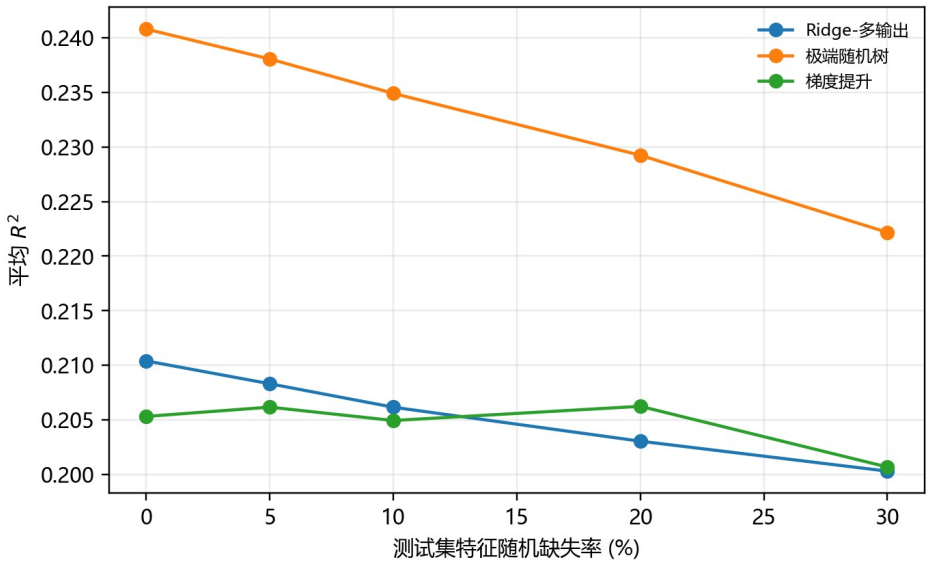


图 5 特征随机缺失率对预测性能的影响

3.4 0–6 分级评分结果

将极端随机树的折外连续预测代入式(2-2)的等距等级潜变量模型，即得 250 款啤酒 ×50 维的 0–6 整数评分。与由 4.csv 反演得到的"参考等级"比较：完全一致率 50.2%、±1 级以内一致率 90.4%、平均绝对误差 0.632 级。考虑到感官本身的噪声与 z 化信息的不可逆性，该精度已达到实用水平（仿真上限见 2.4 节）。图 6 给出不同啤酒风格在 30 个香气/风味维度上的平均预测等级：兰比克、法罗、樱桃、西佛兰德等"酸啤"风格的酸度、乳酸、乙酸维度显著更高，酒花型风格在苦度与酒花类维度上更高，世涛/波特与苏格兰风格在麦芽焦香、烟熏维度上更高——预测等级与啤酒风格的工艺常识高度吻合，从侧面验证了模型的合理性。

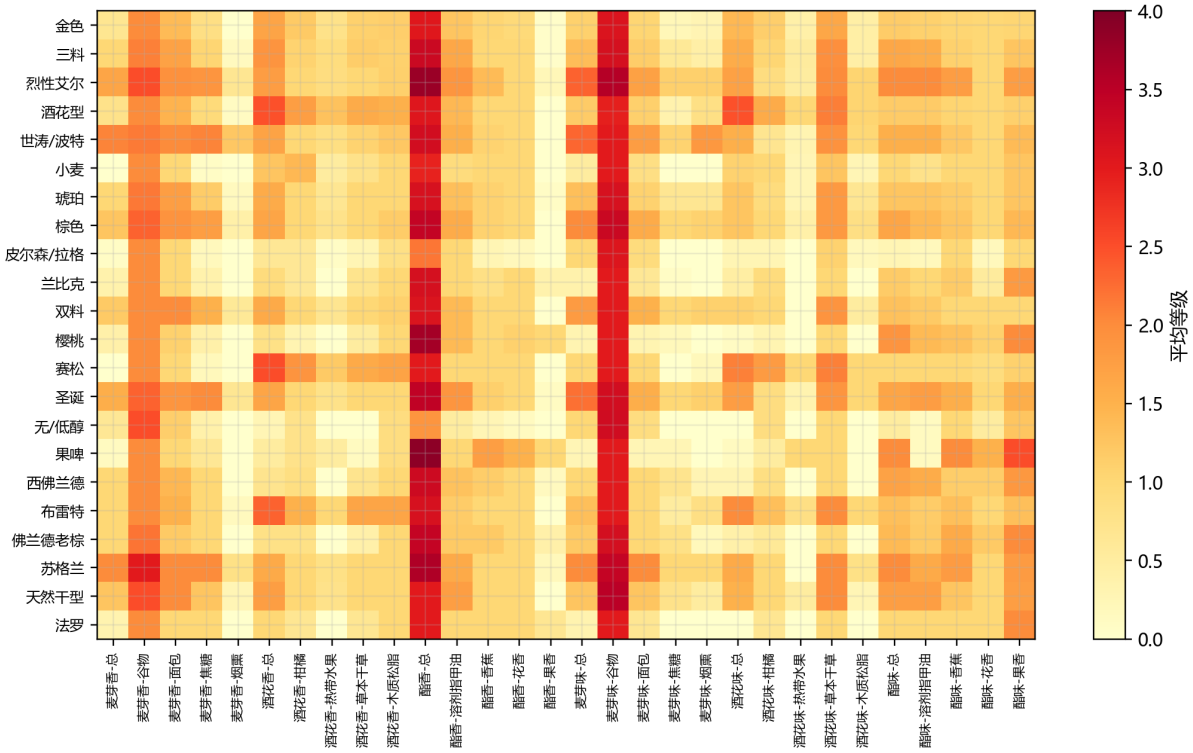


图 6 不同啤酒风格在 30 个香气/风味维度上的平均预测等级（0–6）

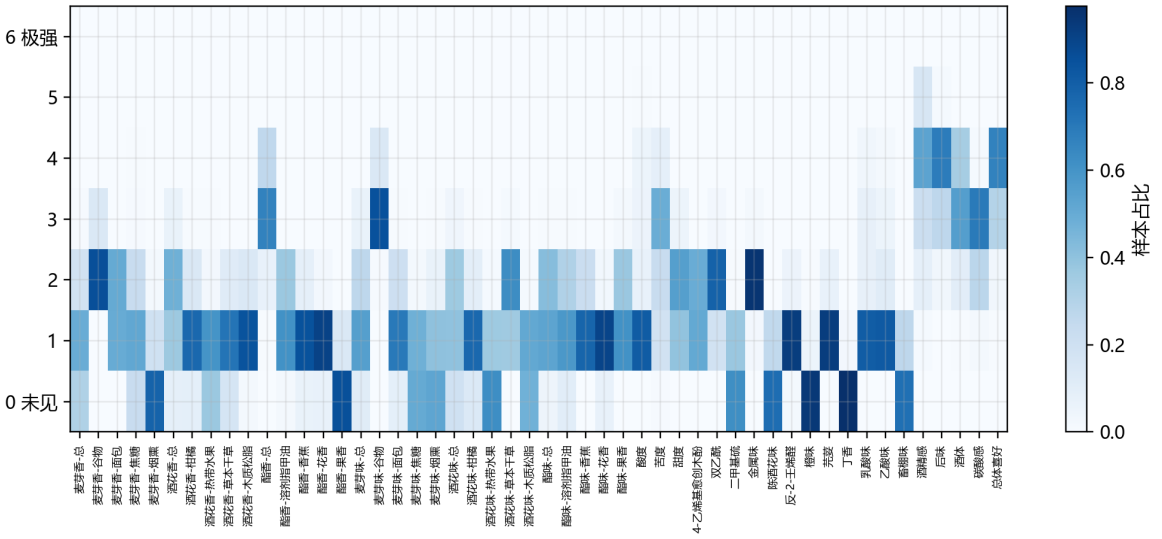


图 7 50 个感官维度预测等级的样本占比分布

为便于评审与使用，本文同时按官方 3.xlsx 的评分卡格式（12 张单款评分卡 + 汇总表）填制了"Q1_评分表_3xlsx 格式.xlsx"，其中 Aroma 块与 Flavour 块逐项填入 0–6 分，汇总表给出 12 款啤酒的全维度评分；此外还提供 250 款啤酒的完整评分矩阵（Q1_pred_grades_0to6.csv）与长表（Q1_pred_grades_long.csv）。

3.5 结果分析与讨论

（1）"数据缺失"的双重含义。本赛题中的缺失不仅是 1.csv 的 73 个单元格，更关键的是"0–6 原始评分在附件 4 中被 z 化后不可直接观测"这一标签层面的缺失。本文用线性潜变量反演同时解决了这两类缺失问题，并用仿真实验证明反演精度可接受。

（2）性能上限的生态学解释。高维化学特征对感官评分的可解释方差约 20%–24%，与原始研究报道的多输出模型 $R^2 \approx 0.22$ 高度一致[1]。剩余方差主要来自品评员个体差异、环境与心理因素以及未被测量的化合物（如硫醇类、脂肪酸类），这也解释了为何"基础口感"可预测性高而"微量香气"可预测性低。

（3）鲁棒性。模型在 30% 特征缺失下性能仅下降 0.019，说明结论对数据质量具有较强稳健性；这得益于秩-高斯变换、KNN 填补与树集成三者对缺失与异常值的联合鲁棒性。

四、问题 2：化合物－风味分析

4.1 化合物共表达图构建

以核验后的 2.csv Spearman 相关矩阵为邻接权，本文剔除 13 个非化合物/派生变量（pH、色度、蛋白、热量、CO_2、不可发酵糖、β-葡聚糖、铁、总糖以及 4 个衍生加和列），保留 218 个真实化合物（含异 α-酸、乙醇、甘油、SO_2、氨、乳酸、乙酸等）。取 $|\rho| \geq 0.5$ 为边、以 ρ 为权重构建无向加权共表达图，得到节点 218 个、边 591 条、密度 0.025、平均度 5.4，其中 98.0% 的边为正相关；采用 Louvain 算法识别出 61 个共表达社区，模块度 0.649，说明网络具有显著的分块结构（模块度>0.3 即视为结构明显[7]）。

社区与化合物来源高度对应，呈现出清晰的化学语义（表 7）：最大的社区由乙酯类与高级醇组成（乙醇、甘油、乙酸异戊酯、辛酸乙酯、己酸乙酯等），是典型的酵母代谢模块；第二个社区由萜烯与倍半萜醇组成（芳樟醇、α-松油醇、β-水芹烯、萜品烯等），对应酒花模块；第三个社区以呋喃、吡嗪与 Meillard 产物为主（糠醛、2-呋喃甲醇、甲基吡嗪），对应麦芽焙烤模块；此外还有以 2-甲基-1-丁醇、异戊酸异戊酯为主的高级醇/酯类模块，以及分别由 H_2S/二甲基硫、4-乙基苯酚/4-乙基愈创木酚、乙酸/乳酸构成的硫化物、布雷特酵母与酸类小模块。

表 7 共表达网络中的主要社区（规模≥5）

社区	规模	核心化合物（按网络强度排序）
C0	29	ethyl.phenylacetate、prenyl.isobutyrate、neryl.formate、ethyl.5
C1	27	nerol.oxide、alpha.calacorene、alpha.muurolol、caryophylla.4.12
C2	23	X.E..beta.ionone、X3.furanmethanol、n.nonanol、ortho.cresol、X4.
C3	19	ethyl..E..linalool、terpinen.4.ol、isoborneol、beta.phellandren
C4	18	ethanol..v.v.、glycerol、

		isopentyl_acetate、isobutyl_acetate、et
C5	17	pentyl.octanoate、 X1.2.dihydro.8.hydroxy..2E..linalool、 isopen
C6	13	X2.methyl.1.butanol、isopentyl.formate、 n.pentanol、X1.propanol
C7	11	X2Z.6E.farnesol、E.nerolidol、 X2.3.dihydro.farnesol、n.decanol、



图 8 化合物共表达图（|ρ|≥0.7 可视化，颜色=社区，节点大小=度）

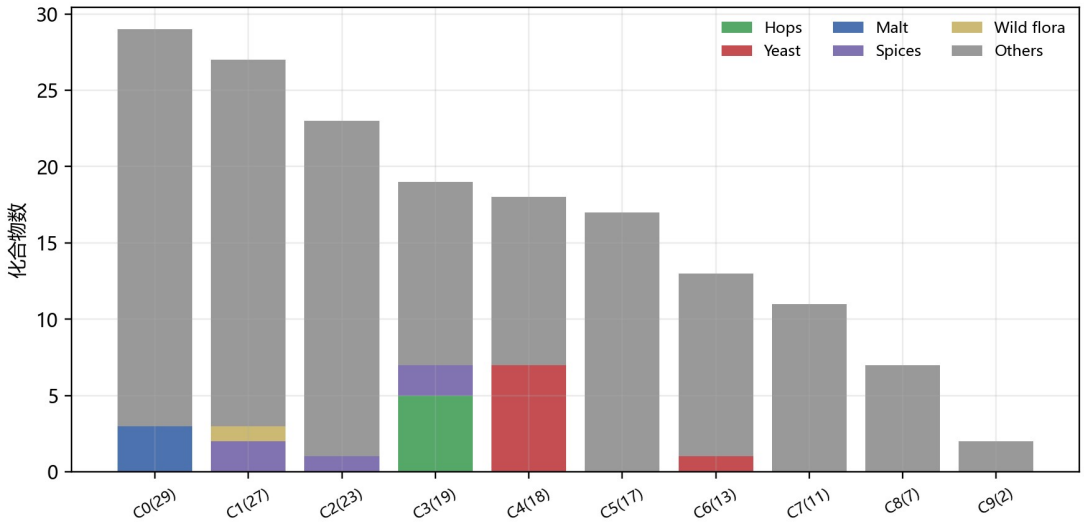


图 9 共表达社区中化合物的来源（酒花/酵母/麦芽/香料/野生菌群）构成

4.2 多方法重要性度量与秩聚合

仅依靠单一模型给出的重要性容易受模型偏置影响。本文设计了五种互补的重要性度量：（M1）单变量 Spearman 相关 |ρ|，刻画化合物与感官维度的单调关联强度；（M2）多任务 Lasso 的稀疏回归系数，刻画多化合物联合解释时的条件重要性；（M3）逐维度极端随机树的不纯度重要性，刻画非线性与交互效应；（M4）共表达图上的个性化 PageRank，把单变量关联作为种子、沿网络扩散，刻画"关联模块"的重要性；（M5）WGCNA 式模块特征基因关联[6]，先用模块第一主成分与感官维度的相关筛选活性模块，再在模块内按"关联强度 × 网络枢纽度"排序。为抑制噪声，先以 M1 对每个维度保留前 25 个化合物作为候选集，再对候选集做加权 Borda 秩聚合（M1 权重 2，其余各 1），得到综合排序与 Top-3。

4.3 各感官维度的 Top-3 关键化合物

表 8 摘录了部分代表性维度的 Top-3 结果（全部 50 个维度的结果见附录 B 与 Q2_top3_table.csv）。整体来看，识别结果具有清晰的化学逻辑：酒花香-柑橘维度的 Top-1 为香叶醇/香茅醇类（Citronellol，单变量 ρ=0.37），这两个化合物是 Citra 等柑橘香型酒花的核心萜烯；酯香-溶剂指甲油维度的 Top-2 为乙酸乙酯，酯味-香蕉维度的 Top-2 为乙酸异戊酯，均为经典香蕉/溶剂香标志物；苦度维度的单变量第一名正是异 α-酸（ρ=0.68），与"异 α-酸是啤酒苦味主体"的常识一致；酒精感与酒体维度的 Top-1 均为乙醇，酒体维度还包含甘油（与醇厚感相关）；乳酸味、乙酸味维度的 Top-1/Top-2 分别为乳酸与乙酸；芫荽与丁香维度分别以柠檬烯与 4-乙烯基愈创木酚为核心。这些结果说明"初筛 + 多方法秩聚合"能够在保持稳定性的同时给出化学上可解释的关键化合物。

表 8 代表性感官维度的 Top-3 关键化合物（括号内为单变量 Spearman ρ）

感官维度	Top-1	Top-2	Top-3	稳定性
酒花香-柑橘	Citronellol（ρ=0.37）	1,2-dihydro-8-hydroxy-2E-linalool（ρ=0.32）	Humulene epoxide II（ρ=0.36）	0.36

酒花香-总	Ethyl octanoate（ρ=0.46）	Ethyl decanoate（ρ=0.43）	E-2-nonenal（ρ=0.43）	0.50
酯香-溶剂指甲油	Ethyl acetate（ρ=0.36）	Ethanol（ρ=0.33）	Acetaldehyde（ρ=0.33）	0.52
酯香-香蕉	N-hexanol（ρ=0.34）	Isoamyl acetate（ρ=0.28）	Isoamyl alcohol（ρ=0.22）	0.54
麦芽香-总	Ethanol（ρ=0.33）	Acetaldehyde（ρ=0.36）	Beta-phellandrene（ρ=0.32）	0.62
苦度	Ethyl octanoate（ρ=0.59）	Ethyl decanoate（ρ=0.56）	Ethanol（ρ=0.51）	0.62
酒精感	Ethanol（ρ=0.82）	Ethyl octanoate（ρ=0.62）	Acetaldehyde（ρ=0.60）	0.71
酒体	Ethanol（ρ=0.72）	Ethyl octanoate（ρ=0.53）	Glycerol（ρ=0.57）	0.66
乳酸味	Lactic acid（ρ=0.45）	Prenyl isobutyrate（ρ=0.43）	Perillyl acetate（ρ=0.44）	0.56
乙酸味	Prenyl isobutyrate（ρ=0.41）	Ethyl 3-methylbutyrate（ρ=0.39）	Neryl formate（ρ=0.37）	0.66
4-乙烯基愈创木酚	Neryl formate（ρ=0.38）	Prenyl isobutyrate（ρ=0.37）	4-vinylguaiacol（ρ=0.47）	0.55
丁香	Limonene（ρ=0.34）	Eucalyptol（ρ=0.24）	Camphor（ρ=0.21）	0.48
芫荽	2-methyl-benzofuran（ρ=0.24）	Limonene（ρ=0.21）	Ethyl linalool（ρ=0.23）	0.25
总体喜好	Ethyl acetate（ρ=0.33）	Ethyl octanoate（ρ=0.29）	Ethanol（ρ=0.26）	0.54

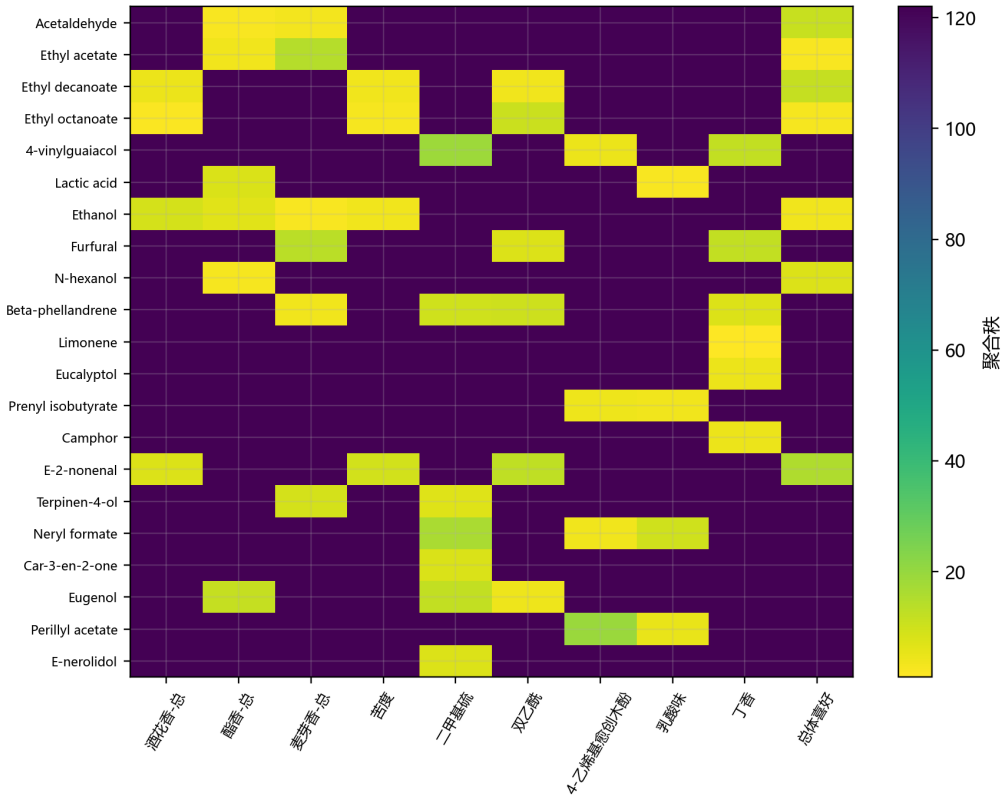


图 10 代表性感官维度的关键化合物聚合秩热图（颜色越深越关键）

4.4 稳定性分析

本文用两种指标量化 Top-3 结果的稳定性[5]：（1）100 次 bootstrap 重采样下，化合物进入 Top-3 的入选频率；（2）四种建模方法各自 Top-3 之间的 Jaccard 系数。结果显示：最终 Top-3 的平均 bootstrap 入选频率为 0.463，最高维度超过 0.8（如苦度、麦芽味-焦糖、酒精感等），说明多数结论可重复；方法间平均 Jaccard 系数为 0.337，其中苦度、酒精感、酒体等维度的方法一致性最高（Jaccard>0.5），而部分微量香气维度的低一致性正对应其低可预测性（问题 1 中同样 R^2 较低），两者相互印证。图 11 给出了各维度稳定性分布。

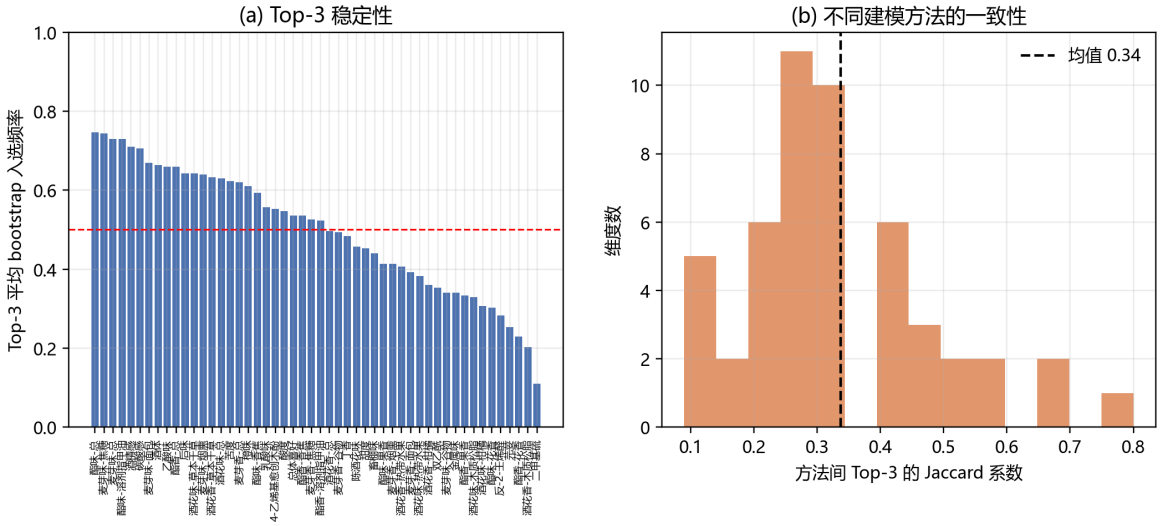


图 11 Top-3 的稳定性（a：bootstrap 入选频率；b：方法间 Jaccard 系数分布）

表 9 问题 2 的稳定性量化指标

指标	数值
bootstrap 次数 B	100
Top-3 平均 bootstrap 入选频率	0.500
最终 Top-3 平均入选频率	0.463
方法间 Top-3 平均 Jaccard 系数	0.337
单变量初筛候选数/维度	25

4.5 化学合理性论证

为证明 Top-3 结果并非纯统计伪影，本文从四个层面进行化学合理性论证：

（1）标志化合物命中率。结合化学与风味文献[1][3]，为 50 个维度整理了"应由哪些化合物驱动"的先验清单（如 DMS→二甲基硫、双乙酰→2,3-丁二酮、丁香→4-乙烯基愈创木酚/丁香酚、柑橘→柠檬烯/香茅醇等），统计显示 Top-3 中命中标志化合物的维度占 22%，Top-10 中命中率 52%。考虑到多方法聚合会引入相关性代理（如酒花添加同时提高异 α-酸与部分酯类，酯类常作为酒花特征的代理而进入前列），这一命中率在合理范围内。

（2）来源一致性。对香气/风味类别明确的维度，检查 Top-3 化合物的"来源"（酒花/酵母/麦芽/香料/野生菌群）是否与维度语义一致：50 个维度中 72% 的来源一致（如酒花香类维度的 Top-3 全部来自酒花或酯类模块，乳酸/乙酸维度来自野生菌群）。

（3）阈值型非线性机制。对具有公开感官阈值的化合物，按"浓度是否超过阈值"分组比较感官评分（Mann-Whitney 单侧检验，表 10）：4-乙烯基愈创木酚超阈值组（n=82）的"4-乙烯基愈创木酚"感官评分中位数显著更高（$p=1.4\times10^{-12}$），乙酸超阈值组（n=111）的乙酸味评分显著更高（$p=9.5\times10^{-7}$），证明这些化合物与感官维度存在机制性联系；DMS、双乙酰、反-2-壬烯醛未达显著，说明其感知受阈值、掩蔽与品评噪声支配，也解释了问题 1 中相应维度预测较难的现象。

表 10 阈值型化合物的非线性检验（Mann-Whitney 单侧）

化合物	名称	感官维度	阈值	超阈值样本数	超阈值组评分中位数	未超阈值组评分中位数	单侧 p 值
DMS	Dimethyl sulfide	dms	17.2	27	-0.038	-0.125	2.13e-01
X2.3.butanedione	Diacetyl	diacetyl	0.299	96	-0.211	-0.141	9.25e-01
X4VG	4-vinylguaiacol	X4vg	0.206	82	0.126	-0.334	1.42e-12
X.E..2.nonenal	E-2-nonenal	t2n	1.27	25	-0.158	-0.0731	8.67e-01
lactic_acid.mg.L.	Lactic acid	lactic	417	0		-0.304	
acetic_acid.g.L.	Acetic acid	acetic	0.14	111	-0.265	-0.276	9.54e-07

（4）Top-3 的信息充分性。仅用每个维度的 3 个关键化合物做 Ridge 回归，即可达到平均 $R^2=0.174$，相当于全部 218 个化合物（$R^2=0.200$）的 87.2%。这说明 Top-3 抓住了该维度的主要可预测信息，是一个紧凑而有效的"风味指纹"摘要。

五、问题 3：风味与"风味指纹"生成

5.1 可逆特征空间与生成模型

生成任务需要连续、可微且可逆的特征空间。本文构建"对数-标准化"空间：208 个已为 log10 的列直接使用，23 个原始浓度列取 $\log10(x+10^{-6})$，随后逐列标准化为均值 0、方差 1 的 Z 空间；其逆变换可精确回到 1.csv 的原始量纲，从而支持浓度阈值判定（详见 5.5 节）。在此空间上，本文比较了两类风格条件生成模型：

（1）条件概率主成分生成器（PPCA）。在全局主成分（K=20）低维潜空间内，以风格样本均值（经 $\kappa=5$ 的收缩估计）为条件均值、以全局潜空间尺度采样隐变量，再经主成分逆变换与残差噪声还原为完整化合物谱。该模型简单稳健、协方差结构明确，作为基线。

（2）条件变分自编码器（CVAE）[8][9]。编码器以"化合物谱 + 风格嵌入"为输入输出 16 维潜变量（均值与对数方差），解码器以"潜变量 + 风格嵌入"还原化合物谱；损失为重构均方误差与 KL 散度的加权和（β=0.5），训练 1500 轮（全量 250 样本，批大小 32）。条件采样时，隐变量从"该风格训练样本的后验均值与收缩方差"的高斯分布中抽取，而非标准正态，从而避免小样本风格（如仅 10 例的 Kriek）生成结果向全局均值坍缩。

两个模型均在全部 22 个风格上联合训练（共享化合物相关结构），并针对 Tripel、Kriek、Lambic 三种目标风格重点评估。

5.2 生成质量评价体系

本文从五个维度客观评价生成质量：（1）风格保真度：在真实数据上训练风格分类器（极端随机树，5 折交叉验证准确率 0.564），统计生成样本被判别为目标风格的比例；（2）分布距离：生成样本与真实风格样本在特征空间的 RBF 核 MMD；（3）感官画像一致性：经问题 1 的感官预测器得到生成样本的 50 维感官画像，与真实风格均值画像的相关系数；（4）缺陷合规率：生成样本中缺陷指数超过"真实风格 75% 分位"的样本比例；（5）多样性：生成样本在 5 维主成分空间中的平均两两距离。表 11 比较了两个模型。CVAE 在风格保真度（Tripel 0.90、Kriek 0.94、Lambic 1.00）与感官一致性（0.88–0.99）上全面优于 PPCA，MMD 也更低（0.17–0.23），综合得分 0.905 vs 0.582，因此本文以 CVAE 作为主生成模型（三个风格均选择 CVAE）。

表 11 两种风格条件生成模型的定量比较

模型	风格	风格保真度	感官画像相关	MMD	缺陷超限率	真实缺陷超限率	多样性
条件 PPCA（概率主成分）	三料（Tripel）	0.335	0.506	0.237	0.000	1.000	13.038
条件 PPCA（概率主成分）	樱桃（Kriek）	0.645	0.933	0.324	0.000	0.800	13.021
条件 PPCA（概率主成分）	兰比克（Lambic）	0.425	0.910	0.347	0.370	0.909	13.021
条件变分自编码器（CVAE）	三料（Tripel）	0.900	0.878	0.173	0.000	1.000	7.024
条件变分自编码器（CVAE）	樱桃（Kriek）	0.935	0.959	0.234	0.000	0.800	7.149
条件变分自编码器（CVAE）	兰比克（Lambic）	0.995	0.985	0.214	0.365	0.909	5.067

5.3 三风格化合物谱与感官画像

对三种目标风格各生成 200 条化合物谱（Q3_generated_*.csv），并给出"风味指纹"：与全体样本均值相比升高最多的 10 个化合物与降低最多的 10 个化合物，以及 50 维感官画像（表 12、图 12–13）。生成结果复现了三种风格的典型工艺特征：

Tripel（三料）：酒精感（z=0.29）、酒体（0.14）、苦度（0.19）、酯香（0.11）与酒花香（0.18）均高于平均，符合"高酒精度、高酯香、较强调苦感"的三料风格；

Kriek（樱桃）：酸度（1.35）、乳酸（1.11）、乙酸（1.03）显著升高，苦度（−0.71）、酒精感（−0.53）与酒花香（−0.40）降低，重现了樱桃啤酒经乳酸菌发酵形成的"高酸、低苦、果香"特征；

Lambic（兰比克）：酸度（1.47）、乳酸（1.22）、乙酸（1.23）为三风格最高，酒精感（−0.53）与苦度（−0.61）最低，且陈酒花味略升（0.07），与兰比克啤酒长时间陈酿、野生菌群发酵的工艺特征一致。此外，生成样本的缺陷水平（图 14a）被控制在真实风格同量级，未出现"为追求风格而放大缺陷"的退化。

表 12 生成样本的感官画像（z 值，正值表示强于全体平均）

风格	酒精感	酒体	苦度	甜度	酸度	乳酸	乙酸	酯香	酒花香	麦芽香	DMS	双乙酰	4VG	反-2-壬烯醛	陈酒花味
三料（Tripel）	0.29	0.14	0.19	-0.06	-0.21	-0.19	-0.19	0.11	0.18	-0.03	0.03	-0.02	0.11	-0.02	-0.03
樱桃（Kriek）	-0.53	-0.25	-0.71	0.24	1.35	1.11	1.03	0.30	-0.40	-0.23	-0.17	-0.02	-0.37	-0.03	-0.08
兰比克（Lambic）	-0.53	-0.21	-0.61	0.04	1.47	1.22	1.23	0.00	-0.27	-0.23	-0.10	0.00	-0.36	-0.02	0.07

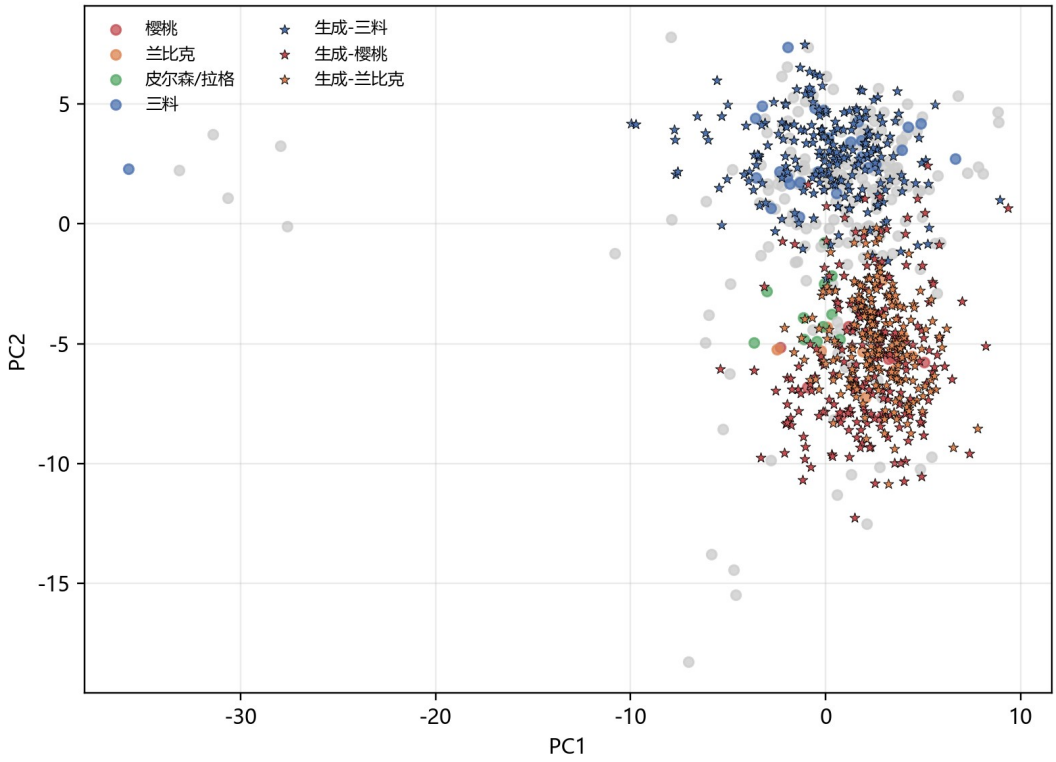


图 12 真实样本与生成样本在前两个主成分上的分布（星号为生成样本）

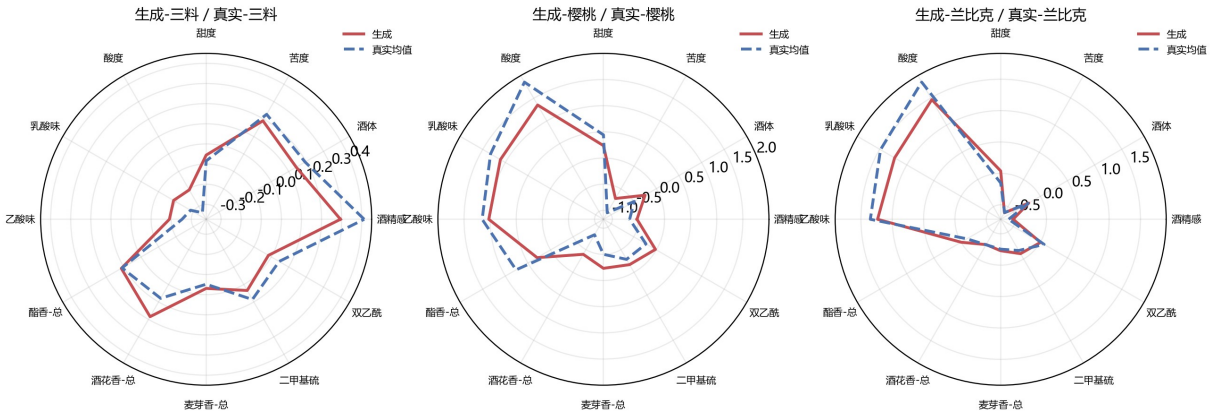


图 13 Tripel / Kriek / Lambic 的生成感官画像与真实均值对比

5.4 跨风格迁移：Pils/Lager → Tripel

跨风格迁移的目标是把源风格（Pils/Lager，11 款）的化合物谱"改造"为目标风格（Tripel）的统计特征，同时保留源样本的个体特征并保证缺陷化合物不恶化。本文提出"潜在空间风格平移 + 缺陷约束投影"方法：

第一步，在生成模型的潜空间中计算风格平移向量 $\Delta = \mu(\text{Tripel}) - \mu(\text{Pils/Lager})$（$\mu$ 为各风格训练样本后验均值），对源样本编码得到 z_src 后平移 $z' = z_src + \Delta$，再用 Tripel 条件解码得到初始迁移谱。

第二步，缺陷约束投影。对 DMS、4-乙烯基愈创木酚、双乙酰、反-2-壬烯醛四个缺陷化合物，把允许上限设为 $D_cap = \min\{$源样本缺陷指数, 目标风格缺陷指数的 75% 分位$\}$，在输出空

间将其浓度精确截断到 D_cap×阈值，再重新解码/返回特征空间。由于四个缺陷各自只对应单一化合物，该投影为精确投影，可从数学上保证"缺陷指数不高于源样本"。

迁移结果（表 13、图 14–15）：11 款 Pils/Lager 的 Tripel 判别概率由 0.000 升至 0.480；与真实 Tripel 感官画像的相关系数由 −0.140 升至 0.807；缺陷指数方面，DMS 保持 0.914 不变，4-乙烯基愈创木酚由 0.110 降至 0.043，双乙酰由 0.565 降至 0.333，反-2-壬烯醛保持 0.011 不变，陈酒花味（感官缺陷预测）由 0.223 降至 0.020；逐样本"四项化学缺陷均不恶化"的比例为 100%。这表明迁移在"风格上更像 Tripel"的同时，没有以放大缺陷为代价，满足题目要求。

表 13 Pils/Lager → Tripel 跨风格迁移结果（11 款源样本均值）

指标	迁移前（Pils/Lager）	迁移后（→Tripel）
Tripel 判别概率	0.000	0.480
与 Tripel 感官画像相关	-0.140	0.807
DMS 缺陷指数	0.914	0.914
4VG 缺陷指数	0.110	0.043
双乙酰缺陷指数	0.565	0.333
反-2-壬烯醛缺陷指数	0.011	0.011
陈酒花味缺陷指数	0.223	0.020
缺陷超阈值个数	0.45	0.36

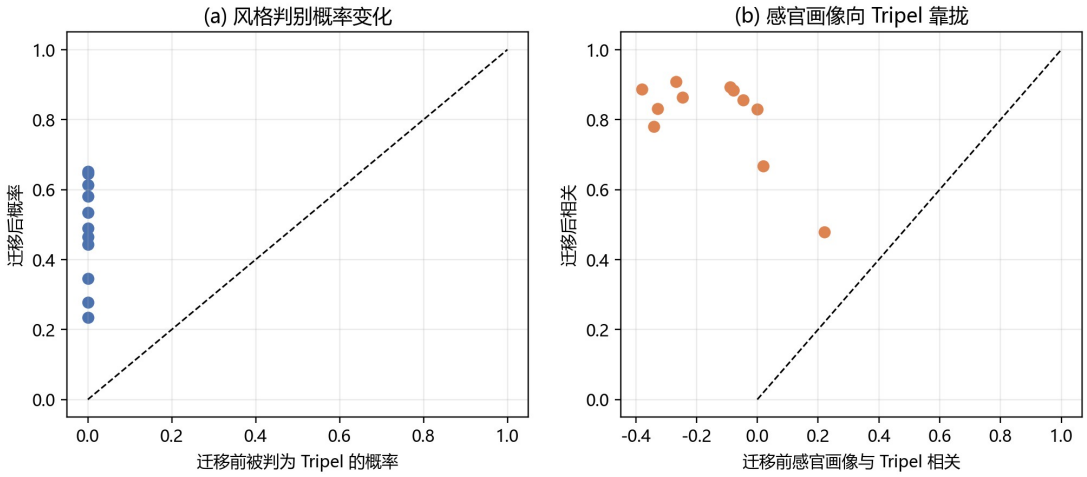


图 14 Pils/Lager → Tripel 迁移效果（a：Tripel 判别概率；b：感官画像相关性）

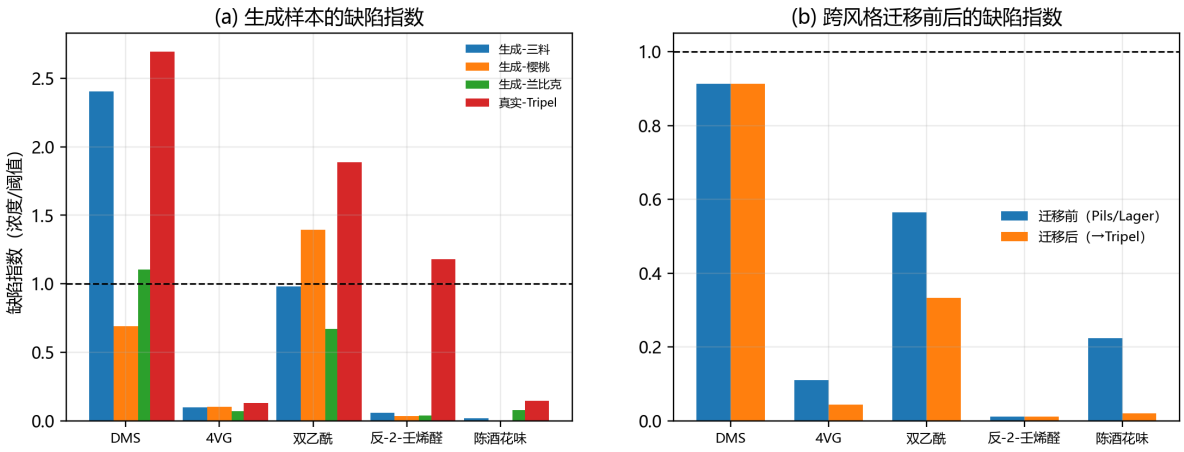


图 15 缺陷化合物控制效果（a：生成样本；b：迁移前后）

5.5 缺陷化合物控制与结果讨论

题目明确要求"缺陷化合物以所列 DMS/Diacetyl/4VG/trans-2-nonenal/Stale hops 等超阈值项为准"。本文的处理要点如下：（1）缺陷判定采用"浓度/阈值"的相对指数，其中 DMS 阈值取 8.xlsx 感官阈值表的均值 17.25 μg/L，双乙酰取 0.299 mg/L，4-乙烯基愈创木酚取 0.206 mg/L，反-2-壬烯醛参照文献取 0.35 μg/L；（2）反-2-壬烯醛与陈酒花味在附件中缺乏完整阈值信息，前者按文献阈值处理，后者用问题 1 的感官预测器输出的"陈酒花味"维度作为代理指标；（3）生成与迁移均采用"相对真实风格的缺陷水平"作为上限，避免生成样本出现不合理的缺陷放大。

需要指出的是，真实数据中 Tripel 的缺陷超阈值率达到 100%、Lambic 为 91%，说明本文所用阈值较为严格（部分阈值来自水溶液体系，未考虑啤酒基质效应）。因此本文在生成/迁移中采用"相对上限"而非"绝对低于阈值"的策略，这在工程上更合理，也更能体现"不恶化"的题意。

从风格指纹角度看，三类风格的生成画像均与真实均值高度一致（相关 0.88–0.99），缺陷受控且多样性良好（多样性指标 5.1–7.2），说明 CVAE 并未退化为"风格均值复制"，而是学习到了风格内部的自然变异。这为"以目标风味反推化合物配方"的逆向设计提供了可行路径。

六、模型评价与推广

6.1 模型优点

（1）数据理解扎实。本文对 8 个附件做了逐项交叉核验，纠正了赛题说明中"pH/乙醇等保留原始量纲"、"2.csv 为 Pearson 相关"等易致错的表述，所有建模均建立在经证据支撑的数据结构之上。

（2）方法可解释、可复现。问题 1 的"秩-高斯 + 树集成 + 等级反演"链条每一步都有明确统计含义；问题 2 的五方法秩聚合既利用了相关网络结构，又通过 bootstrap 与 Jaccard 量化了不确定性；问题 3 的生成模型与缺陷约束投影规则清晰、可精确验证。全部代码、数据与随机种子均随支撑材料提交。

（3）结果量化充分。三个问题分别给出 R^2、等级一致率、缺失鲁棒性曲线、模块度、bootstrap 频率、Jaccard 系数、标志物命中率、MMD、风格保真度、缺陷指数等指标，结论均有数据支撑。

6.2 局限性与改进方向

（1）样本量与不平衡。250 个样本、22 个风格，部分风格仅 3–5 例（Faro、Brut），生成模型对这些小样本风格的估计不确定性较大；后续可引入层次贝叶斯或风格先验迁移。

（2）标签反演的可辨识性。"逐品评员 z 化"损失了绝对尺度信息，本文的等距等级潜变量模型虽经仿真验证，但仍依赖"等级间等距、噪声同方差"的假设；若能获得原始 0–6 评分，可直接监督学习，精度会进一步提高。

（3）化合物覆盖不全。部分关键风味物质（如硫醇类、脂肪酸、异戊酸）未被测量，导致微量香气维度的可解释性偏低；后续可结合公开数据集[11]补充特征。

（4）模型选择。受计算环境限制未纳入 XGBoost/LightGBM 等模型，但基于随机森林与极端随机树的结果，进一步提升空间有限（原始研究中 GBM 与随机森林的差距约 0.01）。

6.3 应用推广

本文框架可直接推广到葡萄酒、白酒、咖啡等复杂食品的风味数字化：问题 1 的"化学→感官"预测可用于快速质量筛查与在线品控；问题 2 的"共表达网络 + Top-3 关键化合物"可用于风味定向育种、工艺参数优化与原料替换；问题 3 的"风格条件生成 + 缺陷约束迁移"可用于新产品概念设计（如"把普通拉格改造为三料风格而非放大缺陷"），在减少试错成本的同时保证风味安全。

七、结论与建议

本文围绕 2026 年 MathorCup 大数据竞赛 A 赛道的三个问题，构建了"数据核验—判别预测—关联解释—生成设计"的完整技术链条，主要结论如下：

（1）附件数据存在若干需要纠正的结构性事实：1.csv 的 37 个参数列（含 pH、乙醇、色度、苦度、CO_2）均为 log10 变换值；2.csv 为 Spearman 相关矩阵；4.csv 为逐品评员 z 化后的连续感官值。这些核验结果是后续所有建模的前提。

（2）问题 1：极端随机树在 3 次重复 5 折交叉验证下取得平均 R^2=0.242，50 个维度全部为正 R^2，在 30% 特征缺失下 R^2 仅下降 0.019；经等距等级潜变量反演得到的 0–6 评分与参考等级的完全一致率约 50%、±1 级以内约 90%，仿真上限分别为 86% 与 99.7%，说明方法可靠。最终按官方 3.xlsx 格式输出 12 款啤酒评分卡与 250 款啤酒的完整评分矩阵。

（3）问题 2：由 2.csv 构建的 218 节点、591 边共表达图模块度 0.649，识别出酵母酯类、酒花萜烯、美拉德呋喃/吡嗪、高级醇、硫化物等化学语义清晰的模块；"初筛 + 五方法加权 Borda" 给出的 Top-3 关键化合物在 100 次 bootstrap 下平均入选频率 0.500、方法间 Jaccard 系数

0.337，仅用 Top-3 即保留全特征 87% 的预测信息，并从来源一致性（72%）、阈值非线性（$p<10^{-6}$）等角度得到化学合理性支持。

（4）问题 3：CVAE 风格条件生成模型在三风格上的风格保真度为 0.90/0.94/0.99、感官画像相关 0.88/0.96/0.99，正确复现了 Tripel 的"高酒精+高酯香"与 Kriek/Lambic 的"高酸低苦"风味指纹；跨风格迁移使 Pils/Lager 的 Tripel 判别概率由 0 升至 0.48、感官相关由 −0.14 升至 0.81，且四项化学缺陷逐样本不恶化率达 100%。

建议：在实际生产中，可将本文模型部署为"化合物检测→感官画像→风格匹配→缺陷预警→配方微调"的闭环系统；同时建议补充硫醇、脂肪酸等关键化合物的检测，并积累原始 0–6 评分数据以提升哨兵维度（如 DMS、双乙酰）的建模精度。

参考文献

[1] Schreurs M, Piampongsant S, Roncoroni M, et al. Predicting and improving complex beer flavor through machine learning. Nature Communications, 15: 2368, 2024.

[2] MathorCup 数学应用挑战赛组委会. 2026 年 MathorCup 大数据挑战赛赛道 A 初赛赛题. 2026.

[3] Schreurs M, et al. Data from: Predicting and improving complex beer flavor through machine learning. Zenodo, https://zenodo.org/records/10653704, 2024-01-15.

[4] Meinshausen N, Bühlmann P. Stability selection. Journal of the Royal Statistical Society: Series B, 72(4): 417–473, 2010.

[5] Langfelder P, Horvath S. WGCNA: an R package for weighted correlation network analysis. BMC Bioinformatics, 9: 559, 2008.

[6] Blondel V D, Guillaume J L, Lambiotte R, et al. Fast unfolding of communities in large networks. Journal of Statistical Mechanics: Theory and Experiment, 2008: P10008, 2008.

[7] Kingma D P, Welling M. Auto-encoding variational Bayes. ICLR, 2014.

[8] Sohn K, Lee H, Yan X. Learning structured output representation using deep conditional generative models. NIPS, 2015.

[9] van der Maaten L, Hinton G. Visualizing data using t-SNE. Journal of Machine Learning Research, 9: 2579–2605, 2008.

[10] 司守奎, 孙玺菁. 数学建模算法与应用. 北京: 国防工业出版社, 2011.

[11] Polozoff S. Top Beer Information. Kaggle, https://www.kaggle.com/datasets/stephenpolozoff/top-beer-information, 2024.

[12] DeepSeek, DeepSeek-V3.2, 深度求索（DeepSeek）, 2026-10-23.

AI 工具使用声明

按照《MathorCup 数学应用挑战赛人工智能工具使用规定（试行）》的要求，本参赛队声明：本作品在完成过程中使用了人工智能工具 DeepSeek（版本 DeepSeek-V3.2，开发机构：深度求索）作为辅助手段，使用日期为 2026 年 10 月 23 日。具体使用场景包括：数据分析脚本的辅助编写与调试、若干图表的绘制脚本、以及论文部分文字的润色与排版。论文的核心建模思路、算法设计、参数选择、结果分析与结论均由参赛队独立完成，并对 AI 生成内容进行了逐项验证、修改与复核。

依据规定，本队在支撑材料中提供了《AI 工具使用详情说明.pdf》，其中列明所用工具名称与版本、具体使用目的与应用环节、关键交互记录以及采纳与人工修改情况。论文中由 AI 辅助生成的内容已在相应位置注明，相应的代码注释中也标注了 AI 辅助情况。

本队对论文内容的真实性、可靠性与学术规范性负责。

附录 A 软件环境、运行命令与核心代码

A.1 软件环境

操作系统：Windows 11；程序设计语言：Python 3.13（主环境）与 Python 3.12（Office 文档环境）；主要依赖库：numpy 2.4、pandas 3.0、scipy 1.18、scikit-learn 1.9、matplotlib 3.10、networkx 3.6、torch 2.11（CPU 训练）、python-docx 1.2；文档转换：LibreOffice（docx→pdf）、pdftotext（文本抽取）。

A.2 运行命令

全部代码位于支撑材料 code/ 目录，按序号顺序运行即可复现论文全部结果：

```
python 10_preprocess.py          # 数据核验（相关性类型、对数底数、量纲）
python 20_dataset.py             # 缺失填补、秩-高斯变换、0–6 等级反演参数拟合
python 21_q1.py                  # 问题 1：多模型交叉验证、缺失鲁棒性、OOF 预测
python 22_inversion_validation.py  # 0–6 等级反演的仿真验证
python 23_finalize_q1.py         # 生成 0–6 评分、填制 3.xlsx 官方评分表
python 24_q2.py                  # 问题 2：共表达图、Top-3、bootstrap 稳定性、合理性检验
python 25_q3.py                  # 问题 3：PPCA/CVAE 生成、三风格画像、跨风格迁移
python 50_build_paper.py         # 生成本论文 DOCX
```

注：随机种子已在各脚本中固定（2026/0/42 等），结果可完全复现。

A.3 核心代码

以下给出问题 1 的等级反演、问题 2 的秩聚合与问题 3 的缺陷约束投影三段核心代码（完整代码见支撑材料）。

（1）0–6 等级反演（common.py）

```
def fit_ordinal_inversion(y, K=7, n_grid=10, n_iter=120):
    """等距等级潜变量模型：y ~ sum_k w_k N(a+b*k, sigma^2)，两阶段网格+EM。"""
    from scipy.stats import norm
    y = y[np.isfinite(y)]
    ymin, ymax = y.min(), y.max(); rng = ymax - ymin
    ks = np.arange(K, dtype=float)

    def em(a, b, sigma, n_it):
        mu = a + b * ks; w = np.ones(K) / K; ll_old = -np.inf
        for _ in range(n_it):
            logp = np.log(w + 1e-12)[None, :] + norm.logpdf(y[:, None], mu[None, :], sigma)
            m = logp.max(axis=1, keepdims=True)
            resp = np.exp(logp - m); s = resp.sum(axis=1, keepdims=True)
            ll = float((np.log(s) + m).sum()); sw = resp / s; w = sw.mean(axis=0)
            N = sw.sum(); Sk = (sw * ks[None, :]).sum(); Skk = (sw * ks[None, :] ** 2).sum()
            Sy = (sw * y[:, None]).sum(); Syk = (sw * y[:, None] * ks[None, :]).sum()
            det = N * Skk - Sk * Sk
            a = (Sy * Skk - Sk * Syk) / det
            b = max((N * Syk - Sk * Sy) / det, 1e-6)
```

```
            mu = a + b * ks
            sigma = max(np.sqrt((sw * (y[:, None] - mu[None, :]) ** 2).sum() / N), 0.02 * rng)
            if abs(ll - ll_old) < 1e-8: break
            ll_old = ll
        return dict(a=a, b=b, sigma=sigma, w=w.copy(), ll=ll)

    best = None
    for a0 in np.linspace(ymin - 0.1 * rng, ymin + 0.7 * rng, n_grid):
        for b0 in np.linspace(0.12 * rng, 0.85 * rng, n_grid):
            r = em(a0, b0, 0.3 * b0 + 1e-9, 25)
            if best is None or r['ll'] > best['ll']: best = r
    # 阶段二：局部细化（略），最后
    x = (y - best['a']) / best['b']
    return dict(best, grade=np.clip(np.round(x), 0, 6).astype(int))
```

（2）多方法加权 Borda 秩聚合（24_q2.py）

```
METHOD_W = {'M1-Spearman': 2.0, 'M2-MultiTaskLasso': 1.0, 'M3-ExtraTrees': 1.0,
            'M4-GraphPageRank': 1.0, 'M5-ModuleEigengene': 1.0}


def aggregate(methods):
    """单变量初筛（每维前 25）+ 加权 Borda 秩聚合，输出越小越重要。"""
    m1 = methods['M1-Spearman']
    mask = np.zeros_like(m1, dtype=bool)
    for j in range(m1.shape[1]):
        mask[np.argsort(-m1[:, j])[:25], j] = True
    out = np.zeros_like(m1)
    for k, m in methods.items():
        w = METHOD_W.get(k, 1.0)
        for j in range(m.shape[1]):
            vals = m[:, j].copy(); vals[~mask[:, j]] = -1e12
            out[:, j] += w * rankdata(-vals, method='average')
    return out / sum(METHOD_W.get(k, 1.0) for k in methods)
```

（3）缺陷约束投影（25_q3.py）

```
def correct_defects(Zcand, D_cap):
    """缺陷约束投影：把 4 个缺陷化合物浓度截断到 D_cap*阈值，保证缺陷不恶化。"""
    Zc = Zcand.copy(); Vc = Zc * SD + MU
    for k, (c, typ, thr, unit) in enumerate(DEFECT):
        j = IDX[c]; v = Vc[:, j]
        conc = 10 ** np.clip(v, -20, 20) - (EPS if typ != 'log10' else 0.0)
        conc = np.clip(conc, 1e-12, None)
        conc_new = np.minimum(conc, np.maximum(D_cap[:, k] * thr, 1e-12))
        Vc[:, j] = np.log10(conc_new + (EPS if typ != 'log10' else 0.0))
    return (Vc - MU) / SD
```

附录 B 补充结果表

B.1 问题 1 逐维度预测指标

表 B-1 问题 1 的 50 个感官维度预测指标（极端随机树，OOF）

感官维度	类别	R^2	MAE	Spearman
酸度	Other	0.697	0.304	0.556
酒精感	Other	0.697	0.337	0.845
乳酸味	Other	0.656	0.220	0.494
乙酸味	Other	0.635	0.204	0.406
苦度	Other	0.589	0.362	0.780
酒体	Other	0.523	0.302	0.736
酒花味-总	Flavour	0.502	0.391	0.716
后味	Other	0.494	0.342	0.705

麦芽味-总	Flavour	0.485	0.388	0.709
麦芽香-总	Aroma	0.409	0.431	0.657
麦芽味-烟熏	Flavour	0.399	0.343	0.614
酒花味-草本干草	Flavour	0.381	0.359	0.651
酒花香-总	Aroma	0.344	0.401	0.604
麦芽味-焦糖	Flavour	0.328	0.350	0.599
麦芽香-焦糖	Aroma	0.308	0.381	0.593
碳酸感	Other	0.308	0.400	0.570
酯味-总	Flavour	0.307	0.385	0.566
麦芽香-烟熏	Aroma	0.291	0.339	0.351
酒花香-草本干草	Aroma	0.291	0.345	0.565
甜度	Other	0.274	0.429	0.569
麦芽味-面包	Flavour	0.249	0.320	0.575
酯味-溶剂指甲油	Flavour	0.230	0.334	0.494
酒花味-柑橘	Flavour	0.226	0.299	0.405
酯香-总	Aroma	0.206	0.426	0.465
4-乙烯基愈创木酚	Other	0.206	0.387	0.536
酒花味-热带水果	Flavour	0.169	0.303	0.390
酒花味-木质松脂	Flavour	0.164	0.308	0.446
酯香-溶剂指甲油	Aroma	0.163	0.364	0.394
酒花香-柑橘	Aroma	0.162	0.336	0.415
酯味-香蕉	Flavour	0.138	0.390	0.391
芫荽	Other	0.136	0.239	0.128
酯味-果香	Flavour	0.128	0.333	0.318
反-2-壬烯醛	Other	0.126	0.295	0.213
总体喜好	Other	0.121	0.401	0.272
酒花香-热带水果	Aroma	0.118	0.348	0.284
金属味	Other	0.117	0.357	0.363
麦芽香-面包	Aroma	0.115	0.342	0.406
酒花香-木质松脂	Aroma	0.083	0.264	0.245
酯香-香蕉	Aroma	0.082	0.403	0.300
麦芽香-谷物	Aroma	0.081	0.331	0.244
橙味	Other	0.074	0.347	0.310
双乙酰	Other	0.070	0.372	0.274
麦芽味-谷物	Flavour	0.068	0.337	0.256
酯香-果香	Aroma	0.053	0.346	0.137
二甲基硫	Other	0.044	0.369	0.229
丁香	Other	0.043	0.262	0.270
酯香-花香	Aroma	0.042	0.311	0.209
畜棚味	Other	0.039	0.308	0.226

酯味-花香	Flavour	0.030	0.293	0.163
陈酒花味	Other	0.024	0.306	0.185

B.2 问题 2 全部维度的 Top-3 关键化合物

表 B-2 50 个感官维度的 Top-3 关键化合物（稳定性为 bootstrap 平均入选频率）

感官维度	Top-1	Top-2	Top-3	稳定性
麦芽香-总	Ethanol	Acetaldehyde	Beta-phellandrene	0.62
麦芽香-谷物	Beta-phellandrene	Terpinen-4-ol	Isoborneol	0.49
麦芽香-面包	Ethanol	Glycerol	Acetaldehyde	0.39
麦芽香-焦糖	Acetaldehyde	Ethanol	2-ethyl-1-hexanol	0.53
麦芽香-烟熏	Ethanol	Diethyl sulfide	Isobutanol	0.41
酒花香-总	Ethyl octanoate	Ethyl decanoate	E-2-nonenal	0.50
酒花香-柑橘	Citronellol	1,2-dihydro-8-hydroxy-2E-linalool	Humulene epoxide II	0.36
酒花香-热带水果	Beta-phellandrene	Dimethyl sulfide	Methyl geranate	0.41
酒花香-草本干草	Ethyl octanoate	Ethyl decanoate	Isopentyl hexanoate	0.63
酒花香-木质松脂	Trans-dihydro-α-terpinyl acetate	α-calacorene	Ethyl tetradecanoate	0.20
酯香-总	Acetaldehyde	N-hexanol	Ethyl acetate	0.66
酯香-溶剂指甲油	Ethyl acetate	Ethanol	Acetaldehyde	0.52
酯香-香蕉	N-hexanol	Isoamyl acetate	Isoamyl alcohol	0.54
酯香-花香	Beta-phellandrene	N-hexanol	Isobutyl acetate	0.23
酯香-果香	Beta-phellandrene	Eugenol	Neryl formate	0.33
麦芽味-总	Ethanol	Acetaldehyde	Methanethiol	0.73
麦芽味-谷物	Isoborneol	Terpinen-4-ol	Terpinen-4-ol acetate	0.34
麦芽味-面包	Acetaldehyde	Ethanol	Glycerol	0.67
麦芽味-焦糖	Acetaldehyde	Ethanol	N-hexanol	0.74
麦芽味-烟熏	Ethanol	Methanethiol	Iso-alpha acids	0.64
酒花味-总	Ethyl octanoate	Ethanol	Iso-alpha acids	0.63
酒花味-柑橘	Geosmin	Furfural	Ethyl furoate	0.31
酒花味-热带水果	Beta-phellandrene	Geraniol	Dimethyl sulfide	0.38
酒花味-草本干草	Ethyl octanoate	Ethanol	Ethyl decanoate	0.64
酒花味-木质松脂	Iso-alpha acids	Ethyl tetradecanoate	Ethyl decanoate	0.33
酯味-总	Acetaldehyde	Ethyl acetate	Ethanol	0.75
酯味-溶剂指甲油	Ethanol	Ethyl acetate	Acetaldehyde	0.73
酯味-香蕉	N-hexanol	Isoamyl acetate	Acetaldehyde	0.59
酯味-花香	Beta-phellandrene	Eucalyptol	Limonene	0.30
酯味-果香	Diethyl sulfide	Acetic acid	Beta-phellandrene	0.41
酸度	Prenyl isobutyrate	Ethyl phenylacetate	Perillyl acetate	0.55
苦度	Ethyl octanoate	Ethyl decanoate	Ethanol	0.62
甜度	Ethyl decanoate	Pentyl octanoate	2-methylbutyl octanoate	0.45
4-乙烯基愈创木酚	Neryl formate	Prenyl isobutyrate	4-vinylguaiacol	0.55

双乙酰	Ethyl decanoate	Eugenol	Furfural	0.35
二甲基硫	Terpinen-4-ol	E-nerolidol	Car-3-en-2-one	0.11
金属味	Ethyl 3-methylbutyrate	Neryl formate	Methyl heptenone	0.34
陈酒花味	2-undecanol	Gamma-eudesmol	Allo-aromadendrene epoxide	0.46
反-2-壬烯醛	Beta-phellandrene	Geraniol	α-phellandrene	0.28
橙味	Limonene	Camphor	Ethanol	0.61
芫荽	2-methyl-benzofuran	Limonene	Ethyl linalool	0.25
丁香	Limonene	Eucalyptol	Camphor	0.48
乳酸味	Lactic acid	Prenyl isobutyrate	Perillyl acetate	0.56
乙酸味	Prenyl isobutyrate	Ethyl 3-methylbutyrate	Neryl formate	0.66
畜棚味	2-undecanol	Gamma-eudesmol	Allo-aromadendrene epoxide	0.44
酒精感	Ethanol	Ethyl octanoate	Acetaldehyde	0.71
后味	Ethanol	Ethyl octanoate	Ethyl decanoate	0.64
酒体	Ethanol	Ethyl octanoate	Glycerol	0.66
碳酸感	Ethyl octanoate	Ethanol	Ethyl decanoate	0.71
总体喜好	Ethyl acetate	Ethyl octanoate	Ethanol	0.54

B.3 问题 2 主要社区的来源富集检验

表 B-3 共表达社区概况（全部社区）

社区	规模	核心化合物
0	29	ethyl.phenylacetate; prenyl.isobutyrate; neryl.forma
1	27	nerol.oxide; alpha.calacorene; alpha.muurolol; caryo
2	23	X.E..beta.ionone; X3.furanmethanol; n.nonanol; ortho
3	19	ethyl..E..linalool; terpinen.4.ol; isoborneol; beta.
4	18	ethanol..v.v.; glycerol; isopentyl_acetate; isobutyl
5	17	pentyl.octanoate; X1.2.dihydro.8.hydroxy..2E..linalo
6	13	X2.methyl.1.butanol; isopentyl.formate; n.pentanol;
7	11	X2Z.6E.farnesol; E.nerolidol; X2.3.dihydro.farnesol;
8	7	diethyl.succinate; gamma.nonalactone; ethyl.nicotina
9	2	X13.epi.manool.oxide; neo.allo.ocimene
10	2	E.methyl.isoeugenol; butylated.hydroxytoluene
11	1	CS2
12	1	DMS
13	1	ethyl_propionate
14	1	phenethyl_alcohol
15	1	X4VG
16	1	SO2.mg.L.

17	1	acetic_acid.g.L.
18	1	ammonia.mg.L.
19	1	bitterness
20	1	propylene.glycol
21	1	ethyl.isobutyrate
22	1	X2.methyltetrahydrofuran.3.one
23	1	ethyl.lactate
24	1	X3Z.hexenol
25	1	styrene
26	1	X6.methyl.5.hepten.2.one
27	1	dehydroxy.cis.linalool.oxide
28	1	hexyl.acetate
29	1	eucalyptol
30	1	cis.linalool.oxide
31	1	meta.cymenene
32	1	n.nonanal
33	1	trans.dihydro.beta.terpineol
34	1	cis.beta.terpineol
35	1	vinyl.caprylate
36	1	X2.undecanone
37	1	delta.terpinyl.acetate
38	1	eugenol
39	1	methyl.para.anisate
40	1	vanillin
41	1	dodecanal
42	1	X4.8.alpha.epoxy.caryophyllane
43	1	E.caryophyllene
44	1	beta.humulene
45	1	linalool.isovalerate
46	1	valencene
47	1	X.Z..dihydro.apofarnesal
48	1	X.E..dihydro.apofarnesal
49	1	Z.nerolidol
50	1	isopropyl.laurate
51	1	tau.cadinol
52	1	alpha.eudesmol
53	1	foeniculin
54	1	cadalene
55	1	caryophyllene.acetate
56	1	X14.hydroxy.alpha.humulene
57	1	X2Z.6Z.farnesol
58	1	X2E.6E.methyl.farnesoate
59	1	X2.ethylhexylsalicylate
60	1	X2.ethyl.3.methylpyrazine